

Tecnológico de Monterrey
Escuela de Ingeniería y Ciencias

Proyecto Integrador

Avance 3 — Modelos de referencia y validación temporal de ventas por tienda y categoría

Entrega Colaborativa:

Daniel Juárez Ortiz - A01797369

Kevin Alexis Valdez Pérez- A01750478

Yael Ariel Márquez Mas - A01745310

17 de octubre de 2026

Avance 3 · Baseline

1. Resumen ejecutivo

El Avance 3 presenta una evaluación experimental de modelos de referencia para pronosticar ventas monetarias diarias por tienda y categoría. La evaluación utiliza información procesada disponible en el servidor, un horizonte fijo de 14 días y cuatro ventanas temporales consecutivas. Se comparan dos reglas de referencia —patrón semanal y media fija de siete días— con dos modelos LightGBM: Log1p y Tweedie.

La corrida principal evaluó 180 series de tienda–categoría en cuatro cortes temporales, con 40,320 predicciones individuales verificadas como consistentes con las métricas registradas. En las tres ventanas de desarrollo, LightGBM Log1p obtuvo el menor WMAPE conjunto (0.4583), mientras que LightGBM Tweedie alcanzó un WMAPE muy próximo (0.4612) y un sesgo conjunto más cercano a cero (−1.92 % frente a −13.69 %). Ambos métodos superaron al baseline semanal en la muestra analizada.

El estado de la ejecución es EJECUTADO_EXPLORATORIO. La consistencia de predicciones y métricas no constituye aprobación integral de calidad de los datos ni certificación para producción. No se ejecutó un modelo por marca en esta corrida. Esta distinción permite presentar resultados empíricos sin atribuir propiedades que todavía no se encuentran acreditadas.

2. Alcance, fuente y registro experimental

2.1. Unidad de análisis y fuente de entrada

La variable objetivo es venta_total, expresada como importe monetario diario registrado. La unidad de observación evaluada corresponde a la combinación tienda–categoría–fecha. Se empleó una fuente procesada preexistente, identificada en el servidor como data/processed/dataset_modelado_externas_final_padded_mayo.parquet. La presencia de esta fuente y de sus campos esenciales fue verificada, pero su calidad de origen continúa sujeta a controles adicionales.

La selección de 180 series representa una muestra operacional acotada; no equivale a cobertura de todas las tiendas o categorías disponibles. El parámetro de la segunda ejecución permitió hasta 20 tiendas y 180 series, sin que el límite de tiendas por sí solo acredite cuántas tiendas distintas resultaron seleccionadas. La cobertura registrada de 1.0 se refiere a la población efectivamente evaluada en cada corte.

2.2. Corridas ejecutadas y selección de evidencia

Se conservan dos ejecuciones exploratorias independientes: una inicial de 100 series, con 22,400 predicciones verificadas, y una ampliada de 180 series, con 40,320 predicciones verificadas. Ambas contienen cuatro modelos y cuatro cortes de 14 días. El incremento de tamaño de muestra no debe interpretarse como mejora algorítmica, dado que modifica la población evaluada.

Para el presente reporte se establece como referencia principal la corrida 20261017T211646Z_entrenar_prueba_703ede88, ejecutada con la configuración ampliada. La verificación posterior obtuvo el estado PREDICCIONES_CONSISTENTES_CON_METRICAS para categoría. El informe técnico de esta misma corrida fue generado por el procedimiento de la Etapa 6. La corrida anterior permanece como antecedente experimental sin ser sobrescrita.

2.3. Delimitaciones de calidad de la fuente

El dataset utilizado es una fuente heredada: las auditorías existentes de duplicados y descuentos no demuestran, por sí solas, que todas las correcciones hayan sido incorporadas a la tabla de entrenamiento. Tampoco se ha acreditado completamente la separación entre ceros comerciales y periodos sin información o inactividad. Por ello, los resultados se interpretan como evaluación exploratoria sobre el conjunto disponible, no como medición final de un producto operacional.

La predicción corresponde a ventas registradas en moneda, no a unidades vendidas ni a demanda insatisfecha. Por tanto, una mejora del WMAPE no puede convertirse directamente en una reducción demostrada de quiebres de inventario, mermas o costos comerciales.

3. Metodología de validación temporal

3.1. Diseño walk-forward de origen único

Se definieron cuatro ventanas consecutivas de 14 días: F1, con origen 5 de abril de 2026 y evaluación del 6 al 19 de abril; F2, con origen 19 de abril y evaluación del 20 de abril al 3 de

mayo; F3, con origen 3 de mayo y evaluación del 4 al 17 de mayo; y F4, con origen 17 de mayo y evaluación del 18 al 31 de mayo.

En cada ventana, las catorce predicciones parten de un mismo origen. El patrón semanal de la segunda semana se calcula a partir de los últimos siete días conocidos antes del origen, sin sustituirlos por ventas observadas durante la primera semana del horizonte. Las variables históricas del experimento se diseñaron a partir de información conocida al origen y del calendario del día objetivo. Este control del procedimiento no sustituye una auditoría de la procedencia temporal de todas las columnas del dataset heredado.

Los cortes F1, F2 y F3 conforman el conjunto de desarrollo. F4 se identifica expresamente como evaluación históricamente consultada: puede describirse, pero no es un test completamente intacto y no debe utilizarse para ajustar parámetros o justificar una selección retrospectiva del modelo.

3.2. Modelos y características

El baseline Naive semanal repite el patrón de los siete días previos al origen. El baseline Media de 7 días utiliza una media fija calculada con la historia disponible antes de pronosticar. LightGBM Log1p ajusta un modelo sobre la transformación log(1 + venta) y después retransforma sus predicciones; LightGBM Tweedie ajusta un objetivo adecuado para valores monetarios no negativos con numerosos ceros. Los cuatro métodos se contrastan sobre las mismas claves y fechas de evaluación.

La implementación exploratoria emplea un subconjunto de características temporales y de identificación; no reproduce íntegramente el contrato más amplio de características por categoría y marca. La selección y el ajuste se evalúan en las ventanas de desarrollo. El valor de las importancias procede de los modelos efectivamente ajustados y no se considera evidencia causal.

3.3. Indicadores y reglas de interpretación

La métrica principal es WMAPE, definida como la suma de errores absolutos dividida entre la suma de ventas observadas del conjunto evaluado; valores menores indican menor error. El sesgo porcentual compara el volumen total pronosticado frente al observado: un valor positivo indica sobrepredicción neta y uno negativo indica subpredicción neta. MAE y RMSE figuran entre los indicadores del procedimiento, pero no se incorporan aquí cifras que no fueron contrastadas en esta revisión.

Los resúmenes F1–F3 se calculan ponderando por el denominador de WMAPE de cada corte, no mediante el promedio simple de sus porcentajes. La comparación entre modelos utiliza las

mismas observaciones: se verificó igualdad de claves y fechas entre los cuatro modelos en F1, F2, F3 y F4, con 180 series por corte.

4. Resultados del experimento ampliado

4.1. Comparación de WMAPE por corte

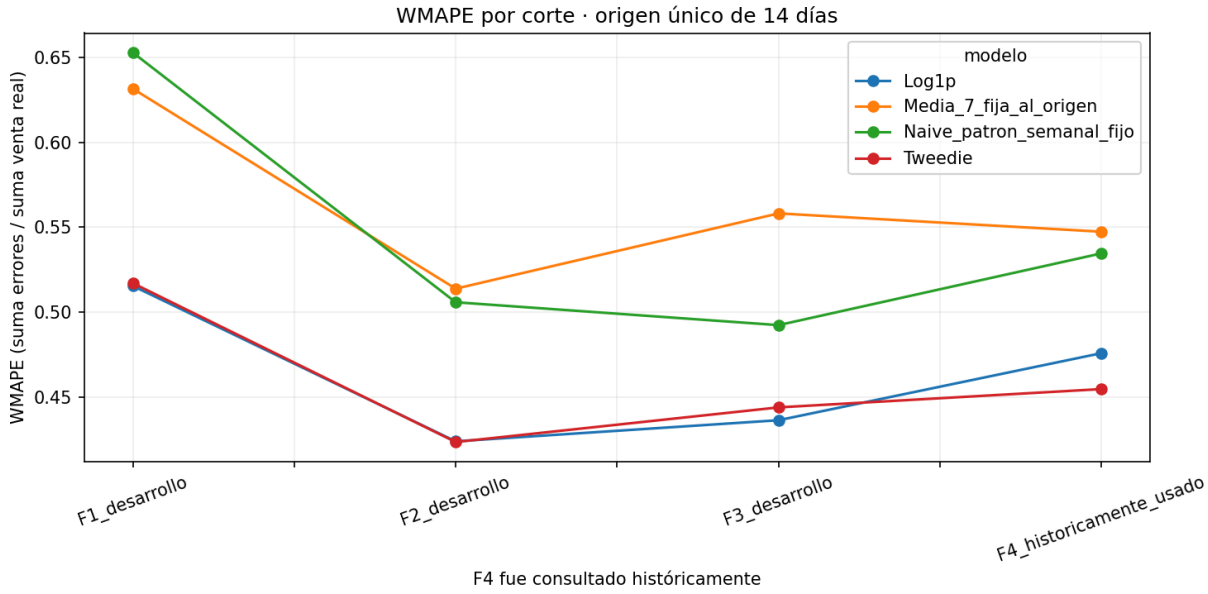
Tabla 1. WMAPE por modelo y corte de 14 días; corrida de 180 series.

Modelo	F1	F2	F3	F4*
Log1p	0.5155	0.4242	0.4366	0.4760
Tweedie	0.5171	0.4238	0.4441	0.4549
Naive semanal	0.6527	0.5059	0.4925	0.5346
Media fija 7 días	0.6314	0.5139	0.5581	0.5474

Nota: F4 (*) es un corte históricamente utilizado; se reporta con fines descriptivos, no como prueba intacta de selección.

En F1 se observan los mayores errores de la secuencia para los cuatro métodos. En F2 y F3 disminuye el WMAPE, especialmente para los modelos LightGBM. La superioridad de Log1p y Tweedie frente a las referencias ingenuas se observa en cada uno de los cuatro cortes de esta muestra, aunque la diferencia relativa varía según el periodo.

Figura 1. Trayectoria de WMAPE por corte, con horizonte de 14 días desde un origen fijo.



Fuente técnica: figura almacenada en el notebook de la corrida ampliada. F4 fue consultado históricamente.

4.2. Precisión y sesgo agregados durante desarrollo

Tabla 2. WMAPE conjunto y sesgo porcentual ponderado, F1–F3.

Modelo	WMAPE F1-F3	Sesgo F1-F3
Log1p	0.4583	-13.69 %
Tweedie	0.4612	-1.92 %
Naive semanal	0.5495	+11.10 %
Media fija 7 días	0.5673	+11.10 %

Nota: resultados sobre las mismas 180 series seleccionadas; no representan un desempeño sobre la totalidad de la red.

LightGBM Log1p presentó el menor WMAPE en desarrollo, 0.4583, seguido de Tweedie con 0.4612. La separación absoluta es 0.0029, equivalente a 0.29 puntos porcentuales de WMAPE. Frente al Naive semanal, Tweedie redujo el WMAPE conjunto en aproximadamente 16.1 % en la muestra evaluada. Estas diferencias describen el experimento y no constituyen por sí solas una prueba de superioridad estadística universal.

En contraste, el sesgo agregado fue −13.69 % para Log1p y −1.92 % para Tweedie. Una subpredicción neta más pequeña puede ser relevante para el análisis comercial, pero debe

verificarse por corte y por segmento para evitar que errores de signo opuesto se compensen. Por esta razón, Tweedie se mantiene como candidato de interés para análisis posterior, sin designarlo campeón aprobado.

4.3. Comportamiento del sesgo por periodo

Los valores individuales de sesgo de Tweedie fueron aproximadamente +10.14 % en F1, −6.34 % en F2 y −9.24 % en F3; el resumen ponderado de −1.92 % refleja compensación parcial entre ventanas. Por su parte, Log1p pasó de un sesgo cercano a cero en F1 (+0.01 %) a subpredicciones de −18.98 % en F2 y −21.74 % en F3. La lectura conjunta del WMAPE y del sesgo resulta por ello necesaria para valorar el comportamiento del modelo.

4.4. Referencia descriptiva del cuarto corte

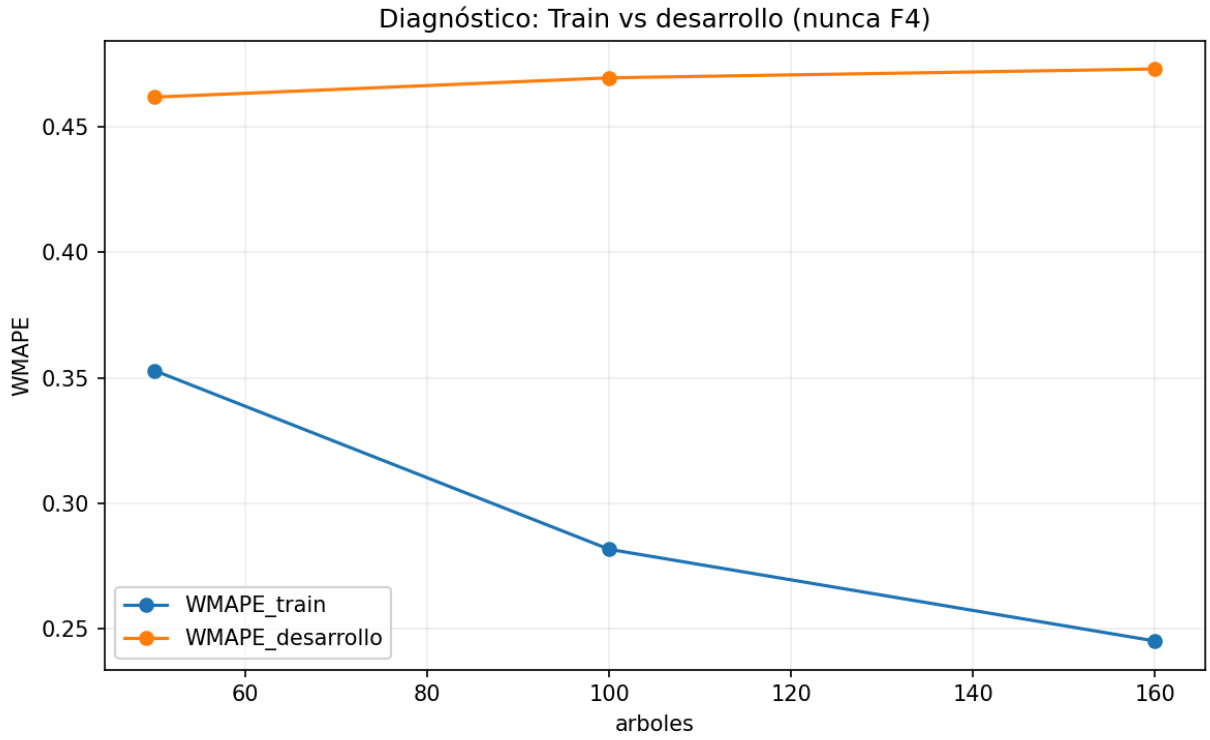
En F4, LightGBM Tweedie registró WMAPE 0.4549 y sesgo −12.98 %; Log1p registró 0.4760 y −26.93 %. Los métodos Naive semanal y Media fija de siete días obtuvieron WMAPE 0.5346 y 0.5474, respectivamente. Estas cifras se presentan únicamente como evidencia histórica de la corrida, sin considerarlas una evaluación final independiente.

5. Diagnóstico de ajuste y relevancia de características

5.1. Relación entre entrenamiento, desarrollo y complejidad

La curva de LightGBM Tweedie compara el error de entrenamiento con el de desarrollo en F1–F3 a diferentes números de árboles. Al aumentar la complejidad de 50 a 160 árboles, el error de entrenamiento disminuye, mientras que el error de desarrollo tiende a aumentar ligeramente. Esta divergencia es compatible con un mayor riesgo de sobreajuste y justifica priorizar la métrica fuera de muestra para seleccionar la complejidad.

Figura 2. Curva de ajuste de LightGBM Tweedie: WMAPE de entrenamiento frente a desarrollo.



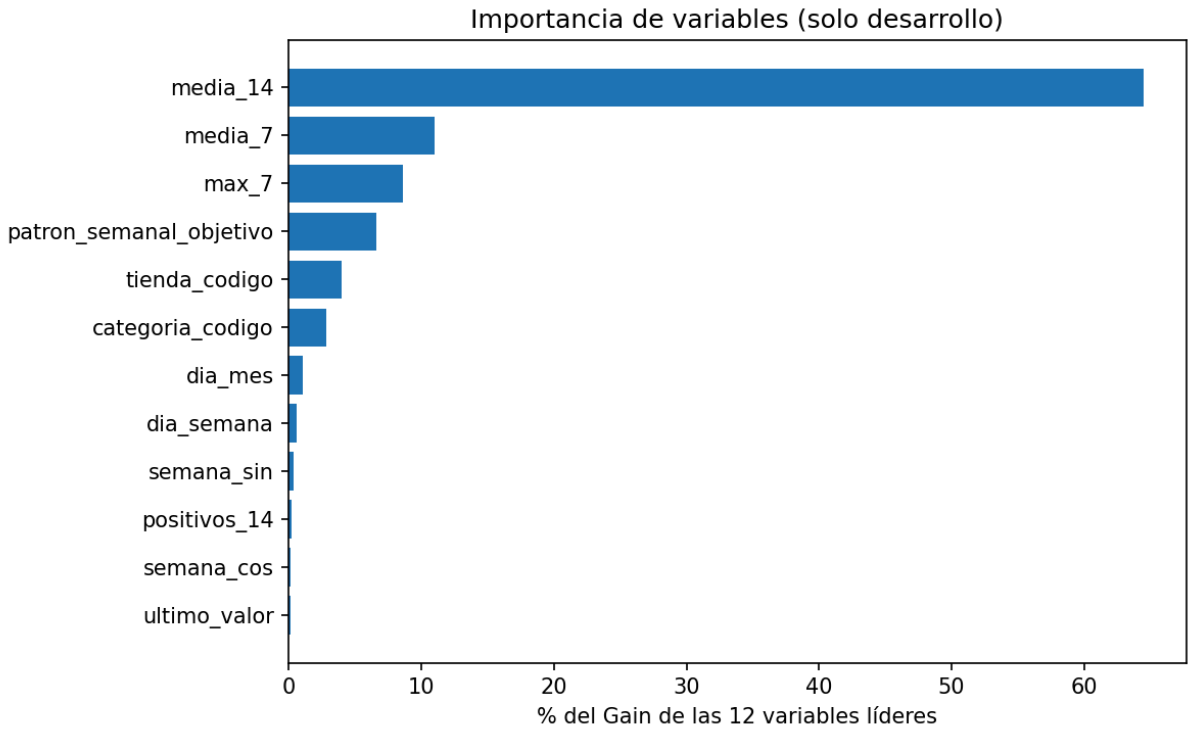
Fuente técnica: curva correspondiente únicamente a Tweedie y a los cortes F1–F3; F4 está excluido.

Una curva con brecha pequeña o estable en determinados periodos no demuestra, por sí sola, ausencia general de sobreajuste. La variabilidad temporal, el tamaño de historia disponible y las limitaciones de la fuente deben considerarse antes de hacer afirmaciones de generalización.

5.2. Importancia relativa de las variables

La importancia por ganancia de los modelos de esta corrida sitúa a media_14 como el predictor dominante entre las doce variables líderes. A continuación aparecen media_7, max_7 y patron_semanal_objetivo. Este patrón señala una dependencia predictiva importante de la historia reciente, sin establecer relaciones de causa y efecto.

Figura 3. Importancia de variables de LightGBM en desarrollo, normalizada entre las 12 variables líderes.



Fuente técnica: figura obtenida de los resultados de desarrollo del notebook; los porcentajes no representan la totalidad de características del contrato más amplio.

El cambio de importancia relativa respecto de la corrida inicial de 100 series no demuestra por sí mismo un cambio en la calidad del algoritmo. La ampliación de la muestra cambia la composición de las series evaluadas, de modo que ambas ejecuciones se conservan como evidencia de sensibilidad a la población seleccionada.

6. Evidencia de ejecución y reproducibilidad

La secuencia verificable comprende inventario inicial de fuentes, baselines, entrenamiento exploratorio, verificación de predicciones contra métricas y generación de informe. Para la corrida ampliada, el verificador devolvió el estado PREDICCIONES_CONSISTENTES_CON_METRICAS, 40,320 predicciones y los cuatro modelos esperados. Los resultados se almacenaron en un directorio de corrida independiente, sin sobrescribir la primera ejecución.

La existencia de CSV con métricas, figuras o directorios asociados a MLflow constituye evidencia de artefactos, pero no acredita por sí sola un registro experimental completo. En las

rutas inspeccionadas no se verificaron corridas MLflow con parámetros, métricas y artefactos asociados; por ello no se afirma trazabilidad formal mediante MLflow. Del mismo modo, no se localizó una tabla Gold validada por marca en las rutas examinadas.

7. Estado de calidad, restricciones y criterios de aceptación

La revisión del contrato de calidad mantuvo el estado PENDIENTE_NO_APROBADO. Los controles pendientes abarcan procedencia y productor, deduplicación y conciliación de identificadores de línea, tratamiento de ceros y días inactivos, objetivo monetario e impuestos/devoluciones, disponibilidad temporal de variables y consistencia de periodo y llaves. Dichos controles no invalidan la ejecución experimental, pero impiden declarar aprobación formal de la fuente y del modelo para producción.

La corrida principal se realizó exclusivamente por categoría. El modelo por marca figura como NO_EJECUTADO debido a que no estuvo disponible una fuente apta para este flujo. Las evaluaciones basadas en muestras acotadas tampoco acreditan desempeño para la totalidad de la población de tiendas. No se consideran implementados un Feature Store productivo, un proceso batch de predicción futura ni un simulador de escenarios comerciales.

Los datos originales y los resultados previos se preservan. La ejecución de nuevas consolidaciones transaccionales y el almacenamiento de copias en directorios personales quedan fuera del alcance permitido. La continuidad debe basarse en fuentes y permisos efectivamente disponibles en el servidor.

8. Continuidad técnica de las siguientes faseS

El siguiente trabajo experimental puede extender el protocolo a pronósticos probabilísticos P10, P50 y P90, comparados con las referencias puntuales existentes y evaluados mediante pérdida Pinball, cobertura y amplitud de intervalos. Será necesario conservar el origen temporal de cada pronóstico, restringir los predictores a información disponible al momento de emisión y mantener separada la evaluación históricamente utilizada.

La arquitectura futura contempla procesos por lotes, gobierno de características, trazabilidad de modelos y publicación de pronósticos para consulta comercial. Azure Databricks, Delta Lake, Unity Catalog, Workflows y la integración SQL/API/React se mantienen como componentes de diseño condicionados a la infraestructura y permisos actuales; no se presentan como despliegues realizados.

9. Conclusiones

La evaluación de 180 series confirma la viabilidad técnica de comparar pronósticos diarios de 14 días con un origen fijo y métricas reproducibles. Los modelos LightGBM redujeron el WMAPE frente a las referencias ingenuas en los cortes examinados. Log1p obtuvo la mejor precisión agregada F1–F3 (0.4583), mientras que Tweedie combinó un error cercano (0.4612) con un menor sesgo neto (−1.92 %).

Se recomienda conservar ambas formulaciones en futuras evaluaciones y priorizar la revisión del sesgo por segmento, la calidad de la fuente y la generalización temporal antes de designar un modelo campeón. La evidencia disponible permite documentar una entrega experimental del Avance 3, pero no certificar un sistema productivo ni extrapolar los resultados a una población no evaluada.

s.