

Tecnológico de Monterrey
Escuela de Ingeniería y Ciencias

Proyecto Integrador

Evolución del Modelado Predictivo de Ventas a Nivel SKU y Sector Promociones para 17,000 Tiendas mediante MLOps y Simulación de Escenarios en Azure Databricks

Entrega Colaborativa:

Daniel Juárez Ortiz - A01797369

Kevin Alexis Valdez Pérez- A01750478

Yael Ariel Márquez Mas - A01745310

11 de Octubre, del 2026

Cuarto Entregable

Avance 2. Ingeniería de características

Construcción, transformación y selección de las variables que alimentarán el pronóstico de demanda de ~17,000 tiendas de conveniencia, ejecutada y persistida en el servidor local (`/opt/predictive_sales`) con la corrección de los defectos heredados que afectan a esta fase y sin modificar las libretas existentes. Preparado por el Equipo 43.

Indicador de la Fase	Valor	Alcance Semana 4
DEFECTOS HEREDADOS	**6 de 8**	Corregidos en esta fase; los dos restantes se consolidan en el Avance 3
VARIABLES CANDIDATAS	**52 → 43**	52 evaluadas en 8 grupos (todas disponibles antes del día a pronosticar); **43 conservadas** y **9 eliminadas**
GRANO DE TRABAJO	**Categoría**	Tienda × categoría × día (`41,682,490` filas); los granos **Marca** y **Top N SKU** se miden en paralelo

Entregable Técnico	Descripción y Acuerdo Operativo con Bnext
ENTREGABLE	**Libreta nueva `notebooks/Avance Semana 4 Ingeniería de características.ipynb`** en el repositorio del equipo (y ejecutable de extremo a extremo en **Google Colaboratory**), corrida de forma secuencial y persistida en el **servidor local (`/opt/predictive_sales`)** sin modificar ninguno de los notebooks previos (`Avance1.12.ipynb`, `Avance2.12.ipynb`, `03` a `06`). En seguimiento a la llamada semanal con **Bnext**, mientras la empresa evalúa el presupuesto para la arquitectura MLOps en Azure Databricks, el pipeline se ejecuta localmente con rutas desacopladas (`config/paths.yml`) listas para migración inmediata a la nube.

INTEGRANTES DEL EQUIPO 43

NOMBRE COMPLETO DEL ESTUDIANTE	MATRÍCULA
Daniel Juárez Ortiz	A01797369
Kevin Alexis Valdez Pérez	A01750478
Yael Ariel Márquez Mas	A01745310

Rol	Nombre / Institución
Asesora	Dra. Eduviges Ludivina Facundo
Patrocinador	Dr. Juan Arturo Nolazco Flores, Director del Hub de Ciencia de Datos
Fecha de entrega	11 de octubre de 2026

SECCIÓN 1. Punto de partida y diferencias frente a la entrega previa

La ingeniería de características es la etapa donde se decide qué información ve el modelo y en qué forma. Es también donde el prototipo heredado concentraba sus errores más costosos: el Avance 1 documentó ocho defectos técnicos del trabajo previo (Avance2.12.ipynb y 06_variables_externas.ipynb), y seis de ellos nacen o se resuelven directamente en esta fase.

Asimismo, en atención al acuerdo establecido en la sesión semanal con el equipo de Bnext, mientras la empresa revisa internamente el presupuesto para el despliegue de la arquitectura MLOps en Azure Databricks, se determinó avanzar con la ejecución y almacenamiento de todos los entregables en el servidor local (/opt/predictive_sales), creando una libreta completamente nueva (notebooks/AvanceSemana4.ipynb) y un módulo compartido (src/features/construir.py) que preservan intactos los notebooks anteriores.

1.1 Defectos heredados que esta fase corrige

#	DEFECTO DOCUMENTADO EN EL AVANCE 1	EFECTO SOBRE LAS CARACTERÍSTICAS EN EL TRABAJO PREVIO	CORRECCIÓN IMPLEMENTADA EN ESTA FASE (`Avance Semana 4 Ingeniería de características.ipynb`)
1	**Duplicados de `order_line_id`:** `1,632,085` filas (`1.1615 %`) diagnosticadas en `03_auditoria_datos` pero sin eliminar en `04_limpieza_ejecucion` ni en `Avance2.12`.	Inflan la venta agregada en `$143.16M MXN` y contaminan todos los rezagos y medias móviles en días con reproceso de carga.	Deduplicación determinista por llave de línea antes de agregar, separando copias exactas (`1,489,210`) y actualizaciones por `sync_date` (`142,875`) (sección 2.1).
2	**Relleno de ceros global sobre los 92 días** para todas las tiendas (`cross join` en `Avance2.12`), aunque `5,670` (`36.45 %`) operaron menos de 61 días.	Introduce `5,128,940` ceros falsos antes de la apertura de tiendas o durante apagones (`262,805` celdas), sesgando hacia abajo las medias móviles.	Relleno acotado exclusivamente a la ventana activa `[min_fecha_tienda, max_fecha_tienda]` de cada tienda y separación de días de inactividad total (sección 2.3).

#	DEFECTO DOCUMENTADO EN EL AVANCE 1	EFECTO SOBRE LAS CARACTERÍSTICAS EN EL TRABAJO PREVIO	CORRECCIÓN IMPLEMENTADA EN ESTA FASE (`Avance Semana 4 Ingeniería de características.ipynb`)
3	**Descuento con error de escala:** `1,777,136` filas por encima del `100 %` en `order_line_discount_percent`.	En `Avance2.12` la variable de descuento quedó reducida a una simple bandera binaria (`> 0`), perdiendo la profundidad de la oferta.	Tasa efectiva continua reconstruida desde los importes como cociente de sumas (MI sube de `0.1328` a `0.1684`, `+26.8 %`) (sección 2.2).
4	**Marca sin aprovechar y catálogo de categorías inconsistente** (categoría `617` sin nombre, `YOGURT` id `548` y `YOGURTH` id `715` duplicadas).	Series fragmentadas por ortografía y ausencia de evidencia cuantitativa sobre la densidad del grano marca y SKU.	Homologación del catálogo (`232` categorías y `1,391` marcas canónicas) y medición empírica de densidad en los tres granos (sección 2.4).
6	***Training-serving skew*:** la inferencia (`predict.ipynb`) definía fin de semana (`weekday >= 5`) y quincena (`[15, 30]`) distinto que el entrenamiento, y aplicaba un segundo `.shift(2)` a variables ya rezagadas.	El modelo servido en producción recibía variables desfasadas y con definiciones distintas a las que aprendió.	Una sola función de construcción de características (`src/features/construir.py`) compartida por entrenamiento, inferencia y simulador, verificada con prueba unitaria anti-fuga (sección 3.3).
7	**Yeo-Johnson ajustado sobre todo el conjunto** antes de separar entrenamiento y prueba (`Avance1.12`), y umbral de varianza aplicado sobre datos ya estandarizados a varianza `1.0` (`Avance2.12`).	Fuga de la distribución del periodo de prueba hacia el entrenamiento e inoperancia del filtro `VarianceThreshold(0.01)`.	Toda transformación y escalador se ajusta sólo con la ventana de entrenamiento (`fecha <= 2026-04-30`), y el filtro de varianza se aplica sobre escala `Min-Max [0, 1]` (secciones 4.3, 4.4 y 5.2).

Los dos defectos restantes quedan fuera de esta fase por su naturaleza: la pérdida de 8.37 % de tiendas en el cruce geográfico exacto por código postal se mitiga mediante el rescate por coordenadas/prefijo postal documentado en el repositorio, y el riesgo de sobreajuste por evaluar el modelo en un único *holdout* de 14 días se resuelve con la **validación *walk-forward*** en el **Avance de la semana 5**.

1.2 Síntesis de diferencias y mejoras frente a lo presentado con anterioridad (Avance2.12.ipynb y 06_variables_externas.ipynb)

La siguiente tabla detalla puntualmente qué hacía el pipeline anterior (repartido entre Avance2.12.ipynb y 06_variables_externas.ipynb), qué cambia en la nueva libreta notebooks/Avance Semana 4 Ingeniería de características.ipynb y cuál es la ganancia técnica obtenida sin alterar los archivos originales:

Dimensión	Presentado con anterioridad (Avance2.12.ipynb + 06_variables_externas.ipynb)	Nuevo entregable (notebooks/Avance Semana 4 Ingeniería de características.ipynb — Equipo 43)	Diferencia y mejora lograda
Estructura del pipeline y preservación de archivos	Dos libretas separadas: Avance2.12.ipynb generaba 21 variables internas y 06_variables_externas.ipynb unía geografía, INEGI, deporte y clima, dejando variables intermedias y venta_total_log dentro del Parquet final.	**Una sola libreta nueva E2E (notebooks/Avance Semana 4 Ingeniería de características.ipynb)** apoyada en src/features/construir.py y config/paths.yml. Los notebooks existentes no se modifican; los nuevos artefactos se escriben en rutas propias dentro de /opt/predictive_sales/data/.	Pipeline reproducible de extremo a extremo en el servidor local y en Google Colaboratory, sin riesgo de usar venta_total_log como predictor.
Calidad de volumen base	Agregaba sobre 140,503,226 filas sin eliminar los 1,632,085 duplicados de order_line_id.	Deduplica order_line_id antes de agregar (1,489,210 copias exactas + 142,875 actualizaciones por sync_date), partiendo de **138,871,141 líneas únicas**.	Elimina **$143,156,221.70 MXN (1.168 %)** de inflación artificial de ingresos.
Construcción del panel temporal (*Zero-Padding*)	cross join global de 552,991 series × 92 días (47,004,235 filas post *warm-up*, **61.16 % de ceros**).	Relleno acotado a la ventana operativa [min_fecha_tienda, max_fecha_tienda] de cada tienda y exclusión de 262,805 celdas de tienda inactiva (0 tickets en tienda).	El panel se depura a **41,682,490 filas (-11.32 %)** y la proporción de ceros baja a **52.38 % (-8.78 pp)**.
Amplitud y diseño de variables candidatas	21 variables internas en Avance2.12 + 9 variables deportivas redundantes en 06_variables_externas (44 predictores evaluados sin variables explícitas de intermitencia ni volatilidad).	**52 variables candidatas en 8 grupos**, añadiendo **15 variables nuevas** (dom_sin, dom_cos, dias_a_quincena, dia_previo_festivo, venta_lag_28, venta_rm_28, venta_rstd_7, venta_rstd_28, tendencia_7_28, dias_desde_ultima_venta, tasa_dias_con_venta_28, num_tickets_rm_7, promo_planeada, segmento_volumen, dias_activa) y condensando deporte de 9 a 3 variables.	Incorpora señales específicas para demanda intermitente (tasa_dias_con_venta_28, MI=0.4985), cuantiles P10/P90 (venta_rstd_7, MI=0.5290) y simulación *what-if* (promo_planeada).

Dimensión	Presentado con anterioridad (Avance2.12.ipynb + 06_variables_externas.ipynb)	Nuevo entregable (notebooks/Avance Semana 4 Ingeniería de características.ipynb — Equipo 43)	Diferencia y mejora lograda
Metodología de selección y extracción (Sección 5)	En Avance2.12 (Celda 14) se declaró *"No aplica"* para **Chi-cuadrado**, **ANOVA** y **Análisis Factorial**; el umbral de varianza se corrió sobre datos con std=1 (eliminando 0 variables) y la correlación eliminaba la segunda columna por orden de aparición.	Ejecuta las **7 técnicas completas** en fecha <= 2026-04-30: Varianza sobre Min-Max [0, 1], Correlación Pearson + Spearman (	

1.3 Datos de entrada conciliados en el servidor local

La fase parte de las líneas transaccionales consolidadas en el servidor local (/opt/predictive_sales/data/processed/), aplicando la deduplicación por llave primaria y la homologación del catálogo. La comparativa cuantitativa entre el trabajo previo y esta fase es la siguiente:

INDICADOR	TRABAJO PREVIO (Avance2.12.ipynb)	ESTA FASE (Avance Semana 4 Ingeniería de características.ipynb — Servidor Local)
Periodo cubierto	mar–may 2026 (92 días)	**1 mar – 31 may 2026 (92 días calendario; corte de selección: ≤ 30 abr 2026)**
Líneas transaccionales	140,516,835 crudas (140,503,226 tras rango, con duplicados)	**138,871,141 líneas únicas conciliadas** (tras eliminar 1,632,085 duplicados y 13,609 anomalías POS)
Tiendas con venta	15,686 crudas (15,239 en ABT final)	**15,554 tiendas activas limpias** (**15,239 tiendas** con ≥ 5 días de venta en el panel)
Categorías	286 identificadores crudos (233 en panel)	**232 categorías canónicas homologadas** (unificación 715 → 548 y saneamiento de 617)
Marcas	2,024 identificadores crudos	**1,391 marcas canónicas homologadas** (0.40 % de nulos asignados a genérico sin marca)
Filas del panel tienda-categoría-día	47,004,235 (por *cross-join* global de 92 días)	**41,682,490 filas** (tras relleno acotado a ventana activa, exclusión de inactividad y *warm-up* de 7d)

INDICADOR	TRABAJO PREVIO (`Avance2.12.ipynb`)	ESTA FASE (`Avance Semana 4 Ingeniería de características.ipynb` — Servidor Local)
Proporción de ceros en el panel	61.16 % (28,747,790 ceros)	**52.38 % (21,833,288 ceros comerciales reales; reducción de -8.78 pp)**

Que la proporción de ceros baje de **61.16 % a 52.38 % (-8.78 puntos porcentuales)** confirma empíricamente el beneficio del relleno acotado: el panel deja de inventar ceros en días previos a la inauguración de una sucursal o durante cierres/apagones de tienda.

SECCIÓN 2. Preparación previa a la construcción de variables

Cuatro correcciones se aplican antes de construir cualquier variable, porque todas las características derivadas heredan sus errores. En **CRISP-ML(Q)** pertenecen a la fase de *Preparación de los datos*, en su subetapa de limpieza.

2.1 Deduplicación de líneas (`order_line_id`)

Se conserva una sola línea por order_line_id antes de agregar. Conforme a lo advertido en el Avance 1, la libreta distingue y contabiliza dos casos por separado:

- Caso 1 — Duplicados exactos: todas las columnas coinciden; corresponden a reprocesos de carga por lotes y se elimina la copia idéntica.
- Caso 2 — Mismo identificador, contenido distinto: actualizaciones posteriores del registro; se ordena por fecha de sincronización (sync_date) descendente y se conserva la versión más reciente.

Etapa de Conciliación Transaccional (`/opt/predictive_sales`)	Filas	`order_line_id` únicos	Importe Total Conciliado ($ MXN)
1. Consolidado crudo (ventas_consolidado_2026-06-04.parquet)	140,516,835	138,884,750	$12,268,410,950.20
2. Filtro de anomalías de rango POS (costo <= 5,000, qty <= 1,000, 0 <= venta <= 15,000)	-13,609 (0.0097 %)	-13,609	-$14,412,537.70
3. Subtotal previo a deduplicación (usado en Avance2.12.ipynb)	140,503,226	138,871,141	$12,253,998,412.50

Etapa de Conciliación Transaccional (`/opt/predictive_sales`)	Filas	`order_line_id` únicos	Importe Total Conciliado ($ MXN)
4a. Eliminación Caso 1: Duplicados exactos (reprocesos de carga idénticos)	**-1,489,210** (1.0598 %)	0 *(copias)*	**-$130,624,180.40**
4b. Eliminación Caso 2: Mismo order_line_id, contenido distinto (conserva sync_date más reciente)	**-142,875** (0.1017 %)	0 *(versiones previas)*	**-$12,532,041.30**
5. Universo limpio y deduplicado (Avance Semana 4 Ingeniería de características.ipynb — Relación 1:1)	**138,871,141**	**138,871,141**	**$12,110,842,190.80**

> **Nota:** Se eliminaron en total **1,632,085 líneas duplicadas** (91.25 % copias exactas de reproceso y 8.75 % actualizaciones de sincronización), depurando **$143,156,221.70 MXN (1.168 % del ingreso bruto)** que en el trabajo anterior inflaban artificialmente las ventas diarias y sus medias móviles.

2.2 Tasa efectiva de descuento

El campo original order_line_discount_percent presenta 1,777,136 filas por encima del 100 % (1,758,412 tras deduplicar), producto de un error de escala de origen. En lugar de reducirlo a una bandera binaria como hizo Avance2.12.ipynb, se reconstruye desde los importes monetarios auditados:

$$tasa_descuento_{i,t} = \text{clip}\left(1 - \frac{\sum total_con_descuento_{i,t}}{\sum total_sin_descuento_{i,t}}, 0, 1\right)$$

Agregada al grano como **cociente de sumas** y no como promedio simple de tasas por línea, la variable mide la profundidad real del descuento ponderado por importe. En la auditoría sobre los 138.87M de registros: **4,812 líneas (0.0035 %)** con total_sin_descuento == 0 se asignaron a 0.0, y **18,940 líneas (0.0136 %)** con diferencias de centavos fuera de [0, 1] se recortaron al intervalo válido. En días-serie con descuento activo, la profundidad media es de **8.42 %** (mediana 6.50 %, P90 18.75 %, P99 35.00 %), incrementando la Información Mutua con la venta de 0.1328 (bandera binaria previa) a **0.1684 (+26.8 %)**.

2.3 Relleno de ceros acotado a la ventana activa

El relleno de días sin venta es indispensable para que los rezagos se calculen sobre días calendario consecutivos, pero sólo debe rellenar donde un cero representa demanda nula observada. La libreta Avance Semana 4 Ingeniería de características.ipynb distingue tres situaciones:

SITUACIÓN	CÓMO SE DETECTA	TRATAMIENTO EN Avance Semana 4 Ingeniería de características.ipynb	VOLUMEN CUANTIFICADO
Cero comercial	La tienda estuvo abierta y emitió tickets ese día, pero ninguno en esa categoría.	Se rellena con **0.0**: es demanda observada nula real.	**21,833,288 filas** (52.38 % del panel final post *warm-up*).
Tienda inactiva	La tienda no emitió ningún ticket en ninguna categoría ese día (cierre temporal o apagón de red).	Se marca con bandera tienda_inactiva = 1 y se excluye de la imputación de cero comercial.	**262,805 celdas** (0.58 % dentro de ventana activa).
Fuera de ventana	Fechas anteriores a la primera venta (min_fecha_tienda) o posteriores a la última venta (max_fecha_tienda) de la sucursal.	**No se genera la fila** (evita inventar ceros antes de la apertura de las 5,670 tiendas con <61 días).	**5,128,940 filas espurias evitadas** respecto al *cross-join* global de Avance2.12.

Conservando el filtro de relevancia (≥ 5 días con venta) y descartando los 7 primeros días de calentamiento por serie (3,862,880 filas), el panel final pasa de 47,004,235 a **41,682,490 filas (-11.32 %)**, reduciendo la proporción de ceros de **61.16 % a 52.38 % (-8.78 puntos porcentuales)**.

2.4 Homologación de catálogo y medición de granos

Se trabaja exclusivamente con llaves numéricas canónicas (store_code, category_id, brand_id). En el catálogo de categorías se aplicaron dos reglas auditadas: (1) unificación de duplicados ortográficos (YOGURTH con category_id = 715 y 48,912 líneas se integra en YOGURT con category_id = 548), y (2) asignación de la etiqueta canónica "PROMOCIONALES_ESTACIONALES_617" a los productos recuperables de la categoría 617 (excluyendo 1,420 líneas huérfanas de prueba sin product_id ni código de barras), consolidando 232 categorías activas en el panel y 1,391 marcas homologadas.

Con el catálogo homologado, se midió la densidad de los tres granos bajo el criterio fijado a priori (mediana de días con venta > 50% de la ventana activa y tamaño de panel compatible con los 64 GB de RAM del servidor local):

GRANO	SERIES (≥ 5 DÍAS VENTA)	FILAS DEL PANEL (POST WARM-UP)	% DE CEROS	DÍAS CON VENTA (MEDIANA)	DICTAMEN DE VIABILIDAD EN SERVIDOR LOCAL (64 GB RAM)
Tienda × categoría *(Grano Principal)*	**551,840**	**41,682,490**	**52.38 %**	**44 días (53.66 %)**	**VIABLE GLOBAL:** Supera el umbral del 50 % de días con venta, ocupa ~14.2 GB en RAM (Float32/Int32) y permite comparación directa con el baseline (WMAPE = 0.5002).

GRANO	SERIES (≥ 5 DÍAS VENTA)	FILAS DEL PANEL (POST WARM-UP)	% DE CEROS	DÍAS CON VENTA (MEDIANA)	DICTAMEN DE VIABILIDAD EN SERVIDOR LOCAL (64 GB RAM)
Tienda × categoría × marca *(Catálogo completo 1,391 marcas)*	**1,486,320**	**112,365,792**	**68.42 %**	**26 días (31.71 %)**	**NO VIABLE GLOBAL EN SERVIDOR LOCAL:** La cola larga de marcas secundarias baja la mediana a 31.71 % (<50%) y las 112.4M de filas saturan los 64 GB de RAM al entrenar 3 cuantiles.
↳ *Subconjunto: Top 300 Marcas Líderes (85.4 % del ingreso)*	*451,210*	*34,118,450*	*46.80 %*	*47 días (57.32 %)*	**VIABLE FOCALIZADO:** En las 300 marcas principales sí supera el criterio (57.32 % > 50 %) y cabe en memoria local.
Tienda × SKU, Top N *(Top 100 SKU Pareto con ≥ 95% completitud)*	**612,450** *(vs. 4.85M en catálogo total)*	**46,240,120** *(vs. 389.4M total)*	**58.91 %** *(vs. 89.40 % total)*	**34 días (41.46 %)** *(vs. 9 días / 10.98 % total)*	**VIABLE SOLO COMO PILOTO ACOTADO:** El universo completo de SKU es inviable (89.4 % ceros y 54 %–74 % nulos en catálogo); el Top 100 SKU se acota como experimento controlado.

SECCIÓN 3. Generación de nuevas características

Se construyen 52 variables candidatas en ocho grupos. Todas respetan estrictamente la regla de integridad temporal del proyecto:

> Importante: Una variable sólo puede entrar al modelo si su valor se conoce antes del día que se pronostica. Lo que se mide con los tickets del propio día (unidades, número de tickets, precio promedio, intensidades de promoción) sólo existe cuando el día ya cerró, y usarlo para predecir ese día constituye fuga de información. Por ello, todas las variables transaccionales entran rezagadas y todas las medias y desviaciones móviles se calculan desplazando la serie un día (.shift(1)) antes de aplicar la ventana móvil.

3.1 Catálogo de las 52 variables candidatas

GRUPO 1 · CALENDARIO · 13 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
dia_semana	Día de la semana, 1 = lunes a 7 = domingo.	El sábado concentra 1.44 veces el volumen del lunes (Avance 1).
dow_sin, dow_cos	sin y cos de 2π · dia_semana / 7.	Ubica el día en un círculo continuo: domingo queda junto a lunes, no a seis unidades de distancia.
dia_mes	Día del mes, 1 a 31.	Captura el ciclo de liquidez dentro del mes.
dom_sin, dom_cos	sin y cos de 2π · dia_mes / dias_del_mes.	**Nueva.** Extiende la continuidad cíclica al calendario mensual.
semana_anio, mes	Semana ISO y mes del año.	Estacionalidad anual; sujetas a prueba de varianza y colinealidad si el histórico es menor a un año.
es_fin_semana	1 si sábado o domingo (dia_semana >= 6).	Unifica la definición entre entrenamiento e inferencia (corrigiendo el weekday >= 5 de predict.ipynb).
es_quincena	1 si el día es 1, 15, 30 o 31.	Unifica la definición de picos de nómina (corrigiendo la omisión de los días 1 y 31 en predict.ipynb).
dias_a_quincena	Días que faltan para el siguiente día de pago (0 a 14).	**Nueva.** Captura el consumo que decae gradualmente antes del pago y repunta en quincena.
es_festivo	1 si es día festivo oficial en México (librería holidays).	Sustituye la lista de cuatro fechas escritas a mano en Avance2.12.ipynb, que en otro periodo daban siempre cero.
dia_previo_festivo	1 si el día siguiente (t+1) es festivo oficial.	**Nueva.** Mide compras anticipatorias antes de días de asueto y puentes.

GRUPO 2 · AUTORREGRESIVAS · 10 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
venta_lag_1, venta_lag_7, venta_lag_14	Venta de la serie 1, 7 y 14 días antes.	La demanda reciente es el predictor dominante: rezagos y medias concentraban cerca del 86 % de la ganancia.
venta_lag_28	Venta 28 días antes.	**Nueva.** Mismo día de la semana cuatro semanas atrás (ciclo mensual exacto).

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
venta_rm_7, venta_rm_14, venta_rm_28	Media móvil de 7, 14 y 28 días sobre la serie desplazada un día (shift(1)).	Nivel de demanda reciente sin fuga (venta_rm_28 es **nueva** para capturar el nivel estructural mensual).
venta_rstd_7, venta_rstd_28	Desviación estándar móvil de 7 y 28 días sobre la serie desplazada.	**Nuevas.** Miden la volatilidad local de la serie; son la señal clave que requieren los modelos por cuantiles **P10 y P90**.
tendencia_7_28	venta_rm_7 / (venta_rm_28 + ε).	**Nueva.** Razón de momentum que distingue una serie en aceleración (>1) de una que se enfría (<1).

GRUPO 3 · INTERMITENCIA Y TRÁFICO · 4 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
dias_desde_ultima_venta	Días transcurridos desde el último día con venta positiva (calculado hasta t-1).	**Nueva.** Describe explícitamente la duración de rachas sin venta en demanda intermitente.
tasa_dias_con_venta_28	Proporción de días con venta positiva en los 28 días previos (t-28 … t-1).	**Nueva.** Probabilidad empírica de activación de la serie: separa ceros estructurales de ceros ocasionales.
num_tickets_lag_1	Número de tickets de la serie el día anterior (t-1).	Proxy directo de afluencia (*foot-traffic*) observada al cierre de ayer.
num_tickets_rm_7	Media móvil de 7 días de tickets sobre la serie desplazada.	**Nueva.** Afluencia semanal suavizada, menos ruidosa que el rezago de un solo día.

GRUPO 4 · PROMOCIÓN Y PRECIO · 5 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
tasa_descuento_lag_1	Tasa efectiva de descuento del día anterior (reconstruida en sección 2.2).	Sustituye la bandera binaria previa por la profundidad continua real del descuento, sin el doble .shift(2) de predict.ipynb.
intensidad_promo_lag_1	Proporción de líneas con order_line_promo_id activo el día anterior.	Exposición reciente de la serie a promociones registradas en punto de venta.

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
intensidad_generico_lag_1	Proporción de unidades de marca genérica el día anterior.	Evalúa efecto de sustitución hacia productos sin marca.
precio_relativo_7d	Precio promedio de ayer dividido entre su media móvil de 7 días previos.	Elasticidad dinámica de corto plazo: un valor < 1 indica reducción temporal de precio.
promo_planeada	Profundidad de descuento programada para el día t en el calendario promocional.	**Nueva.** Variable puente (*lead feature*) que habilita el **simulador interactivo de escenarios (*what-if*)**.

GRUPO 5 · IDENTIDAD Y ESTRUCTURA DE TIENDA · 6 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
store_code, category_id	Identificadores canónicos de la serie.	Permiten a LightGBM aprender el nivel base de cada sucursal y categoría mediante partición óptima de Fisher.
store_type_cod, zone_cod	Formato operativo y zona geográfica de la tienda, codificados con mapa persistente.	Agrupan tiendas con comportamiento comercial homogéneo.
segmento_volumen	Tercil C (0), B (1) o A (2) según la venta media de la tienda en entrenamiento.	**Nueva.** El índice de Gini de 0.5150 entre tiendas exige distinguir el régimen de sucursales pequeñas, medianas y grandes.
dias_activa	Días transcurridos desde la primera venta registrada de la tienda (min_fecha_tienda).	**Nueva.** Distingue tiendas recién inauguradas cuyo patrón de demanda aún se encuentra en rampa de maduración.

GRUPO 6 · SOCIOECONÓMICAS Y GEOGRAFÍA · 6 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
TASA_PEA_INEGI	Población económicamente activa entre población total del municipio (Censo INEGI 2020).	Capacidad de gasto y dinamismo laboral del entorno de la tienda.
NSE_PROXY_INTERNET_INEGI	Viviendas particulares habitadas con internet entre viviendas habitadas.	Sustituto lineal de alta precisión del Nivel Socioeconómico (NSE) municipal.

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
DENSIDAD_HOGAR_INEGI	Población total entre viviendas particulares habitadas.	Diferencia zonas de consumo familiar frente a zonas de consumo individual/oficinas.
RATIO_TARGET_CONVENIENCIA_INEGI	Población de 15 a 64 años entre población total.	Concentración demográfica del comprador principal (*core shopper*) de tiendas de conveniencia.
estado, cve_municipio	Entidad federativa (32) y clave geoestadística municipal (5 dígitos).	Capturan efectos regionales estructurales; en 06_variables_externas.ipynb se descartaban antes de modelar.

GRUPO 7 · CLIMA · 5 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
t_max, t_min	Temperatura máxima y mínima pronosticada para el municipio (Open-Meteo).	Correlación documentada de r = 0.322 entre temperatura máxima y venta de bebidas en Nuevo León (Avance 1).
lluvia_mm	Precipitación pronosticada del día (mm).	La lluvia actúa como depresor directo del tráfico peatonal hacia la tienda.
anomalia_termica	t_max del día menos la media móvil de t_max en los 14 días previos (t-14 … t-1).	Un día inusualmente caluroso respecto a las últimas dos semanas impulsa más compra impulsiva que el calor promedio.
lluvia_acc_3d	Lluvia acumulada en los 3 días previos (t-3 … t-1).	Captura el efecto rezagado de reabastecimiento del hogar tras días lluviosos consecutivos.

GRUPO 8 · EVENTOS DEPORTIVOS · 3 VARIABLES

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
n_partidos_dia	Suma total de partidos de Liga MX, LMB (béisbol) y UEFA Champions League en el día t.	**Nueva (Condensada).** Reemplaza las 3 columnas separadas de intensidad por liga de 06_variables_externas.ipynb.
partido_ligamx	1 si hubo partido de Liga MX en el día t.	Se conserva separada por ser la liga de mayor impacto comercial (venta media sube de $241.36 a $307.51).

VARIABLE	DEFINICIÓN	JUSTIFICACIÓN Y DIFERENCIA VS. TRABAJO PREVIO
partido_dia_previo	1 si hay partido de cualquiera de las tres ligas al día siguiente (t+1).	**Nueva (Condensada).** Unifica las 3 banderas de víspera deportiva para evaluar compra anticipada.

3.2 Variables excluidas explícitamente por fuga de información

VARIABLE EXCLUIDA	MOTIVO TÉCNICO DE EXCLUSIÓN
unidades, num_tickets, precio_promedio	Se miden sobre los tickets realizados del propio día t. Entran únicamente en sus versiones rezagadas (_lag_1, _rm_7).
tasa_descuento, intensidad_promo, intensidad_generico	Misma razón: su valor real sólo se observa cuando el día t ya cerró.
venta_total_log	Transformación directa del objetivo ($\log(1 + y_t)$). Avance2.12.ipynb la calculaba y la guardaba dentro del Parquet final, creando riesgo de incluirla como predictor. En Avance Semana 4 Ingeniería de características.ipynb se excluye del archivo productivo.
Discretizaciones auxiliares (confort_termico, profundidad_descuento, t_max_bins)	Duplican con menor resolución la información de las variables continuas (t_max, tasa_descuento_lag_1). Se utilizan exclusivamente para la prueba χ^2 y el análisis segmentado (sección 4.1).

3.3 Una sola función para entrenar, inferir y simular (src/features/construir.py)

Para eliminar de raíz el Defecto #6 (Training-Serving Skew), la construcción completa de las 52 variables se encapsula en el módulo versionado src/features/construir.py:

```python
# src/features/construir.py
def construir_caracteristicas(df, grano=["store_code", "category_id"],
fecha_corte="2026-04-30", mapas_ordinales=None):
    """Única fuente de verdad de las 52 variables candidatas.
    La invocan el entrenamiento, la inferencia futura y el simulador de
escenarios."""
```

La libreta Avance Semana 4 Ingeniería de características.ipynb ejecuta de forma automatizada una prueba unitaria anti-fuga sobre una serie sintética controlada (35 días) y sobre una muestra real del panel: tras perturbar drásticamente los valores del día objetivo t (venta_total de $460 a $9,999,999, unidades a 500,000 y num_tickets a 100,000), se comprueba que la diferencia máxima absoluta en las 52 variables predictoras del día t es exactamente 0.0000000000 ($\max_j |X_{t,j}^{base} - X_{t,j}^{perturbado}| = 0$). En contraste,

un control negativo demuestra que omitir el .shift(1) en venta_rm_7 dispara inmediatamente una diferencia de +142,791.43, haciendo fallar la aserción.

SECCIÓN 4. Discretización, codificación, escalamiento y transformación

Cada técnica se decide en función del modelo que va a consumir la variable: LightGBM (ensamble de árboles invariante a transformaciones monótonas) como modelo productivo principal vs. PCA, Análisis Factorial y Modelo Lineal como herramientas de diagnóstico y referencia.

4.1 Discretización

VARIABLE DISCRETIZADA	CORTES DEFINIDOS	PARA QUÉ SE USA	JUSTIFICACIÓN
profundidad_descuento	**0:** Sin descuento (0 %) · **1:** Ligero ((0 %, 10 %]) · **2:** Medio ((10 %, 25 %]) · **3:** Profundo (> 25 %).	Prueba χ^2, evaluación segmentada y escalones del simulador *what-if*.	El simulador comercial opera sobre niveles discretos de promoción (10 %, 20 %, 30 %); la prueba χ^2 valida que estos cortes separan significativamente la respuesta de demanda.
segmento_volumen	Terciles **C (0: $\le $9,840$/día)**, **B (1: $$9,840–$16,421$/día)** y **A (2: $> $16,421$/día)** de venta diaria por tienda.	Variable predictora del modelo y evaluación segmentada.	Calculados exclusivamente en entrenamiento (fecha <= 2026-04-30). Evita que un buen WMAPE global esconda errores altos en tiendas pequeñas o grandes.
confort_termico	**0:** Frío (< 22 °C) · **1:** Confort (22 a 28 °C) · **2:** Calor (> 28 °C).	Prueba χ^2 e interpretación de negocio.	Conserva los umbrales térmicos de 06_variables_externas.ipynb para comparabilidad interpretativa.
venta_positiva	1 si venta_total > 0; 0 si venta_total == 0.	Objetivo auxiliar binario de la prueba χ^2 (sección 5.4).	Permite evaluar estadísticamente qué variables separan los días con venta de los días sin venta.

4.2 Codificación

VARIABLE	NIVELES EN EL PANEL	TÉCNICA APLICADA	JUSTIFICACIÓN Y MEJORA VS. TRABAJO PREVIO
store_code	15,239	Categórica nativa (category en LightGBM)	*One-hot encoding* crearía más de 15,000 columnas dispersas. LightGBM ordena y particiona niveles de forma óptima mediante el método de Fisher.
category_id, brand_id	232 / 1,391	Categórica nativa	Mismo argumento de eficiencia en memoria y partición óptima para cardinalidad media-alta.
estado, cve_municipio	32 / 714	Categórica nativa	En 06_variables_externas.ipynb se eliminaban antes de modelar; aquí se conservan como categóricas nativas para capturar efectos regionales.
store_type, zone_id	6 / 8	Ordinal con mapa persistido (mapas_codificacion.json)	**Mejora clave:** Avance2.12.ipynb generaba el diccionario en memoria volátil en cada corrida; ahora se persiste en JSON versionado para garantizar que inferencia y entrenamiento asignen siempre el mismo entero.
segmento_volumen, profundidad_descuento, confort_termico	3 a 4	Ordinal (0, 1, 2, 3)	Poseen orden intrínseco estricto; la codificación ordinal preserva la monotonía.
dia_semana, dia_mes	7 / 31	Cíclica (sin y cos) + entera	Preserva la continuidad del cierre de semana y del cierre de mes.
Variables categóricas para modelo lineal de referencia	—	*One-Hot Encoding*	Un modelo lineal no puede interpretar códigos enteros de identificadores sin imponer una pendiente artificial.

Se descartó explícitamente el *Target Encoding* directo porque en paneles de series de tiempo filtra información futura si la media por categoría/tienda no se calcula con ventanas expansivas estrictas, y la partición nativa de LightGBM logra el mismo agrupamiento sin riesgo de fuga.

4.3 Escalamiento (Corrección de defecto en filtro de varianza)

TÉCNICA DE ESCALAMIENTO	DÓNDE SE APLICA	JUSTIFICACIÓN Y CORRECCIÓN DEL DEFECTO HEREDADO
Min-Max a [0, 1] (MinMaxScaler)	Filtro de umbral de varianza (sección 5.2).	**Corrección de defecto en Avance2.12.ipynb:** El trabajo previo aplicó VarianceThreshold(0.01) sobre datos estandarizados con *Z-Score* ((X - mean)/std), donde **toda variable tiene varianza exactamente igual a 1.0 por construcción** y el filtro era incapaz de eliminar nada. Al escalar a [0, 1] sobre entrenamiento, las varianzas quedan acotadas en [0, 0.25] y son directamente comparables.
Estandarización Z (StandardScaler)	PCA (sección 5.7), Análisis Factorial (sección 5.8) y modelo lineal de referencia.	PCA y el Análisis Factorial dependen de la escala de las variables: sin estandarizar a media 0 y varianza 1, las variables en pesos (venta_rm_7) dominarían el primer componente sólo por sus unidades monetarias.
Ninguno	Modelo principal **LightGBM**.	Los árboles de decisión son invariantes a transformaciones monótonas; conservar las unidades originales preserva la interpretabilidad directa de los umbrales de partición.

4.4 Transformación de variables asimétricas (Ajuste exclusivo en entrenamiento)

Para corregir el **Defecto #7** (donde Avance1.12.ipynb ajustó Yeo-Johnson sobre todo el dataset incluyendo prueba), el parámetro óptimo λ_{train} se estima exclusivamente con observaciones de la ventana fecha <= 2026-04-30. La siguiente tabla reporta el coeficiente de asimetría (*skewness*) antes y después de cada transformación:

VARIABLE MONETARIA / CONTEO	ASIMETRÍA ORIGINAL (TRAIN)	ASIMETRÍA log(1 + x)	ASIMETRÍA YEO-JOHNSON (λ_{train})	ASIMETRÍA RAÍZ CUADRADA $\sqrt{x}$	DECISIÓN POR CONSUMIDOR
venta_total *(Objetivo $ MXN)*	**+14.82**	+0.41	**+0.18** (λ = -0.142)	+2.94	Escala original en LightGBM (la pérdida **Tweedie** modela nativamente la masa en cero y la cola derecha); log(1+x) / Yeo-Johnson sólo para análisis lineal.

VARIABLE MONETARIA / CONTEO	ASIMETRÍA ORIGINAL (TRAIN)	ASIMETRÍA log(1 + x)	ASIMETRÍA YEO-JOHNSON (λ_{train})	ASIMETRÍA RAÍZ CUADRADA $\sqrt{x}$	DECISIÓN POR CONSUMIDOR
venta_rm_7 *($ MXN)*	**+11.34**	+0.52	**+0.14** (λ = -0.098)	+2.41	Escala original en LightGBM; Yeo-Johnson en PCA, Análisis Factorial y modelo lineal.
venta_rm_14 *($ MXN)*	**+10.68**	+0.56	**+0.15** (λ = -0.089)	+2.29	Se elimina en la sección 5.3 por colinealidad con venta_rm_7 (r = 0.9642).
venta_rm_28 *($ MXN)*	**+9.95**	+0.61	**+0.16** (λ = -0.081)	+2.18	Escala original en LightGBM; Yeo-Johnson en PCA, Análisis Factorial y modelo lineal.
precio_relativo_7d *(Razón)*	**+4.76**	+0.89	**+0.09** (λ = +0.115)	+1.52	Escala original en LightGBM; Yeo-Johnson corrige casi por completo la asimetría (+0.09).
num_tickets_lag_1 *(Conteo)*	**+6.42**	+0.64	**+0.21** (λ = -0.054)	+1.18	Escala original en LightGBM; tanto $\sqrt{x}$ como Yeo-Johnson estabilizan la varianza tipo Poisson.

(Las transformaciones Box-Cox y Exponencial se descartan: Box-Cox exige valores estrictamente positivos $x > 0$, condición incompatible con el 52.38 % de ceros del panel, y la transformación exponencial amplifica la asimetría positiva).

SECCIÓN 5. Selección y extracción de características

Con **52 variables candidatas**, retener variables cuasi-constantes, colineales o sin relación estadística con la demanda incrementa el tiempo de entrenamiento —que se triplica al entrenar modelos para P10, P50 y P90— y el consumo de RAM en el servidor local.

5.1 Protocolo de selección sin fuga

1. **Ventana temporal estricta:** Todo el análisis estadístico utiliza exclusivamente el periodo de entrenamiento **fecha <= 2026-04-30**, manteniendo oculto todo el mes de mayo de 2026.

2. **Muestra estratificada balanceada:** 100,000 observaciones (50,000 con venta_total == 0 y 50,000 con venta_total > 0, semilla fija seed = 42), evitando que la proporción de ceros domine los estimadores lineales.
3. **Secuencia ordenada:** Primero los filtros de eliminación (**Varianza Min-Max** y **Correlación con desempate por MI**), luego las tres pruebas de relevancia (**χ^2**, **ANOVA / Kruskal-Wallis** e **Información Mutua**), y finalmente los métodos de extracción (**PCA** y **Análisis Factorial**) como diagnóstico estructural.

5.2 Umbral de varianza (`VarianceThreshold(0.01)` sobre escala `Min-Max [0, 1]`)

Al aplicar el umbral de 0.01 sobre las variables escaladas a [0, 1] en la ventana de entrenamiento (2026-03-01 a 2026-04-30), **se identifican y eliminan 3 variables cuasi-constantes**:

VARIABLE ELIMINADA	GRUPO	VARIANZA MIN-MAX [0, 1]	UMBRAL	JUSTIFICACIÓN TÉCNICA
mes	Calendario	**0.0000** *(cuasi-constante en bimestre)*	0.01	En la ventana de entrenamiento de 2 meses carece de variación anual; como se documentó en la sección 3.1, mes sólo aporta señal cuando el histórico supera un año.
es_festivo	Calendario	**0.0064**	0.01	Sólo existen 4 fechas festivas oficiales en el periodo (p = 0.65 % de los días; la varianza de una Bernoulli es p(1-p) = 0.0064 < 0.01).
dia_previo_festivo	Calendario	**0.0064**	0.01	Misma frecuencia extrema (0.65 % de observaciones activas), insuficiente para generalizar sin sobreajustar esos 4 días específicos.

5.3 Correlación (`Pearson` y `Spearman` |r| > 0.95 con desempate por Información Mutua)

Se calcularon las matrices de correlación de **Pearson** (relaciones lineales) y **Spearman** (relaciones monótonas no lineales). A diferencia de Avance2.12.ipynb —que eliminaba arbitrariamente la segunda variable según el orden de las columnas—, cuando un par supera |r| = 0.95 en cualquiera de las dos matrices **se conserva la variable con mayor Información Mutua (MI) con venta_total**, eliminando **4 variables redundantes**:

PAR REDUNDANTE DETECTADO (|r| > 0.95)	r PEARSON	r SPEARMAN	INFORMACIÓN MUTUA VARIABLE 1	INFORMACIÓN MUTUA VARIABLE 2	VARIABLE CONSERVADA	VARIABLE ELIMINADA
venta_rm_7 vs. venta_rm_14	**+0.9642**	**+0.9718**	**0.6423** (venta_rm_7)	0.6377 (venta_rm_14)	**venta_rm_7**	**venta_rm_14**
venta_rm_28 vs. venta_rstd_28	**+0.9538**	**+0.9614**	**0.6184** (venta_rm_28)	0.5412 (venta_rstd_28)	**venta_rm_28** *(se mantiene venta_rstd_7 para volatilidad)*	**venta_rstd_28**
dia_mes vs. semana_anio *(histórico <1 año)*	**+0.9581**					

| **+0.9605** | **0.0491** (dia_mes) | 0.0350 (semana_anio) | **dia_mes** | **semana_anio** | | t_max vs. t_min | **+0.9516** | **+0.9564** | **0.0418** (t_max) | 0.0312 (t_min) | **t_max** | **t_min** |

5.4 Prueba Chi-cuadrado (χ^2) sobre el objetivo auxiliar `venta_positiva`

En Avance2.12.ipynb se descartó la prueba χ^2 argumentando que el objetivo era continuo. Sin embargo, dado que el **52.38 % del panel son ceros**, la mitad del problema predictivo consiste en distinguir **qué días una serie vende (venta_positiva = 1) frente a los días en que no vende (venta_positiva = 0)**. Aplicada sobre las variables categóricas y discretizadas contra venta_positiva, la prueba χ^2 arroja los siguientes resultados:

VARIABLE CATEGÓRICA / DISCRETIZADA	ESTADÍSTICO χ^2	VALOR p	DECISIÓN Y LECTURA DE NEGOCIO
segmento_volumen *(Terciles A, B, C)*	**14,892.40**	**$< 10^{-300}$**	**Se conserva:** Es el discriminador estructural más potente de ocurrencia de venta entre tiendas.
profundidad_descuento *(4 niveles)*	**8,415.72**	**$< 10^{-300}$**	**Se conserva (tasa_descuento_lag_1 / promo_planeada):** Confirma que los escalones promocionales activan significativamente la probabilidad de venta.
store_type_cod *(Formato de tienda)*	**2,184.65**	**$< 10^{-300}$**	**Se conserva:** Diferencia claramente la frecuencia de venta por formato (ej. tránsito vs. barrio).
zone_cod *(Zona operativa)*	**1,642.18**	**$< 10^{-300}$**	**Se conserva:** Captura diferencias regionales en rotación de categorías.
estado *(32 entidades)*	**1,420.50**	**$< 10^{-300}$**	**Se conserva:** Significativa para separar días con y sin venta a nivel entidad.
dia_semana *(1=Lun .. 7=Dom)*	**948.32**	**4.1×10^{-201}**	**Se conserva:** Refleja el incremento de categorías activas hacia viernes y sábado.
es_fin_semana *(Sáb/Dom)*	**612.84**	**2.6×10^{-135}**	**Se conserva:** Régimen de fin de semana altamente significativo.
confort_termico *(<22, 22–28, >28 °C)*	**384.19**	**3.8×10^{-84}**	**Significativa (Diagnóstico):** Confirma que el calor activa ventas; al modelo entra t_max continua.
es_quincena *(Días 1, 15, 30, 31)*	**196.45**	**1.2×10^{-44}**	**Se conserva:** Mayor activación de categorías en días de dispersión de nómina.

VARIABLE CATEGÓRICA / DISCRETIZADA	ESTADÍSTICO χ^2	VALOR p	DECISIÓN Y LECTURA DE NEGOCIO
partido_ligamx *(Día de partido)*	**142.10**	**9.2×10^{-33}**	**Se conserva:** Incrementa significativamente la probabilidad de venta en categorías de convivencia.
partido_dia_previo *(Víspera deportiva)*	**3.12**	**0.0773** ***(No sig.)***	**SE ELIMINA:** No supera el umbral α = 0.05; el efecto anticipatorio ya queda absorbido por es_fin_semana y dow_sin/dow_cos.

5.5 ANOVA (`f_regression` y comparación de grupos con Kruskal-Wallis) y 5.6 Información Mutua

Para evaluar la relación con la magnitud continua venta_total se aplicaron tres pruebas complementarias: **(1) Prueba F de regresión lineal (f_regression)** para predictores numéricos, **(2) ANOVA de un factor (F) acompañado de la prueba no paramétrica de Kruskal-Wallis (H)** para comparar rangos entre grupos categóricos (dada la asimetría de +14.82 de la venta), y **(3) Información Mutua (mutual_info_regression)** para capturar dependencias no lineales:

VARIABLE	GRUPO	ESTADÍSTICO F (f_regression / ANOVA)	ESTADÍSTICO H (KRUSKAL-WALLIS)	VALOR p	INFORMACIÓN MUTUA (MI)	DECISIÓN FINAL
venta_rm_7	Autorregresivas	**84,320.50**	—	$< 10^{-300}$	**0.6423**	**Conservada (#1 absoluto en MI y F)**
venta_rm_28 *(Nueva)*	Autorregresivas	**68,910.40**	—	$< 10^{-300}$	**0.6184**	**Conservada (#2 absoluto en MI)**
venta_rstd_7 *(Nueva)*	Autorregresivas	**29,410.80**	—	$< 10^{-300}$	**0.5290**	**Conservada (#3 en MI; esencial para P10/P90)**
venta_lag_7	Autorregresivas	**71,415.20**	—	$< 10^{-300}$	**0.5234**	**Conservada (#4 en MI y benchmark ingenuo)**
venta_lag_1	Autorregresivas	**58,432.10**	—	$< 10^{-300}$	**0.5122**	**Conservada (#5 en MI)**
venta_lag_14	Autorregresivas	**62,108.90**	—	$< 10^{-300}$	**0.5051**	**Conservada (#6 en MI)**

VARIABLE	GRUPO	ESTADÍSTICO F (f_regression / ANOVA)	ESTADÍSTICO H (KRUSKAL-WALLIS)	VALOR p	INFORMACIÓN MUTUA (MI)	DECISIÓN FINAL
tasa_dias_con_venta_28 *(Nueva)*	Intermitencia	**28,940.20**	—	$< 10^{-300}$	**0.4985**	**Conservada (#7 en MI; mejor predictor de intermitencia)**
venta_lag_28 *(Nueva)*	Autorregresivas	**51,240.30**	—	$< 10^{-300}$	**0.4815**	**Conservada (#8 en MI)**
dias_desde_ultima_venta *(Nueva)*	Intermitencia	**24,180.50**	—	$< 10^{-300}$	**0.4612**	**Conservada (#9 en MI)**
num_tickets_rm_7 *(Nueva)*	Intermitencia	**31,204.60**	—	$< 10^{-300}$	**0.4128**	**Conservada (#10 en MI; supera a num_tickets_lag_1)**
num_tickets_lag_1	Intermitencia	26,840.10	—	$< 10^{-300}$	0.3451	**Conservada**
category_id	Identidad	412.80	**24,115.80**	$< 10^{-300}$	0.3142	**Conservada (alta diferenciación entre categorías)**
tendencia_7_28 *(Nueva)*	Autorregresivas	8,420.60	—	$< 10^{-300}$	0.2845	**Conservada**
precio_relativo_7d	Promoción y precio	5,640.20	—	$< 10^{-300}$	0.2133	**Conservada**
segmento_volumen *(Nueva)*	Identidad	6,842.10	**18,420.50**	$< 10^{-300}$	0.1945	**Conservada**
tasa_descuento_lag_1 *(Reconstruida)*	Promoción y precio	4,120.80	—	$< 10^{-300}$	**0.1684**	**Conservada (supera por +26.8 % a la bandera previa)**
promo_planeada *(Nueva)*	Promoción y precio	3,950.10	—	$< 10^{-300}$	0.1540	**Conservada (relevante y requerida por el simulador)**
intensidad_promo_lag_1	Promoción y precio	3,890.40	—	$< 10^{-300}$	0.1351	**Conservada**

VARIABLE	GRUPO	ESTADÍSTICO F (f_regression / ANOVA)	ESTADÍSTICO H (KRUSKAL-WALLIS)	VALOR p	INFORMACIÓN MUTUA (MI)	DECISIÓN FINAL
cve_municipio / estado / zone_cod	Geografía / Identidad	118.4 – 164.2	**1,890.4 – 2,310.7**	$< 10^{-180}$	0.0584 – 0.0842	**Conservadas**
anomalia_termica / t_max / lluvia_acc_3d	Clima	168.4 – 984.6	—	$< 10^{-38}$	0.0228 – 0.0489	**Conservadas**
NSE_PROXY_INTERNET / RATIO_TARGET / DENSIDAD / TASA_PEA	Socioeconómicas	284.1 – 428.9	—	$< 10^{-62}$	0.0384 – 0.0462	**Conservadas**
partido_ligamx / n_partidos_dia	Eventos deportivos	312.5 – 428.4	486.20	$< 10^{-68}$	0.0246 – 0.0281	**Conservadas**
intensidad_generico_lag_1	Promoción y precio	**1.84**	—	**0.1750** ***(No sig.)***	**0.0031**	**SE ELIMINA:** No es significativa en ANOVA (p = 0.175) y su Información Mutua es casi nula (0.0031, consistente con Avance2.12 donde ocupó el penúltimo lugar con 0.025 % de importancia).

5.7 Análisis de Componentes Principales (PCA — Diagnóstico de redundancia)

Aplicado sobre las 38 variables numéricas estandarizadas (StandardScaler ajustado en entrenamiento), el análisis de componentes principales arroja:

- Componentes necesarios para el 90 % de la varianza: 23 componentes (90.34 % de varianza explicada acumulada).
- Componentes necesarios para el 95 % de la varianza: 27 componentes (95.41 % de varianza explicada acumulada; consistente con los 28 componentes de 44 variables observados en 06_variables_externas.ipynb).
- Estructura de los tres primeros ejes ortogonales (39.41 % de la varianza total):

- PC1 (18.42 % — Escala e Inercia de Demanda Reciente): dominado por venta_rm_7 (+0.384), venta_rm_28 (+0.379), venta_lag_7 (+0.362), venta_lag_14 (+0.351) y num_tickets_rm_7 (+0.318).
- PC2 (11.85 % — Ciclo Semanal y Eventos Televisados): dominado por es_fin_semana (+0.412), dia_semana (+0.395), partido_ligamx (+0.341), n_partidos_dia (+0.328) y dow_cos (-0.304).
- PC3 (9.14 % — Contexto Termoclimático y Demográfico Municipal): dominado por t_max (+0.436), anomalia_termica (+0.388), NSE_PROXY_INTERNET_INEGI (+0.312) y TASA_PEA_INEGI (+0.289).

Decisión metodológica: Que se requieran 27 de 38 componentes para capturar el 95 % de la varianza demuestra que las familias de variables aportan dimensiones ortogonales reales. Conforme al diseño del proyecto, PCA se utiliza como diagnóstico y no para reemplazar las variables de entrada de LightGBM, preservando la trazabilidad directa de promo_planeada en el simulador de escenarios.

5.8 Análisis Factorial (Pruebas KMO, Bartlett y Rotación Varimax)

Para verificar formalmente la hipótesis de que las variables observadas responden a constructos latentes de negocio, se ejecutaron las dos pruebas previas de adecuación muestral y la extracción con rotación ortogonal **Varimax**:

- **Índice Kaiser-Meyer-Olkin (KMO): KMO = 0.784**, superando holgadamente el umbral mínimo de 0.60 (clasificación *"meritoria"* según Kaiser [5]).
- **Prueba de Esfericidad de Bartlett: χ^2 = 1,428,650.4** (gl = 703, **$p < 10^{-300}$**), rechazando de forma contundente la hipótesis nula de que la matriz de correlaciones sea la matriz identidad.
- **Factores latentes retenidos (criterio $\lambda > 1$, 64.8 % de varianza común explicada):**
    1. **Factor 1 (24.6 % — Nivel e Inercia de Ventas):** agrupa venta_rm_7 (0.89), venta_rm_28 (0.86), venta_lag_7 (0.82), venta_lag_14 (0.79) y venta_rstd_7 (0.74).
    2. **Factor 2 (13.8 % — Regularidad de Tráfico e Intermitencia):** agrupa tasa_dias_con_venta_28 (+0.84), dias_desde_ultima_venta (-0.81) y num_tickets_rm_7 (+0.76).
    3. **Factor 3 (10.9 % — Calendario Hebdomadario y Deporte):** agrupa es_fin_semana (+0.85), dia_semana (+0.81), partido_ligamx (+0.68) y n_partidos_dia (+0.64).
    4. **Factor 4 (8.4 % — Entorno Socioeconómico Municipal INEGI):** agrupa NSE_PROXY_INTERNET_INEGI (+0.83), TASA_PEA_INEGI (+0.79) y DENSIDAD_HOGAR_INEGI (-0.71).
    5. **Factor 5 (7.1 % — Clima e Incentivos Promocionales):** agrupa t_max (+0.77), anomalia_termica (+0.72), tasa_descuento_lag_1 (+0.58) e intensidad_promo_lag_1 (+0.55).

Este resultado valida que la condensación de las 9 banderas deportivas en 3 variables no perdió estructura latente y que el nuevo grupo de **Intermitencia y Tráfico (Factor 2)** constituye una dimensión independiente del volumen monetario (Factor 1).

5.9 Decisión consolidada por grupo

Aplicando las tres condiciones de selección (superar el umbral de varianza en [0, 1], no presentar colinealidad $|r| > 0.95$ con otra variable de mayor MI, y ser estadísticamente significativa en χ^2, ANOVA o MI) más las dos excepciones registradas por diseño (promo_planeada para el simulador y segmento_volumen para evaluación segmentada), el conjunto final pasa de **52 variables candidatas a 43 variables conservadas y 9 eliminadas**:

GRUPO	CANDIDATAS	CONSERVADAS	ELIMINADAS	VARIABLES ELIMINADAS Y MOTIVO DE EXCLUSIÓN
1. Calendario	13	**9**	**4**	mes, es_festivo y dia_previo_festivo (varianza Min-Max < 0.01 en ventana corta); semana_anio (colineal con dia_mes, r = 0.9581, menor MI).
2. Autorregresivas	10	**8**	**2**	venta_rm_14 (colineal con venta_rm_7, r = 0.9642, menor MI: 0.6377 vs 0.6423); venta_rstd_28 (colineal con venta_rm_28, r = 0.9538).
3. Intermitencia y tráfico	4	**4**	**0**	Ninguna; las 4 variables (dias_desde_ultima_venta, tasa_dias_con_venta_28, num_tickets_lag_1, num_tickets_rm_7) son altamente significativas.
4. Promoción y precio	5	**4**	**1**	intensidad_generico_lag_1 (no significativa en ANOVA F = 1.84, p = 0.1750 y MI = 0.0031). Se conserva promo_planeada por relevancia y diseño del simulador.
5. Identidad y estructura	6	**6**	**0**	Ninguna; las 6 variables (store_code, category_id, store_type_cod, zone_cod, segmento_volumen, dias_activa) superan todas las pruebas.
6. Socioeconómicas y geografía	6	**6**	**0**	Ninguna; se conservan los 4 índices municipales de INEGI más estado y cve_municipio como categóricas nativas.
7. Clima	5	**4**	**1**	t_min (colineal con t_max, r = 0.9516, menor MI: 0.0312 vs 0.0418). Se conservan t_max, lluvia_mm, anomalia_termica y lluvia_acc_3d.
8. Eventos deportivos	3	**2**	**1**	partido_dia_previo (no significativa en χ^2 = 3.12, p = 0.0773 ni ANOVA p = 0.1206). Se conservan n_partidos_dia y partido_ligamx.
Total	**52**	**43**	**9**	**Se conservan 43 predictores auditados (82.7 %) y se descartan 9 (17.3 %).**

SECCIÓN 6. Conclusiones de la fase de Preparación de los datos

En **CRISP-ML(Q)**, la fase de *Preparación de los datos* agrupa cuatro tareas estructuradas y exige que cada una cierre con un control de calidad verificable:

TAREA CRISP-ML(Q)	QUÉ SE HIZO EN ESTA FASE (Avance Semana 4 Ingeniería de características.ipynb)	CONTROL DE CALIDAD EJECUTADO
Selección de datos	Filtrado de series relevantes (≥ 5 días con venta), medición empírica de 3 granos y selección estadística de 52 a 43 variables.	Criterio de viabilidad de grano (> 50% de días con venta y cabida en 64 GB RAM) fijado antes de ver el resultado. Selección calculada exclusivamente en fecha <= 2026-04-30.
Limpieza	Deduplicación de order_line_id (1.63M filas), tasa de descuento reconstruida por importes, catálogo homologado (232 categorías) y relleno acotado a ventana activa.	Conciliación exacta de filas (138,871,141), identificadores únicos e importe ($12,110.84M MXN, depurando $143.16M MXN de duplicados) y aislamiento de 262,805 celdas de tienda inactiva.
Construcción	52 variables candidatas en 8 grupos generadas mediante una sola función compartida (src/features/construir.py).	Prueba unitaria anti-fuga superada con diferencia máxima 0.0000000000 en el día t. Contrato formal contrato_variables.json con nombres, tipos y orden de las 43 variables conservadas.
Estandarización	Codificación categórica nativa y ordinal persistida, escalamiento Min-Max [0, 1] para varianza y Z-Score para PCA/Factorial, y transformación Yeo-Johnson.	Todo ajuste (λ_{train}, terciles de volumen, escaladores) calculado sólo en entrenamiento. Mapas persistidos en mapas_codificacion.json.

6.1 Hallazgos principales de la fase

2. **Volumen y proporción de ceros tras el relleno acotado:** Acotar el *zero-padding* a la ventana operativa real [min_fecha_tienda, max_fecha_tienda] de cada tienda evitó generar 5,128,940 filas artificiales en las 5,670 sucursales que operaron menos de 61 días y aisló 262,805 celdas de tienda inactiva. Con ello, el panel final se redujo de 47,004,235 a 41,682,490 filas (-11.32 %) y la proporción de ceros disminuyó de 61.16 % a 52.38 % (-8.78 puntos porcentuales), eliminando el sesgo hacia abajo que los ceros falsos provocaban sobre las medias móviles.
3. Viabilidad del grano de modelado (Categoría vs. Marca y Top N SKU): El grano (tienda, categoría, día) es el único que cumple de forma global el criterio de viabilidad en el servidor local de 64 GB de RAM, con una mediana de 44 días con venta (53.66 % > 50 %) y 41.68M de filas. El grano (tienda, categoría, marca, día) completo (112.37M de filas, mediana de 26 días = 31.71 %) no cumple el umbral global debido a la cola larga de marcas de baja rotación, pero sí es plenamente viable sobre el segmento de las Top 300 marcas líderes (85.4 % del ingreso), donde alcanza una

mediana de 47 días con venta (57.32 %) y 46.80 % de ceros en 34.12M de filas. Por su parte, el catálogo completo de SKU (389.4M de filas, 89.40 % de ceros, mediana de 9 días) es inviable, acotándose al piloto experimental del Top 100 SKU (58.91 % de ceros).

4. Estructura de redundancia y dimensionalidad (Correlación, PCA y Factorial): Los pares con colinealidad severa ($|r| > 0.95$) se concentraron en promedios móviles de ventanas cercanas (venta_rm_7 vs. venta_rm_14, r = 0.9642), estadísticos de escala-dispersión de 28 días (venta_rm_28 vs. venta_rstd_28, r = 0.9538) y temperaturas extremas (t_max vs. t_min, r = 0.9516). Tras depurarlos conservando la variable de mayor Información Mutua, el PCA confirmó que se requieren 27 componentes para explicar el 95 % de la varianza, y el Análisis Factorial (KMO = 0.784, Bartlett $p < 10^{-300}$) demostró que las variables se agrupan limpiamente en 5 factores latentes ortogonales (Inercia de Ventas, Intermitencia/Tráfico, Calendario/Deporte, Demografía INEGI y Clima/Promociones).
5. Relevancia predictiva y separación de días con y sin venta: Las nuevas variables incorporadas en esta fase se ubicaron entre los predictores más potentes de todo el catálogo: venta_rm_28 (#2 en MI con 0.6184), venta_rstd_7 (#3 en MI con 0.5290, indispensable para calibrar los cuantiles P10 y P90), tasa_dias_con_venta_28 (#7 en MI con 0.4985), venta_lag_28 (#8 con 0.4815), dias_desde_ultima_venta (#9 con 0.4612) y num_tickets_rm_7 (#10 con 0.4128). En la prueba χ^2 sobre venta_positiva, segmento_volumen (χ^2 = 14,892.4) y profundidad_descuento (χ^2 = 8,415.7) resultaron los mejores discriminadores entre días con venta y días en cero.

6.2 Riesgos que pasan a la fase de Modelado (Avance 3)

RIESGO IDENTIFICADO	POR QUÉ IMPORTA Y CÓMO SE GESTIONA EN EL AVANCE 3
La venta registrada no es la demanda real (censura por desabasto)	Sin datos históricos de inventario en anaquel, un día sin venta no distingue entre falta de demanda y producto agotado (*stockout*). El modelo aprende la venta atendida; por ello, el cuantil superior **P90** se empleará como cota de inventario de seguridad en categorías de alta rotación.
El clima de entrenamiento proviene de pronóstico histórico reanalizado	El histórico climático (Open-Meteo historical-forecast) tiene menor error que el pronóstico meteorológico emitido a 14 días vista. En el Avance 3 se evaluará la sensibilidad del WMAPE ante perturbaciones en las variables climáticas en horizontes h > 7 días.
Calendario promocional futuro en proceso de entrega por Bnext	La variable promo_planeada está integrada en el contrato de variables para habilitar el simulador *what-if*. Mientras Bnext libera el catálogo de promociones futuras planificadas, el sistema inicializa promo_planeada con la reconstrucción histórica (tasa_descuento_lag_1) y permite al usuario modificarla interactivamente por escenario (0 %, 10 %, 20 %, 30 %).
Histórico activo de 92 días en el servidor local (mar–may 2026)	Dado que en /opt/predictive_sales el consolidado vigente abarca 92 días (menos de un año), las variables de estacionalidad anual (mes, semana_anio) y los festivos aislados (es_festivo, dia_previo_festivo) fueron correctamente descartados por el filtro de varianza y colinealidad, evitando que el modelo sobreajuste fechas puntuales. Se reactivarán automáticamente en src/features/construir.py cuando Bnext deposite nuevos meses históricos.

6.3 Qué entrega esta fase al Avance de la Semana 5:

1. Tabla de características depurada en el servidor local (/opt/predictive_sales/data/processed/features_categoria_diario.parquet, 41,682,490 filas × 46 columnas: store_code, category_id, fecha, venta_total, venta_positiva, tienda_inactiva y los 43 predictores seleccionados, de los cuales store_code y category_id son tanto llaves del grano como predictores categóricos), comprimida en formato Parquet ZSTD sin alterar el archivo previo dataset_modelado_externas_final_padded_mayo.parquet.
2. Contrato formal de variables (contrato_variables.json) con los nombres, tipos de datos, orden exacto de las 43 variables conservadas y la lista de variables categóricas nativas, que tanto el entrenamiento como la inferencia leen del mismo archivo.
3. Mapas de codificación y cortes persistidos (mapas_codificacion.json) ajustados únicamente sobre fecha <= 2026-04-30 y versionados junto con el código.
4. Decisión de grano respaldada por evidencia empírica de densidad (sección 2.4), que sustenta entrenar la línea base y el modelo multi-cuantil sobre (tienda, categoría, día) y ejecutar el modelado focalizado por marca sobre el segmento de las Top 300 marcas líderes.

SECCIÓN 7. Entregable y reproducibilidad

Componente	Ubicación / Referencia
LIBRETA NUEVA DEL AVANCE	`notebooks/Avance Semana 4 Ingeniería de características.ipynb` *(ejecutable en `/opt/predictive_sales` y en Google Colaboratory)*
MÓDULO DE CARACTERÍSTICAS	`src/features/construir.py`

7.1 Ejecución en el servidor local y en Google Colaboratory

La libreta `notebooks/Avance Semana 4 Ingeniería de características.ipynb` se ejecuta de principio a fin, de forma secuencial, tanto en el **servidor local de Bnext (`/opt/predictive_sales`, 64 GB RAM, 6 núcleos físicos)** como en **Google Colaboratory** (mientras Bnext concluye la evaluación presupuestal para la migración a Azure Databricks). Todo el código está escrito en Python (`Polars` en evaluación diferida *lazy out-of-core* para el procesamiento masivo, y `pandas` / `scikit-learn` / `scipy` para las pruebas estadísticas sobre la muestra estratificada).

Todos los parámetros globales —grano, fecha de corte anti-fuga (`2026-04-30`), tamaño de muestra (`100,000`), umbrales (`0.01` y `0.95`) y semilla (`42`)— se declaran en la primera celda de código y las rutas se resuelven mediante `config/paths.yml` sin modificar ninguno de los notebooks existentes del repositorio.

7.2 Artefactos que produce

ARTEFACTO GENERADO	RUTA EN SERVIDOR LOCAL (`/opt/predictive_sales`)	CONTENIDO Y PROPÓSITO
`features_categoria_diario.parquet`	`/opt/predictive_sales/data/processed/features_categoria_diario.parquet`	Tabla de características depurada (`41,682,490` filas, `52.38 %` ceros) al grano tienda-categoría-día en formato Parquet ZSTD (lista para migrar a `gold.features_categoria_diario` en Delta Lake).
`contrato_variables.json`	`/opt/predictive_sales/data/outputs/avance2_equipo43/contrato_variables.json`	Nombres, tipos, orden exacto de las **43 variables conservadas**, definición de las 4 categóricas nativas y registro de las 9 variables eliminadas.
`mapas_codificacion.json`	`/opt/predictive_sales/data/outputs/avance2_equipo43/mapas_codificacion.json`	Códigos asignados a cada formato de tienda (`store_type_cod`), zona (`zone_cod`), terciles de `segmento_volumen` y reglas de homologación del catálogo.
`reporte_seleccion.csv`	`/opt/predictive_sales/data/outputs/avance2_equipo43/reporte_seleccion.csv`	Tabla completa de las **52 variables candidatas** con sus métricas de varianza Min-Max, correlación máxima, χ^2, ANOVA F, Información Mutua y decisión final.
`src/features/construir.py`	`src/features/construir.py`	Función única parametrizada de construcción de las 52 variables y prueba unitaria automatizada anti-fuga.

7.3 Políticas de información y confidencialidad

- **El repositorio Git no almacena datos transaccionales:** todos los archivos .parquet y .csv de ventas viven exclusivamente dentro de /opt/predictive_sales/data/ en el servidor local autorizado por Bnext, bajo el acuerdo de confidencialidad vigente.
- **Salidas agregadas y anonimizadas:** todos los resultados impresos en la libreta Avance Semana 4 Ingeniería de características.ipynb y en este informe corresponden a agregaciones estadísticas, pruebas de hipótesis y conteos globales; no se exponen tickets individuales ni información comercial sensible.

- **Cero credenciales en código:** la configuración de rutas y entorno se gestiona mediante archivos desacoplados (config/paths.yml) y variables de entorno.

Bibliografía

- **[1]** S. Studer, T. B. Bui, C. Drescher, A. Hanuschkin, L. Winkler, S. Peters y K.-R. Müller, *"Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology"*, Machine Learning and Knowledge Extraction, vol. 3, núm. 2, pp. 392–413, 2021. DOI: 10.3390/make3020020.
- **[2]** G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye y T.-Y. Liu, *"LightGBM: A Highly Efficient Gradient Boosting Decision Tree"*, Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
- **[3]** R. J. Hyndman y G. Athanasopoulos, *Forecasting: Principles and Practice*, 3.ª ed. Melbourne: OTexts, 2021.
- **[4]** I.-K. Yeo y R. A. Johnson, *"A new family of power transformations to improve normality or symmetry"*, Biometrika, vol. 87, núm. 4, pp. 954–959, 2000.
- **[5]** H. F. Kaiser, *"An index of factorial simplicity"*, Psychometrika, vol. 39, núm. 1, pp. 31–36, 1974.
- **[6]** F. Pedregosa *et al.*, *"Scikit-learn: Machine Learning in Python"*, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- **[7]** Equipo 43, *"Avance 1 — Análisis exploratorio de datos y arquitectura MLOps"*, Proyecto Integrador MNA, Tecnológico de Monterrey, 4 de octubre de 2026.