

Tecnológico de Monterrey
Escuela de Ingeniería y Ciencias

Proyecto Integrador

Evolución del Modelado Predictivo de Ventas a Nivel SKU y Sector Promociones para 17,000 Tiendas mediante MLOps y Simulación de Escenarios en Azure Databricks

Entrega Colaborativa:

Daniel Juárez Ortiz - A01797369

Kevin Alexis Valdez Pérez- A01750478

Yael Ariel Márquez Mas - A01745310

19 de Octubre, del 2026

Quinto Entregable

PROYECTO INTEGRADOR · SEMANA 5

Pronóstico probabilístico de demanda por marca y simulación de escenarios promocionales

Avance 3. Modelos de referencia (*Baseline*), validación *Walk-Forward* multi-ventana, diagnóstico de *Overfitting* y registro en MLflow

Implementación y evaluación empírica de la escalera de modelos base (Naive estacional lag_7, Media Móvil causal de 7 días, LightGBM RMSE sobre log(1 + y) heredado y LightGBM con pérdida Tweedie ρ = 1.5 sobre la Capa Oro a nivel Categoría y Marca) en 4 cortes consecutivos de 14 días en /opt/predictive_sales

Campo	Valor
Institución académica	Tecnológico de Monterrey — Maestría en Inteligencia Artificial Aplicada
Curso	Proyecto Integrador
Entregable de referencia del curso (TEC)	**Semana 5 — Avance 3. Baseline** *(Justificación algorítmica, importancia de variables, diagnóstico de sub/sobre-entrenamiento, métricas de negocio y umbral mínimo a superar)* *Google Colab notebook*
Entregable comprometido con el cliente (Bnext)	**Semana 5 — Modelado base y validación *walk-forward*** *(Backtesting automatizado en múltiples cortes temporales de 14 días y entrenamiento de modelos base Naive estacional, Media Móvil y LightGBM Tweedie registrados en MLflow)*
Asesora del proyecto (TEC)	Dra. Eduviges Ludivina Facundo
Patrocinador (Sponsor)	Dr. Juan Arturo Nolazco Flores — Director del Hub de Ciencia de Datos (jnolazco@tec.mx)
Fecha de entrega	Octubre de 2026

Resumen ejecutivo de indicadores de la Fase (Semana 5)

Indicador de la Fase (Semana 5)	Resultado en /opt/predictive_sales	Cumplimiento TEC (*Avance 3*) + Bnext (*Semana 5*)
WMAPE EN CORTE *HOLDOUT* (18–31 MAYO)	**0.4991 (Categoría) / 0.4543 (Marca)**	Supera el benchmark heredado (0.5002) y abate en **-8.24 pts** (Categoría) y **-13.71 pts** (Marca) el error del Naive estacional ($p < 0.0001$).
CORRECCIÓN DE SESGO DE DESABASTO (*BIAS %*)	**-5.32 % (Cat.) / -0.31 % (Marca)**	Elimina la severa sub-predicción (-29.86 % media y -35.89 % en Holdout) causada por la desigualdad de Jensen al retransformar $\exp(\hat{z}) - 1$ en el modelo anterior.
REDUCCIÓN DE RMSE PROMEDIO (4 CORTES)	**903.55** *(vs. 984.61 modelo previo, **-8.23 %**)*	En el corte *Holdout*, el RMSE baja de 1,223.66 a **1,076.11 (-12.06 %)**, protegiendo contra quiebres de inventario en días pico.
BRECHA TRAIN VS. VALIDACIÓN (*OVERFITTING*)	**0.0234** *(2.34 pts en best_iteration = 111)*	WMAPE_Train = 0.4757 vs. WMAPE_Val = 0.4991, confirmando ausencia de sobre-entrenamiento y alta estabilidad inter-corte (Std = 0.0193).

SECCIÓN 1. Alineación dual (TEC + Bnext) y selección justificada de la arquitectura *Baseline*

1.1 Cobertura simultánea de la rúbrica del TEC (*Avance 3. Baseline*) y del plan con Bnext (Semana 5)

En cumplimiento de la metodología **CRISP-ML(Q)** [1] y del cronograma establecido en Semana1_Planteamiento_del_Proyecto_EquipoBnext.docx (Secciones 5 y 6.2), la entrega de la **Semana 5** articula en un solo flujo reproducible tanto las cinco preguntas de evaluación académica del **Tecnológico de Monterrey (*Avance 3. Baseline*)** como los entregables técnicos comprometidos con **Bnext**:

1. **Selección y justificación del algoritmo *baseline* (Criterio TEC 1 + Compromiso Bnext Sem 5):** En lugar de evaluar un único modelo aislado, se diseña una **escalera de 4 modelos de referencia (*benchmarking ladder*)** que contrasta reglas heurísticas de negocio (**Naive estacional lag_7** y **Media Móvil causal de 7 días**), la formulación exacta del equipo anterior (**LightGBM con pérdida RMSE sobre log(1 + y)**) y nuestra nueva formulación base (**LightGBM con pérdida Tweedie ρ = 1.5 en escala natural** sobre la Capa Oro a nivel Categoría y Marca).
2. **Protocolo automatizado de *backtesting walk-forward* multi-ventana con registro en MLflow (Compromiso Bnext Sem 5):** Se evalúan los modelos sobre los **4 cortes consecutivos de 14 días** materializados en la Semana 4 (Fold_1_Val: 06–19 abr, Fold_2_Val: 20 abr–03 may, Fold_3_Val:

04–17 may y Fold_4_Holdout: 18–31 may), registrando hiperparámetros, métricas y artefactos en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/mlruns/.

3. **Importancia de características en el modelo *baseline* (Criterio TEC 2):** Se cuantifica el aporte real de las variables limpias de la Capa Oro mediante **Ganancia Total (*Gain %*)** y **Frecuencia de Partición (*Split Count*)**, verificando la contribución de las variables autorregresivas, de calendario, de descuento efectivo reconstruido (tasa_descuento), climáticas y demográficas de INEGI rescatadas con SEPOMEX.
4. **Diagnóstico cuantitativo de *underfitting* y *overfitting* (Criterio TEC 3):** Se audita la evolución de las métricas de entrenamiento y validación a los 50, 100 y 111 árboles (best_iteration), demostrando empíricamente el control de la brecha de generalización (2.34 %).
5. **Métricas alineadas al negocio y umbral mínimo a superar (Criterio TEC 4 y 5):** Se fundamenta el uso conjunto de **WMAPE**, **MAE**, **RMSE**, **Sesgo Porcentual (*Bias %*)** y la prueba estadística de **Diebold–Mariano (DM)** [2], estableciendo la compuerta formal de promoción para los modelos probabilísticos por cuantiles (P10, P50, P90) de la Semana 6.

1.2 ¿Qué algoritmo se debe utilizar como *baseline* y por qué? El problema del sesgo de Jensen en el modelo heredado

El pronóstico diario de demanda en tiendas de conveniencia presenta tres propiedades estadísticas verificadas en nuestro panel de /opt/predictive_sales (2,535,125 filas muestreadas con series completas de 92 días en dataset_modelado_externas_final_padded_mayo.parquet):

- **Masa puntual en cero (*zero-inflation*):** Incluso después de aplicar el *Targeted Zero-Padding* de la Semana 4, entre el **52.38 % y el 61.71 %** de las celdas tienda-categoría-día registran venta exactamente igual a 0.00 MXN.
- **Asimetría positiva extrema en días con venta:** Cuando ocurre demanda ($Y > 0$), la distribución sigue una cola derecha pesada impulsada por fines de semana, quincenas, calor y promociones cerveceras.
- **No linealidad e interacciones de orden superior:** El efecto de una promoción o de una anomalía térmica depende simultáneamente del arquetipo de la tienda (store_type_cod), la zona geográfica (zone_id_cod) y la categoría (category_id).

Demostración matemática de la falla del modelo previo (LightGBM RMSE sobre log1p)

El equipo anterior entrenó un árbol impulsado por gradiente (**LightGBM** [3]) minimizando el error cuadrático medio (RMSE) sobre la variable transformada $Z = \log(1 + Y)$, y en inferencia invirtió la predicción mediante $\hat{Y} = \exp(\hat{Z}) - 1$. Aunque este enfoque logró bajar el WMAPE respecto al Naive estacional, introduce una **patología matemática severa por la Desigualdad de Jensen**:

Como la función exponencial $g(z) = \exp(z) - 1$ es estrictamente convexa, para cualquier variable aleatoria Z con varianza condicional $\sigma^2 > 0$ se cumple estrictamente que:

exp(E[log(1 + Y) | X]) - 1 < E[Y | X]

En el caso log-normal aproximado, la media condicional verdadera es $E[Y \mid X] \approx \exp(\mu_z + 0.5 \cdot \sigma^2_z) - 1$. Al omitir el factor correctivo $\exp(0.5 \cdot \sigma^2_z)$, **el modelo del equipo anterior sub-predice sistemáticamente el volumen total de ventas entre -25.34 % y -35.89 % en todos los cortes temporales** (Tabla 1). En operación comercial para las tiendas, un sesgo de **-35.89 %** en la segunda quincena de mayo implica programar un tercio menos de inventario cervecero del que realmente demanda el consumidor, provocando quiebres de inventario (*stockouts*).

Por qué LightGBM con verosimilitud Tweedie (ρ = 1.5) es el *baseline* estadísticamente óptimo

Para resolver de raíz el sesgo de retransformación sin perder la capacidad de modelar ceros exactos y colas derechas pesadas, proponemos como **nuevo modelo *baseline* de aprendizaje automático** un **LightGBM entrenado directamente en la escala natural de pesos (MXN) bajo una función de pérdida Tweedie (objective = "tweedie", ρ = 1.5)** [4]:

1. **Modelado nativo de series cero-infladas (*Compound Poisson-Gamma*):** Cuando el parámetro de potencia de varianza se ubica en $1 < \rho < 2$ ($Var(Y) = \varphi \cdot \mu^\rho$), la distribución Tweedie equivale a una suma aleatoria de $N \sim Poisson(\lambda)$ tickets diarios donde cada ticket aporta un gasto $G_k \sim Gamma(\alpha, \gamma)$. Esto asigna una probabilidad positiva exacta al evento $Y = 0$ (cuando $N = 0$ tickets) y una densidad continua asimétrica para $Y > 0$, reflejando fielmente el proceso físico de compra en las tiendas.
2. **Insesgadez en la media condicional:** La desviación (*deviance*) Tweedie:

   $L_Tweedie(y, \hat{\mu}) = 2 \cdot [\, y^{(2-\rho)} / ((1-\rho)(2-\rho)) - (y \cdot \hat{\mu}^{(1-\rho)}) / (1-\rho) + \hat{\mu}^{(2-\rho)} / (2-\rho) \,]$ es una **función de pérdida estrictamente consistente (*strictly consistent scoring function*) para la esperanza condicional $\mu = E[Y \mid X]$** [5]. Al usar enlace logarítmico interno ($\hat{\mu} = \exp(\eta)$) sin transformar la etiqueta Y, el modelo garantiza predicciones estrictamente no negativas ($\hat{\mu} > 0$) sin sufrir el sesgo de Jensen.

SECCIÓN 2. Selección y justificación de métricas de evaluación y desempeño mínimo a superar (*Benchmark*)

2.1 ¿Cuáles son las métricas adecuadas para el problema de negocio y por qué?

En un panel con 61.71 % de días con venta cero, el error porcentual absoluto medio clásico (MAPE = $(1/N) \cdot \sum |y_i - \hat{y}_i| / y_i$) **se indetermina matemáticamente (división entre cero)**. Por ello, de acuerdo con la literatura de pronóstico minorista a gran escala (competencias M5 [6]) y los compromisos firmados con Bnext, adoptamos cinco métricas complementarias:

Métrica	Fórmula Matemática	Qué mide en el negocio de las tiendas y por qué es indispensable
1. WMAPE *(Métrica Primaria)*	`WMAPE = ∑	$y_{i,t} - \hat{y}_{i,t}$
2. Sesgo Porcentual (*Bias %*)	Bias % = 100 × ∑ ($\hat{y}_{i,□}$ - $y_{i,□}$) / ∑ $y_{i,□}$	Mide si el modelo **sobre-inventaría (Bias > 0, capital inmovilizado)** o **sub-inventaría (Bias < 0, desabasto y venta perdida)**. Es la métrica que reveló el defecto de -35.89 % del modelo previo.
3. MAE *(Error Absoluto Medio)*	`MAE = (1/N) · ∑	$y_{i,t} - \hat{y}_{i,t}$
4. RMSE *(Error Cuadrático Medio)*	RMSE = √[(1/N) · ∑ ($y_{i,□}$ - $\hat{y}_{i,□}$)²]	Penaliza cuadráticamente los errores extremos en **días pico** (quincenas, olas de calor y promociones cerveceras), donde fallar cuesta más al negocio.
5. Estadístico de Diebold–Mariano (DM)	DM = $\bar{d}$ / √(Var($\bar{d}$) / T), con `d_t =	$e_{1,t}$

2.2 ¿Cuál es el desempeño mínimo a superar (*Benchmark*)?

Para que un modelo sea aceptado en el registro de modelos (MLflow) y pueda avanzar a la fase de calibración probabilística por cuantiles (Semana 6), debe superar simultáneamente **tres compuertas cuantitativas (*Quality Gates*)**:

1. **Compuerta 1 — Superar holgadamente el Baseline Ingenuo Estacional (venta_lag_7):** Obtener un WMAPE significativamente menor al 0.5815 del Naive en el corte *Holdout* (0.5913 promedio en los 4 cortes) con un estadístico de Diebold–Mariano DM < -1.96 ($p < 0.05$).
2. **Compuerta 2 — Igualar o superar el WMAPE del prototipo previo en el corte *Holdout* (WMAPE <= 0.5002):** En el corte oficial de prueba (18–31 de mayo), el modelo debe romper la barrera de 0.5002 establecida en la auditoría de la Semana 1.
3. **Compuerta 3 — Controlar el sesgo sistemático de volumen (|Bias %| <= 10.0 %) y reducir el RMSE en picos:** Corregir el sesgo de -29.86 % (-35.89 % en Holdout) del modelo LGBM_RMSE_Log1p sin degradar la precisión puntual.

SECCIÓN 3. Resultados del Backtesting *Walk-Forward* en 4 Cortes de 14 Días (Grano Categoría y Grano Marca)

3.1 Evaluación en los 4 cortes *walk-forward* sobre /opt/predictive_sales (Grano Categoría)

Utilizando el entorno productivo del servidor vmbnextsp-111 (/opt/anaconda3/envs/predictive_sales/bin/python, Polars 1.33.1, LightGBM 4.6.0), se ejecutó el protocolo de validación con ventana de entrenamiento expansiva (*expanding window walk-forward*) sobre 2,535,125 registros de series completas (39 características numéricas limpias tras excluir venta_total_log y las 4 variables calendario sin varianza en 92 días). Los resultados íntegros persistidos en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/tabla1_backtesting_walkforward_4_cortes.csv se muestran en la siguiente tabla:

Corte *Walk-Forward* (14 días)	Ventana Train → Val	Modelo Evaluado	Filas Train	Filas Val	WMAPE	MAE (MXN)	RMSE (MXN)	Sesgo (Bias %)	Diebold–Mariano (DM)	Valor-p
Fold_1_Val	08 mar–05 abr → 06–19 abr	1. Baseline Naive (lag_7)	864,925	417,550	0.6488	156.40	1,178.15	+6.04 %	0.00	1.0000
Fold_1_Val	08 mar–05 abr → 06–19 abr	2. Baseline Media Móvil 7d	864,925	417,550	0.6433	155.07	1,050.69	+3.26 %	-0.99	0.3231
Fold_1_Val	08 mar–05 abr → 06–19 abr	3. LGBM RMSE Log1p (Equipo Previo)	864,925	417,550	0.5007	120.70	928.34	**-25.34 %**	-30.52	< 0.0001

Corte *Walk-Forward* (14 días)	Ventana Train → Val	Modelo Evaluado	Filas Train	Filas Val	WMAPE	MAE (MXN)	RMSE (MXN)	Sesgo (Bias %)	Diebold–Mariano (DM)	Valor-p
Fold_1_Val	08 mar–05 abr → 06–19 abr	**4. LGBM Tweedie Capa Oro (Bnext)**	864,925	417,550	**0.5246**	**126.46**	**889.80**	**-2.90 %**	**-27.43**	**< 0.0001**
Fold_2_Val	08 mar–19 abr → 20 abr–03 may	1. Baseline Naive (lag_7)	1,282,475	417,550	0.5624	140.11	918.75	-2.30 %	0.00	1.0000
Fold_2_Val	08 mar–19 abr → 20 abr–03 may	2. Baseline Media Móvil 7d	1,282,475	417,550	0.5788	144.18	905.86	-1.70 %	+3.72	0.0002
Fold_2_Val	08 mar–19 abr → 20 abr–03 may	3. LGBM RMSE Log1p (Equipo Previo)	1,282,475	417,550	0.4585	114.22	793.37	**-26.45 %**	-27.31	< 0.0001
Fold_2_Val	08 mar–19 abr → 20 abr–03 may	**4. LGBM Tweedie Capa Oro (Bnext)**	1,282,475	417,550	**0.4797**	**119.50**	**734.27**	**-1.81 %**	**-25.12**	**< 0.0001**
Fold_3_Val	08 mar–03 may → 04–17 may	1. Baseline Naive (lag_7)	1,700,025	417,550	0.5726	151.13	1,007.01	-1.69 %	0.00	1.0000
Fold_3_Val	08 mar–03 may → 04–17 may	2. Baseline Media Móvil 7d	1,700,025	417,550	0.6094	160.84	1,084.91	-1.03 %	+8.16	< 0.0001
Fold_3_Val	08 mar–03 may → 04–17 may	3. LGBM RMSE Log1p (Equipo Previo)	1,700,025	417,550	0.4755	125.49	993.08	**-31.77 %**	-24.32	< 0.0001
Fold_3_Val	08 mar–03 may → 04–17 may	**4. LGBM Tweedie Capa Oro (Bnext)**	1,700,025	417,550	**0.4894**	**129.18**	**914.02**	**-7.94 %**	**-24.18**	**< 0.0001**
Fold_4_Holdout	08 mar–17 may → 18–31 may	1. Baseline Naive (lag_7)	2,117,575	417,550	0.5815	162.88	1,206.91	-6.08 %	0.00	1.0000
Fold_4_Holdout	08 mar–17 may → 18–31 may	2. Baseline Media Móvil 7d	2,117,575	417,550	0.6327	177.23	1,307.95	-7.32 %	+11.34	< 0.0001
Fold_4_Holdout	08 mar–17 may → 18–31 may	3. LGBM RMSE Log1p (Equipo Previo)	2,117,575	417,550	0.5045	141.32	1,223.66	**-35.89 %**	-19.69	< 0.0001

Corte *Walk-Forward* (14 días)	Ventana Train → Val	Modelo Evaluado	Filas Train	Filas Val	WMAPE	MAE (MXN)	RMSE (MXN)	Sesgo (Bias %)	Diebold–Mariano (DM)	Valor-p
Fold_4_Holdout	08 mar–17 may → 18–31 may	**4. LGBM Tweedie Capa Oro (Bnext)**	2,117,575	417,550	**0.4991**	**139.80**	**1,076.11**	**-8.65 %**	**-25.40**	**< 0.0001**

3.2 Síntesis consolidada de los 4 cortes *walk-forward* y hallazgos de negocio

La tabla consolidada (tabla2_resumen_global_walkforward.csv) resume la media y desviación estándar a lo largo de las cuatro quincenas evaluadas:

Modelo Evaluado (4 Cortes *Walk-Forward*)	WMAPE Medio (4 Cortes)	Estabilidad (WMAPE_Std)	WMAPE en Corte *Holdout* (Fold 4)	MAE Medio (MXN)	RMSE Medio (MXN)	Sesgo Medio (Bias %)	Diebold–Mariano Medio (DM)	Diagnóstico Integral (TEC + Bnext)
4. LGBM Tweedie Capa Oro (Equipo Bnext)	**0.4982**	**0.0193** *(Más estable)*	**0.4991** *(Mejor Holdout)*	128.74	**903.55** *(Mejor RMSE)*	**-5.32 %** *(Insesgado)*	**-25.53** ($p < 0.0001$)	**MODELO BASE CAMPEÓN:** Cumple las 3 compuertas; abate el RMSE en -8.2 % (-12.1 % en Holdout) y corrige el sesgo de desabasto.
3. LGBM RMSE Log1p (Equipo Previo)	0.4848	0.0217	0.5045	125.43	984.61	**-29.86 %** *(-35.89 % Holdout)*	-25.46 ($p < 0.0001$)	**Descartado por sesgo severo de Jensen:** Sub-predice casi un tercio de la demanda real y falla en días pico (RMSE = 1,223.66 en Holdout).
1. Baseline Naive Estacional (lag_7)	0.5913	0.0391	0.5815	152.63	1,077.70	-1.01 %	0.00 *(Referencia)*	Línea base heurística inferior en casi 10 puntos de WMAPE frente a los modelos basados en árboles.

Modelo Evaluado (4 Cortes *Walk-Forward*)	WMAPE Medio (4 Cortes)	Estabilidad (WMAPE_Std)	WMAPE en Corte *Holdout* (Fold 4)	MAE Medio (MXN)	RMSE Medio (MXN)	Sesgo Medio (Bias %)	Diebold–Mariano Medio (DM)	Diagnóstico Integral (TEC + Bnext)
2. Baseline Media Móvil Causal 7d	0.6160	0.0286	0.6327	159.33	1,087.35	-1.70 %	+5.56 *(Peor que lag_7)*	Promediar los últimos 7 días diluye la fuerte estacionalidad semanal (viernes–domingo vs. lunes–miércoles).

IMPORTANTE — ¿Por qué LGBM_RMSE_Log1p aparenta un WMAPE ligeramente menor en los primeros cortes pero fracasa en el RMSE y en el Sesgo?
En series con 61.71 % de ceros, un estimador fuertemente sesgado hacia cero (Bias = -29.86 %) reduce artificialmente la suma de errores absolutos en los días sin venta, pero **colapsa en los días de alta demanda**, como lo demuestra su **RMSE en el corte *Holdout* (1,223.66 en LGBM_RMSE_Log1p, incluso peor que el 1,206.91 del Naive lag_7, frente a 1,076.11 de nuestro LGBM_Tweedie)**. Además, conforme el histórico de entrenamiento crece hacia el Fold_4_Holdout (2.11M de filas de entrenamiento), **LGBM_Tweedie supera a LGBM_RMSE_Log1p tanto en WMAPE (0.4991 vs. 0.5045), como en MAE (139.80 vs. 141.32), RMSE (1,076.11 vs. 1,223.66) y Sesgo (-8.65 % vs. -35.89 %)**.

3.3 Extensión del Baseline LightGBM Tweedie al Nuevo Grano de Marca (Compromiso Bnext Semana 5)

En cumplimiento del segundo compromiso de la Semana 5 con Bnext (*"Entrenar los modelos base de referencia —Naive estacional y LightGBM Tweedie— sobre el nuevo grano de marca"*), se ejecutó en vmbnextsp-111 el *backtesting walk-forward* de 4 cortes sobre el panel agregado al grano **(store_code, category_id, brand_id, fecha)** para las 50 marcas líderes (con deduplicación previa de order_line_id y tasa_descuento continua reconstruida). Los resultados exactos persistidos en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/tabla5_backtesting_walkforward_grano_marca.csv son:

Corte *Walk-Forward* (Grano Marca)	Filas Train	Filas Val	WMAPE Naive Estacional (lag_7)	WMAPE LightGBM Tweedie Marca (ρ = 1.4)	Mejora Relativa vs. Naive (%)	MAE Marca (MXN)	RMSE Marca (MXN)	Sesgo (Bias %)	Diebold–Mariano (DM)
Fold_1_Val (06–19 abr)	120,402	68,729	0.6388	**0.4809**	**+24.73 %**	256.12	851.27	+4.02 %	**-32.00** ($p < 0.0001$)
Fold_2_Val (20 abr–03 may)	189,131	73,084	0.5751	**0.4455**	**+22.54 %**	235.98	761.95	**-0.74 %**	**-28.46** ($p < 0.0001$)
Fold_3_Val (04–17 may)	262,215	74,110	0.5672	**0.4438**	**+21.76 %**	245.10	849.11	-5.84 %	**-31.44** ($p < 0.0001$)

Corte *Walk-Forward* (Grano Marca)	Filas Train	Filas Val	WMAPE Naive Estacional (lag_7)	WMAPE LightGBM Tweedie Marca (ρ = 1.4)	Mejora Relativa vs. Naive (%)	MAE Marca (MXN)	RMSE Marca (MXN)	Sesgo (Bias %)	Diebold–Mariano (DM)
Fold_4_Holdout (18–31 may)	336,325	73,456	0.5914	**0.4543**	**+23.18 %**	248.08	841.94	**+1.32 %**	**-31.47** ($p < 0.0001$)
Promedio 4 Cortes (Media ± Std)	—	—	0.5931 (± 0.0320)	**0.4561 (± 0.0171)**	**+23.05 %**	246.32	826.07	**-0.31 %**	**-30.84** ($p < 0.0001$)

Hallazgo clave para Bnext: Al modelar sobre el nuevo grano productivo de **Marca ((store_code, category_id, brand_id, fecha))** con la tasa_descuento continua reconstruida, el WMAPE en el corte *Holdout* desciende hasta **0.4543** (0.4561 promedio en los 4 cortes, equivalente a una **mejora relativa de 23.05 % sobre el Naive estacional**, muy superior al 14.76 % del prototipo previo), con un **sesgo promedio de apenas -0.31 % (+1.32 % en el Holdout)** y un estadístico de Diebold–Mariano medio de **-30.84 ($p < 0.0001$)**.

SECCIÓN 4. Diagnóstico de Sub-entrenamiento y Sobre-entrenamiento (*Underfitting / Overfitting*)

4.1 Evidencia cuantitativa de la curva de aprendizaje (Train vs. Validación)

Para responder con rigor cuantitativo la pregunta de la rúbrica del TEC (*"¿El modelo está sub-entrenado o sobre-entrenado?"*), se instrumentó el registro de métricas sobre el conjunto de **Entrenamiento (2,117,575 filas)** y el conjunto de **Validación Holdout (417,550 filas)** a lo largo de la construcción secuencial de los árboles de decisión (50, 100 y 111 iteraciones, punto óptimo determinado por *early stopping* con paciencia de 30 rondas en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/tabla3_diagnostico_overfitting_curvas.csv):

Corte Evaluado	Número de Árboles (n_estimators)	¿Iteración Óptima (*Early Stopping*)?	WMAPE Entrenamiento (Train)	WMAPE Validación (Val)	Brecha de Generalización (WMAPE_Val - WMAPE_Train)	MAE Entrenamiento (MXN)	MAE Validación (MXN)	Diagnóstico del Régimen de Aprendizaje
Fold_4_Holdout	50 árboles	No (En aprendizaje)	0.5046	0.5265	+0.0219 (+2.19 %)	127.07	147.47	**Sub-entrenamiento leve (*Underfitting* parcial):** Con solo 50 árboles con $\eta = 0.07$, el ensamble aún no captura todas las interacciones de clima y categoría.
Fold_4_Holdout	100 árboles	No (Cerca de convergencia)	0.4771	0.4993	+0.0222 (+2.22 %)	120.15	139.86	**Convergencia estable:** El WMAPE de validación rompe la barrera de 0.5000 mientras la brecha Train–Val permanece constante en 2.22 %.
Fold_4_Holdout	**111 árboles**	**Sí (best_iteration = 111)**	**0.4757**	**0.4991**	**+0.0234 (+2.34 %)**	**119.80**	**139.80**	**Punto óptimo de equilibrio Sesgo–Varianza:** El *early stopping* detiene el entrenamiento antes de que la brecha supere 2.5 %, logrando el mínimo error fuera de muestra (0.4991).

4.2 Mecanismos de regularización aplicados para prevenir el *Overfitting*

El modelo **no presenta *underfitting*** (reduce el WMAPE en -8.24 puntos porcentuales en Categoría y -13.71 puntos porcentuales en Marca frente al Naive estacional) **ni presenta *overfitting*** (la brecha entre entrenamiento y prueba es de apenas **2.34 puntos porcentuales** y la desviación estándar del WMAPE a través de los 4 cortes *walk-forward* es de solo **0.0193** en Categoría y **0.0171** en Marca). Este equilibrio se logró mediante cinco controles explícitos de complejidad en LightGBM:

1. **Restricción estructural de profundidad y hojas (max_depth = 8, num_leaves = 63):** Aunque un árbol binario completo de profundidad 8 tendría 2^8 = 256 hojas, limitar num_leaves = 63 impide que el algoritmo cree particiones hiper-específicas que memoricen picos aislados de una sola tienda.
2. **Masa mínima por hoja (min_data_in_leaf = 150):** Obliga a que cada regla terminal esté respaldada por al menos 150 observaciones tienda-categoría-día, filtrando el ruido de alta frecuencia.
3. **Submuestreo estocástico doble (feature_fraction = 0.85, bagging_fraction = 0.85, bagging_freq = 1):** En cada árbol se muestrea sin reemplazo el 85 % de las filas y el 85 % de las columnas, reduciendo la varianza del ensamble y evitando que venta_media_movil_7 monopolice el 100 % de las particiones superiores.
4. **Penalización elástica sobre los pesos de las hojas (lambda_l1 = 1.0, lambda_l2 = 2.0):** Contrae hacia cero las hojas con baja ganancia marginal en la verosimilitud Tweedie.
5. **Parada temprana (*Early Stopping* = 30 rondas):** Monitorea simultáneamente la desviación Tweedie y el MAE en el corte de validación temporal, seleccionando automáticamente best_iteration = 111.

SECCIÓN 5. Importancia de las Características en el Modelo *Baseline* (Criterio TEC 2)

5.1 Ranking empírico de las Top 25 variables por Ganancia (*Gain %*) y Particiones (*Split Count*)

Para responder la segunda pregunta de la rúbrica del TEC (*"¿Se puede determinar la importancia de las características para el modelo baseline?"*), se consolidó la importancia acumulada a través de los 4 cortes *walk-forward* en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/tabla4_importancia_variables_baseline.csv bajo dos criterios complementarios:

- **Ganancia porcentual (Gain_Pct):** Proporción de la reducción total de la desviación Tweedie aportada por cada variable. Mide el **poder explicativo estructural sobre el nivel de la demanda**.
- **Conteo medio de particiones (Split_Count):** Número promedio de nodos de decisión donde la variable fue utilizada para refinar el pronóstico. Mide la **capacidad de modulación contextual y ajuste fino en colas**.

Posición	Característica (Feature)	Familia de la Capa Oro (Semana 4)	Ganancia Total (Gain_Pct %)	Particiones Promedio (Split_Count)	Interpretación Económica y Operativa en las tiendas
1	venta_media_movil_7	Estadísticos móviles	**85.606 %**	625.8	Ancla el nivel base de escala de cada serie (tienda, categoría) durante la última semana operativa.
2	venta_lag_7	Autorregresivos de ventas	**9.447 %**	297.8	Captura el ciclo semanal exacto (mismo día de la semana anterior: sábado vs. sábado).
3	venta_lag_1	Autorregresivos de ventas	**1.482 %**	239.2	Captura la inercia inmediata del día anterior (choques de corto plazo y rachas).
4	category_id	Identificación y jerarquía	**1.416 %**	**899.2** ***(1° en Splits)***	**Variable con más particiones en el bosque (899.2):** Modula las elasticidades específicas de cada una de las 232 categorías.
5	venta_lag_14	Autorregresivos de ventas	**1.149 %**	**642.0** ***(2° en Splits)***	Segunda referencia estacional semanal y quincenal (t - 14).
6	precio_vs_prom_7d	Precios y promociones	**0.127 %**	154.2	Ratio de precio relativo respecto a la última semana; detecta caídas promocionales de precio.
7	dow_sin	Calendario y Fourier	**0.090 %**	174.0	Componente armónica semanal ($\sin(2\pi \cdot \text{dow} / 7)$) que suaviza la transición hacia el fin de semana.
8	dia_semana	Calendario y Fourier	**0.076 %**	157.2	Diferencia el salto de volumen de viernes, sábado y domingo.
9	store_code	Identificación y jerarquía	**0.067 %**	142.5	Captura heterogeneidad idiosincrática de sucursales de alto tráfico.
10	dia_mes	Calendario y Fourier	**0.054 %**	150.5	Captura el efecto de liquidez de quincena (días 15 y 30/31) y principio de mes.

Posición	Característica (Feature)	Familia de la Capa Oro (Semana 4)	Ganancia Total (Gain_Pct %)	Particiones Promedio (Split_Count)	Interpretación Económica y Operativa en las tiendas
11	num_tickets_lag_1	Tráfico de tienda	**0.047 %**	64.5	Afluencia peatonal observada en la sucursal el día previo.
12	t_max	Clima municipal (Open-Meteo)	**0.046 %**	105.0	Temperatura máxima del día; impulsa fuertemente las categorías de cerveza, hielo, agua y refrescos.
13	anomalia_termica	Clima municipal (Open-Meteo)	**0.045 %**	144.8	Desviación térmica frente al promedio móvil de 14 días (olas de calor repentinas).
14	t_max_lag1	Clima municipal (Open-Meteo)	**0.038 %**	76.8	Persistencia térmica del día anterior.
15	t_max_media_14d	Clima municipal (Open-Meteo)	**0.034 %**	72.5	Régimen climático quincenal de cada municipio.
16	zone_id_cod	Geografía y perfil de tienda	**0.033 %**	75.5	Diferenciación regional entre bloques geográficos de las tiendas.
17	intensidad_descuento_lag_1	Precios y promociones	**0.029 %**	70.5	Efecto de arrastre promocional del descuento efectivo reconstruido.
18	RATIO_TARGET_CONVENIENCIA_INEGI	Demografía INEGI (Rescate SEPOMEX)	**0.029 %**	62.2	Proporción de población objetivo en el municipio (con 100 % de cobertura tras el rescate de 1,753 tiendas).
19	TASA_PEA_INEGI	Demografía INEGI (Rescate SEPOMEX)	**0.023 %**	61.8	Tasa de Población Económicamente Activa municipal (poder adquisitivo local).
20	t_max_lag7	Clima municipal (Open-Meteo)	**0.023 %**	61.8	Contraste térmico respecto al mismo día de la semana anterior.
21	NSE_PROXY_INTERNET_INEGI	Demografía INEGI (Rescate SEPOMEX)	**0.021 %**	57.8	Nivel socioeconómico proxy del entorno de la tienda.

Posición	Característica (Feature)	Familia de la Capa Oro (Semana 4)	Ganancia Total (Gain_Pct %)	Particiones Promedio (Split_Count)	Interpretación Económica y Operativa en las tiendas
22	DENSIDAD_HOGAR_INEGI	Demografía INEGI (Rescate SEPOMEX)	**0.021 %**	52.8	Tamaño medio del hogar en el municipio (asociado a compras de empaque familiar/six-pack).
23	intensidad_ligamx	Eventos deportivos (Liga MX)	**0.020 %**	52.0	Partidos de alta audiencia de la Liga MX que disparan el consumo de cerveza y botanas.
24	t_min	Clima municipal (Open-Meteo)	**0.020 %**	59.0	Temperatura mínima nocturna (relevante para ventas vespertinas/nocturnas).
25	lluvia_acc_3d	Clima municipal (Open-Meteo)	**0.010 %**	32.5	Precipitación acumulada de 3 días (reduce el tráfico peatonal a la tienda).

5.2 Interpretación estructural: Ganancia (*Gain*) vs. Frecuencia de Partición (*Splits*)

El análisis conjunto de Gain_Pct y Split_Count revela un comportamiento clásico y saludable en modelos jerárquicos de paneles minoristas:

1. **Separación de escala vs. modulación contextual:** Las primeras divisiones de cada árbol (venta_media_movil_7 con 85.61 % del Gain y venta_lag_7 con 9.45 %) separan las órdenes de magnitud entre una categoría líder en una tienda grande (ventas de 5,000+ MXN/día) y una categoría secundaria en una tienda pequeña (20 MXN/día).
2. **Importancia real de las variables exógenas y de catálogo en los nodos profundos:** Una vez fijada la escala base de la serie en los primeros niveles del árbol, **category_id (899.2 splits), venta_lag_14 (642.0 splits), el precio relativo (precio_vs_prom_7d, 154.2 splits), el calendario (dow_sin, dia_semana, dia_mes con >480 splits combinados), el clima (t_max y anomalia_termica con 250 splits) y las variables demográficas de INEGI rescatadas con SEPOMEX (RATIO_TARGET_CONVENIENCIA_INEGI, TASA_PEA_INEGI, NSE_PROXY_INTERNET_INEGI con >230 splits combinados)** son las que determinan el ajuste fino que permite a LightGBM Tweedie reducir el RMSE en **-12.1 %** y batir al Naive estacional por más de 8 puntos de WMAPE en Categoría y 13.7 puntos en Marca.

SECCIÓN 6. Conclusiones de la Semana 5 y Hoja de Ruta hacia la Semana 6 (Cuantiles P10 / P50 / P90)

1. **Cierre al 100 % de los entregables del TEC (*Avance 3. Baseline*) y de Bnext (*Semana 5*):** Quedaron ejecutados y persistidos en /opt/predictive_sales/data/outputs/avance3_baseline_bnext/ los 4 cortes *walk-forward* de 14 días, las corridas en formato MLflow (mlruns/), las 5 tablas comparativas (tabla1 a tabla5), el diagnóstico de *underfitting/overfitting* y el ranking de importancia de variables, además de la libreta reproducible notebooks/Avance3.43.ipynb y el script src/models/entrenar_baseline_walkforward.py.
2. **Descubrimiento y corrección del sesgo de Jensen del prototipo heredado:** Se demostró que entrenar con RMSE sobre log(1 + y) provocaba un sesgo de sub-predicción de **-29.86 %** (-35.89 % en el Holdout). La migración a **LightGBM Tweedie (ρ = 1.5) en escala natural** corrige el sesgo a **-5.32 %**, reduce el RMSE de 1,223.66 a **1,076.11 (-12.1 %)** y mejora el WMAPE en el corte *Holdout* a **0.4991** en Categoría y a **0.4543** en el nuevo grano de **Marca** (+23.05 % de mejora relativa media sobre el Naive estacional, con sesgo medio de -0.31 %).
3. **Preparación directa para la Semana 6 (Pronóstico probabilístico P10, P50, P90 con Optuna):** Con el protocolo *walk-forward* automatizado y la línea base LightGBM Tweedie establecida como nuevo @champion puntual, en la Semana 6 se extenderá este mismo pipeline al entrenamiento de tres regresores cuantílicos ($\tau \in \{0.10, 0.50, 0.90\}$) con pérdida *Pinball* y optimización bayesiana en Optuna 4.8.0.

Referencias bibliográficas

1. Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction*, 3(2), 392–413.
2. Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
3. Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 3146–3154.
4. Dunn, P. K., & Smyth, G. K. (2005). Series evaluation of Tweedie exponential dispersion model densities. *Statistics and Computing*, 15(4), 267–280.
5. Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494), 746–762.
6. Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364.