

Tecnológico de Monterrey
Escuela de Ingeniería y Ciencias

Proyecto Integrador

Evolución del Modelado Predictivo de Ventas a Nivel SKU y Sector Promociones para 17,000 Tiendas mediante MLOps y Simulación de Escenarios en Azure Databricks

Entrega Colaborativa:

Daniel Juárez Ortiz - A01797369

Kevin Alexis Valdez Pérez- A01750478

Yael Ariel Márquez Mas - A01745310

25 de octubre de 2026

Sexto Entregable

PROYECTO INTEGRADOR · SEMANA 6

Pronóstico de ventas por categoría y evaluación de modelos alternativos

Avance 4. Comparación de algoritmos, ajuste de hiperparámetros y selección del modelo final

La Semana 6 amplía la línea base del proyecto mediante un torneo de nueve alternativas sobre cuatro cortes temporales de catorce días en Azure Databricks. LightGBM Tweedie se selecciona como candidato final: obtiene WMAPE medio de 0.4562 en las filas evaluables del conjunto ampliado, frente a 0.5530 del ingenuo estacional. La búsqueda de hiperparámetros conserva las configuraciones iniciales; el modelo queda registrado como versión 1 con alias challenger. La promoción productiva y la validación probabilística permanecen pendientes.

Identificación del entregable

Campo	Valor
Institución académica	Tecnológico de Monterrey — Maestría en Inteligencia Artificial Aplicada
Curso y equipo	Proyecto Integrador — Equipo 43
Entregable académico	Semana 6 — Avance 4. Modelos alternativos; objetivos 3.3 y 3.4
Compromiso con Bnext	Comparación temporal de alternativas, afinación de dos finalistas y selección sustentada de un candidato
Asesora	Dra. Eduviges Ludivina Facundo
Patrocinador	Dr. Juan Arturo Nolazco Flores — Director del Hub de Ciencia de Datos (jnolazco@tec.mx)
Fecha de entrega	25 de octubre de 2026
Evidencia principal	Avance 4 TEC.ipynb; módulos 20_features_oro y 21_avance4_modelos_alternativos; salidas registradas del 20 y 22 de octubre de 2026

Resumen ejecutivo de indicadores de la fase

Tabla 1. Resultados principales de la Semana 6

Indicador	Resultado registrado	Interpretación
Diversidad de candidatos	9 alternativas, 6 familias según agrupación del código; más referencia ingenua	N-HiTS está desactivado; no se cuenta como modelo ejecutado
Mejor candidato en muestra común	LightGBM Tweedie: 0.4503 ± 0.0038	Media y desviación del WMAPE en 4 cortes; ingenuo 0.5499
Evaluación ampliada	0.4562 ± 0.0043 frente a 0.5530	Reducción relativa de WMAPE 17.5%; sesgo medio +0.48%
Segundo finalista	CatBoost Tweedie: 0.4637 en conjunto ampliado	Mejora relativa 16.2% frente al ingenuo
Afinación de hiperparámetros	7 pruebas LightGBM y 4 CatBoost; mejora 0.0%	Se retienen parámetros iniciales dentro del presupuesto explorado
Registro del candidato	demanda_categoria, versión 1, alias challenger	Registro acreditado por las salidas; promoción a champion pendiente
Cobertura de modelos individuales	10 candidatos independientes (6 de estimador único + 4 de árboles)	Cumple como candidatos individuales sin meta-ensamble (S7) y con 6 estimadores únicos (M0, M1, M2, M6, M8, M9)

SECCIÓN 1. Alineación académica y de negocio y continuidad del proyecto

1.1 Propósito del avance y relación con los objetivos 3.3 y 3.4

El objetivo 3.3 se aborda contrastando enfoques lineales, lineales generalizados, métodos de árboles, una red neuronal tabular y métodos estadísticos por serie. El objetivo 3.4 se aborda mediante la definición de espacios de búsqueda, la afinación de los dos finalistas y la evaluación posterior de sus configuraciones. La elección incorpora error, estabilidad temporal, sesgo y costo computacional. La búsqueda realizada no demuestra un óptimo global: establece la mejor configuración observada dentro de las pruebas completadas [1, 2].

En una red de tiendas de conveniencia, el pronóstico orienta la planeación de ventas y reabasto bajo restricciones de espacio, rotación y vida útil. La subestimación puede contribuir a faltantes; la sobreestimación puede elevar inventario y merma. Sin embargo, este avance mide ventas monetarias observadas, no demanda insatisfecha, niveles de inventario ni merma. La reducción del error es un

habilitador de esas decisiones y todavía no constituye una reducción operativa medida de quiebres o desperdicio.
El planteamiento S6–S10 propone un desarrollo gradual en Databricks, con calidad de datos, modelado, evaluación, registro, compuerta, inferencia y monitoreo. El alcance ejecutado en este notebook termina en comparación, selección, explicación y registro del candidato. Los cuantiles, intervalos, promociones futuras y automatización corresponden a etapas posteriores. El servidor se conserva como respaldo y sus pruebas locales no se mezclan con los resultados oficiales de esta corrida [2].

1.2 Continuidad con la ingeniería de características y la línea base

La Semana 4 organizó el trabajo de calidad y construcción de variables: rezagos de ventas, promedios móviles, calendario, precios y descuentos, contexto de tienda y fuentes externas. La Semana 5 estableció la necesidad de evaluar en el tiempo, comparar contra reglas simples y observar el sesgo además del WMAPE. La Semana 6 conserva esas preguntas y cambia su implementación: utiliza el histórico de marzo a agosto, un estado de características congelado en cada origen y evaluación de horizontes futuros de uno a catorce días [3, 4].

Tabla 2. Evolución metodológica y límites de la comparación histórica

Referencia	Alcance documentado	Lectura para este avance
Prototipo histórico	WMAPE 0.5002; holdout único de 14 días; ingenuo 0.5868	Referencia histórica de Documentacion.md; no es el benchmark recalculado del torneo
Semana 4	Selección de características y preparación de la capa analítica	Antecedente conceptual; no implica que las tablas antiguas y la nueva Oro sean idénticas
Semana 5 oficial	Categoría: WMAPE medio 0.4982 y holdout 0.4991; cortes abril–mayo	Resultados reportados en aquella entrega; su población, periodo y protocolo difieren
Semana 6 actual	Muestra común: 0.4503 frente a 0.5499; ampliada: 0.4562 frente a 0.5530	Las mejoras válidas se calculan dentro de cada evaluación actual

Por ello, no se atribuye una mejora causal a la resta entre 0.4991 de Semana 5 o 0.5002 del prototipo y 0.4562 actual. Cambiaron las fechas, las variables, las cohortes y la agregación. Tampoco se trasladan a esta corrida los resultados previos a nivel marca: el grano evaluado aquí es tienda–categoría. La continuidad se demuestra con el protocolo, las preguntas de negocio y el contraste actual contra el ingenuo, no suponiendo equivalencia entre ejecuciones.

1.3 Alcance de la condición de modelos individuales sin ensambles

En el diseño curricular del proyecto, la Semana 6 evalúa modelos candidatos entrenados de forma independiente, a diferencia de la Semana 7 (Avance 5), donde se construyen meta-ensambles que combinan las predicciones de múltiples modelos (blending, voting o stacking). Bajo esta definición metodológica, se entrenaron y evaluaron por separado nueve alternativas más la referencia ingenua (diez modelos en total de seis familias algorítmicas), sin aplicar aún combinación ni apilado entre candidatos

finales. Adicionalmente, se distingue con rigor técnico qué algoritmos utilizan internamente múltiples árboles mediante bagging o boosting (Random Forest, LightGBM y CatBoost) frente a los de estimador único [7, 8].
Incluso bajo una lectura estructural estricta que separe a los algoritmos basados en múltiples árboles, el experimento evalúa seis modelos de estimador único al contabilizar la referencia estacional (M0 Ingenuo estacional, M1 Elastic Net, M2 GLM Tweedie, M6 Perceptrón multicapa, M8 Theta y M9 TSB), además de las cuatro formulaciones basadas en árboles (M3 Random Forest, M4 LightGBM Tweedie, M4b LightGBM Log1p y M5 CatBoost Tweedie). N-HiTS figura en el código como extensión futura desactivada. De este modo, el torneo acredita tanto la diversidad de seis familias algorítmicas independientes como la comparación explícita entre estimadores únicos y algoritmos de boosting.

SECCIÓN 2. Datos, métricas y protocolo experimental

2.1 Grano de la capa Oro y poblaciones de análisis

Una serie representa la evolución de ventas de una categoría en una tienda. No es una fila aislada ni una tienda completa: una misma tienda puede aportar muchas series. La capa Oro transforma esas historias en ejemplos con clave tienda, categoría, origen T y horizonte h. El objetivo y es la venta monetaria observada en T+h. El modelo global aprende de múltiples series y recibe h como predictor, sin necesitar un modelo independiente para cada tienda.
La fuente operativa es modeladoprescriptivoventas.maestria.gold_features_origen, construida a partir del panel diario y catálogos del mismo esquema. El periodo del panel es del 1 de marzo al 31 de agosto de 2026. La capa registra 42,524,507 filas: 7,838,948 de entrenamiento y 34,685,559 de evaluación antes de los filtros de elegibilidad, incluido el origen de ajuste. El diseño declara 63 orígenes de entrenamiento cada dos días; la tabla materializada conserva 62 orígenes y 9,996 series. Se distinguen ambos conteos en lugar de interpretar el número planeado como observaciones efectivas [1].
El universo identificado contiene 653,881 series relevantes. La selección de entrenamiento se estratifica por ABC: 5,000 series A, 3,000 B y 2,000 C, con participaciones de ventas de aproximadamente 80%, 15% y 5%. La muestra común de evaluación se define mediante hash del 3% de las series: inicialmente 19,575; después de filtros se observan 18,798. Esta cohorte permite comparar candidatos sobre las mismas observaciones evaluables, aunque los límites de entrenamiento varían por algoritmo.

Tabla 3. Conteos efectivos para interpretar los resultados

Población o etapa	Filas	Alcance
Oro materializada	42,524,507	Entrenamiento y evaluación antes de filtros del torneo
Entrenamiento elegible previo al muestreo	7,012,878	Historia suficiente, referencia no nula y actividad reciente
Entrenamiento cargado en driver	3,498,262	9,906 series; muestra aleatoria aproximada del 50%

Población o etapa	Filas	Alcance
Evaluación común total	1,116,864	5 orígenes, incluido ajuste; 18,798 series
Origen de ajuste	204,942	Validación del 21 de mayo al 3 de junio
Torneo en muestra común	911,922	Suma de los 4 cortes de comparación
Evaluación ampliada elegible	30,471,370	4 cortes, todas las filas que cumplen el protocolo

Los filtros exigen al menos cinco días históricos con venta, referencia estacional disponible y cinco días activos recientes. Por tanto, “conjunto completo” significa todas las filas evaluables bajo esas reglas; no representa las 17,000 tiendas objetivo sin exclusiones ni todas las filas de Oro. Los conteos se refieren a ejemplos serie–origen–horizonte y no a ventas transaccionales únicas.

2.2 Cortes temporales y disponibilidad de la información

Tabla 4. Orígenes y ventanas de validación

Uso	Origen T	Inicio objetivo	Fin objetivo	Filas muestra
Ajuste	20-may-2026	21-may-2026	03-jun-2026	204,942
Corte 1	03-jun-2026	04-jun-2026	17-jun-2026	214,202
Corte 2	17-jun-2026	18-jun-2026	01-jul-2026	224,513
Corte 3	01-jul-2026	02-jul-2026	15-jul-2026	232,008
Corte 4	17-ago-2026	18-ago-2026	31-ago-2026	241,199

En cada corte sólo se admiten ejemplos de entrenamiento cuya fecha objetivo sea menor o igual al origen. El estado de ventas, tráfico y promociones se congela en T; el calendario de T+h puede utilizarse porque es conocido de antemano. Los rezagos por día de semana se desplazan a semanas anteriores al origen: para h mayor que siete no se toma una venta que aún no estaba disponible. Es el equivalente a tomar una fotografía del negocio al cierre de T y pronosticar las dos semanas siguientes sin actualizarla con las ventas reales de esas semanas.

Los cuatro cortes son fijos, pero no todos son consecutivos. El salto de julio a agosto responde a la cobertura del histórico documentada en el planteamiento, donde faltan datos del 16 al 31 de julio. La ausencia de archivos se trata como falta de observación y no como ventas cero. En el panel también se diferencia cero comercial de inactividad o falta de datos. El porcentaje de ceros de la muestra común crece de 60.4% a 65.4% entre el primer y cuarto corte.

En atención directa a la observación de la Semana 5 sobre posibles fugas de información en la ventana de 14 días, la auditoría del módulo 21 clasifica las 62 entradas predictoras en cinco grupos estrictamente anclados al origen T: (1) 21 variables de estado de la serie congeladas en T (s_t0, s_ma7, s_ma14, s_ma28, s_ma56, que reemplazan al rezago móvil venta_lag_1 en t−1); (2) 8 variables de tráfico de tienda y contexto zonal congeladas en T (t_ma7, t_ma28, t_tickets_ma7, t_tickets_ma28 y zc_ma7, que

reemplazan a num_tickets_lag_1 en t−1 y eliminan el clima observado t_max_lag1); (3) 13 rezagos del mismo día de la semana anclados en T+h−7k ≤ T (para h=1..7 usan T+h−7 ≤ T y para h=8..14 usan T+h−14 ≤ T, sin leer jamás ventas posteriores a T); (4) 12 variables de calendario determinístico y horizonte h ∈ {1..14} conocidas ex-ante; y (5) 8 atributos estáticos invariantes de tienda y categoría. Complementariamente, la auditoría física del módulo 20 reconstruyó 49 variables —43 numéricas y seis categóricas— en 257,364 filas del origen 3 de junio comparando panel completo y panel truncado en T, encontrando 0 diferencias fuera de la tolerancia definida (sólo 94 diferencias al cuarto decimal por agregación paralela).

Persisten dos límites metodológicos: las cohortes ABC y mapas categóricos se construyen con el histórico disponible completo, por lo que deben versionarse y evaluarse bajo una política temporal explícita. Además, en Theta y TSB el código rellena valores faltantes mediante la media de la serie antes de truncar la historia por origen. Ese orden puede incorporar información futura en la imputación; el efecto no está cuantificado. Sus métricas se conservan como resultados registrados y su comparación definitiva requiere corregir y repetir esa parte del flujo.

2.3 Preparación común y restricciones de entrenamiento

Los modelos de árboles reciben 62 entradas —55 numéricas, incluido el horizonte, y siete categorías codificadas—. Las familias lineales y la red utilizan 114 columnas después de transformaciones y one-hot de categorías seleccionadas, con imputación y escalamiento ajustados en entrenamiento. LightGBM conserva los nulos numéricos admitidos por el algoritmo. Los rezagos semanales largos presentan mayor ausencia: s_lag_dow_4 alcanza 27.30% y s_lag_dow_3, 16.65%; no deben interpretarse como ventas cero.

Las predicciones de los modelos tabulares se acotan a valores no negativos y a un tope de tres veces el cuantil 0.999 del objetivo del entrenamiento efectivo. Los códigos categóricos y la semilla 43 se mantienen comunes. La preparación no es idéntica entre familias: cada algoritmo recibe una representación compatible con su aprendizaje. También difieren las cantidades de ejemplos utilizadas, de modo que el torneo compara soluciones bajo presupuestos computacionales definidos, no una prueba aislada de algoritmos con igual volumen de entrenamiento.

Tabla 5. Alternativas ejecutadas y presupuesto de entrenamiento

Código y algoritmo	Enfoque y función en el torneo	Límite de entrenamiento
M1 Elastic Net	Regresión regularizada; log1p, retransformación y ajuste de escala	1,500,000 filas
M2 GLM Tweedie	Relación multiplicativa con enlace log y distribución Tweedie	400,000 filas
M3 Random Forest	Bagging de árboles para relaciones no lineales	350,000 filas
M4 LightGBM Tweedie	Boosting global directo en pesos; candidato principal	2,000,000 filas
M4b LightGBM Log1p	Control diagnóstico de transformación y corrección Duan	2,000,000 filas

Código y algoritmo	Enfoque y función en el torneo	Límite de entrenamiento
M5 CatBoost Tweedie	Boosting con tratamiento de categorías; retador	1,000,000 filas
M6 Perceptrón multicapa	Red neuronal tabular con variables transformadas	500,000 filas
M8 Theta	Método estadístico de extrapolación por historia de serie	15,740–17,795 historias según corte
M9 TSB	Suavizado de probabilidad y tamaño de demanda intermitente	15,740–17,795 historias según corte
M0 Ingenuo estacional	Repite el mismo día de una semana observable desde T	Referencia, sin ajuste de parámetros

N-HiTS no se ejecutó y XGBoost sólo aparece como dependencia instalada: ninguno aporta resultados al torneo. La ejecución registra LightGBM 4.7.0, CatBoost 1.2.10, XGBoost 3.4.1, StatsForecast 2.1.1 y scikit-learn 1.7.2. La presencia de una librería no acredita un modelo construido. El tiempo total registrado del módulo de modelado es 386.9 minutos, aproximadamente 6.45 horas; no se adopta la estimación de 15–25 minutos escrita en un comentario del código.

2.4 Métricas y criterio de agregación

El WMAPE se calcula como suma de errores absolutos dividida entre la suma de ventas reales: $\Sigma|y-\hat{y}| / \Sigma y$. Así, un WMAPE de 0.4562 representa aproximadamente 45.62 pesos de desviación absoluta por cada 100 pesos vendidos, en promedio por corte; no significa 54.38% de exactitud ni mide error porcentual de cada tienda por separado. Pondera más las observaciones con mayor contribución monetaria y puede ocultar el desempeño de series pequeñas.

El sesgo se calcula como $\Sigma\hat{y} / \Sigma y - 1$. Un valor negativo indica subestimación neta; uno positivo, sobreestimación. MAE expresa la desviación media en pesos por ejemplo, mientras RMSE penaliza con mayor intensidad los errores grandes. Sus versiones relativas dividen cada métrica por la de la referencia en la misma población: valores menores que uno favorecen al candidato. Para ventas con ceros y valores positivos asimétricos, el objetivo Tweedie con potencia 1.5 admite una masa en cero y una parte continua positiva; se puede entender como modelar conjuntamente la ocurrencia y el importe acumulado de ventas, sin convertir la venta en un conteo entero [1, 6].

La cifra principal es la media aritmética de los cuatro WMAPE calculados por corte. Su desviación describe variación entre cortes; no es un intervalo de confianza. Las tablas por horizonte, región o día agrupan sumas de error y venta en cada segmento, por lo que sus valores no deben promediarse sin ponderación para reconstruir la cifra principal. La mejora relativa se obtiene como 1 − WMAPE_modelo / WMAPE_ingenuo.

La prueba Diebold–Mariano del notebook compara pérdidas agregadas por fecha. Los valores impresos como 0.000 se reportan como $p < 0.001$ a la precisión mostrada, nunca como probabilidad cero. Al haberse reutilizado los cuatro cortes para seleccionar candidatos y valorar el resultado final, son evidencia de desarrollo y comparación temporal, no un test final intocado. Un único valor p agregado tampoco demuestra la condición del plan de significancia en al menos tres de cuatro cortes [2, 5].

SECCIÓN 3. Resultados comparativos y selección de los dos finalistas

3.1 Desempeño en la muestra común

Tabla 6. Comparación de candidatos en cuatro cortes de la muestra común

Candidato	WMAPE	Desv.	Mejora vs. ingenuo	Sesgo	RMSE relativo
LightGBM Tweedie	0.4503	0.0038	18.11%	−0.08%	0.7741
LightGBM Log1p + Duan	0.4520	0.0025	17.80%	−7.61%	0.8458
CatBoost Tweedie	0.4582	0.0037	16.67%	−0.03%	0.7830
Elastic Net	0.4677	0.0117	14.94%	−15.06%	0.9164
Theta*	0.4688	0.0128	14.75%	+0.64%	0.8044
Random Forest	0.4691	0.0023	14.69%	+4.02%	0.7679
GLM Tweedie	0.4828	0.0077	12.20%	−0.44%	0.8297
Perceptrón multicapa	0.5282	0.0865	3.94%	−0.99%	0.9921
Ingenuo estacional	0.5499	0.0215	0.00%	−0.97%	1.0000
TSB*	0.5845	0.0151	−6.29%	−3.25%	1.0577

* Theta y TSB conservan la cautela de imputación descrita en 2.2. Las cifras se transcriben de las salidas registradas. La tabla ordena las alternativas utilizadas en la decisión; el control Log1p sin corrección se analiza por separado y tiene menor WMAPE que M4, con un sesgo mucho más negativo.

LightGBM Tweedie combina menor WMAPE que el resto de candidatos de decisión con sesgo cercano a cero. Random Forest obtiene el menor RMSE relativo de la muestra entre estas alternativas, pero tiene mayor WMAPE y sobreestimación de 4.02%. Elastic Net ofrece simplicidad y una brecha de entrenamiento pequeña, aunque subestima 15.06%. Theta presenta un resultado competitivo con costo bajo, sujeto a la corrección temporal indicada. TSB empeora frente al ingenuo; la intermitencia del panel no basta para que un método especializado gane en una métrica monetaria ponderada.

El perceptrón es inestable: su WMAPE cambia de 0.4510 en el tercer corte a 0.6513 en el segundo. Su mejora media es pequeña y la prueba DM contra la referencia arroja $p = 0.5663$. Por ello no hay evidencia de superioridad estadística en esa comparación. Las demás salidas muestran $p < 0.001$, pero en TSB una diferencia significativa indica peor desempeño; significancia no equivale a utilidad.

Tabla 7. WMAPE por corte en la muestra común

Candidato	C1	C2	C3	C4
LightGBM Tweedie	0.4492	0.4513	0.4458	0.4549
LightGBM Log1p + Duan	0.4511	0.4491	0.4529	0.4551
CatBoost Tweedie	0.4554	0.4568	0.4570	0.4637
Elastic Net	0.4590	0.4705	0.4831	0.4583
Theta	0.4642	0.4718	0.4847	0.4544
Random Forest	0.4665	0.4712	0.4710	0.4678
GLM Tweedie	0.4754	0.4786	0.4844	0.4928
Perceptrón multicapa	0.5164	0.6513	0.4510	0.4941
Ingenuo	0.5590	0.5361	0.5757	0.5287
TSB	0.5763	0.5673	0.5972	0.5971

3.2 Transformación logarítmica, sesgo y comparación en pesos reales

El control Log1p responde a una pregunta pendiente de Semana 5: ¿una transformación que estabiliza la variación también conserva el nivel esperado de ventas al volver a pesos? Como la exponencial es convexa, invertir una predicción del promedio logarítmico no recupera en general el promedio monetario. La desigualdad de Jensen explica el riesgo de subestimación, pero no determina por sí sola el sesgo exacto de cada modelo ajustado. La salida denomina Duan al factor aplicado, pero el código lo calcula como la razón entre suma real y suma pronosticada en una muestra de entrenamiento. Es una corrección agregada de escala; no implementa el estimador clásico de smearing mediante residuos [1, 9].

Tabla 8. Control Log1p frente a Tweedie en la misma muestra y cortes

Formulación	Factor medio	WMAPE	Sesgo	MAE MXN	RMSE MXN
Log1p con expm1 directo	1.0000	0.4345	−24.38%	119.68	893.31
Log1p con corrección Duan	1.2218	0.4520	−7.61%	124.48	873.04
Tweedie en escala natural	1.0000	0.4503	−0.08%	124.02	798.62

La formulación Log1p directa tiene el menor WMAPE de este control, pero pronostica aproximadamente 24.4% menos venta total. Duan reduce esa subestimación a 7.6% y aumenta el WMAPE. Tweedie logra el

mejor RMSE de las tres y sesgo prácticamente neutro. La selección de Tweedie se sostiene en el equilibrio entre error absoluto, riesgo de errores grandes y nivel agregado; sería incorrecto afirmar que vence a Log1p en todas las métricas. Tampoco se presenta Duan como eliminación completa del sesgo ni como una elasticidad comercial.

3.3 Horizonte y calendario en la muestra común

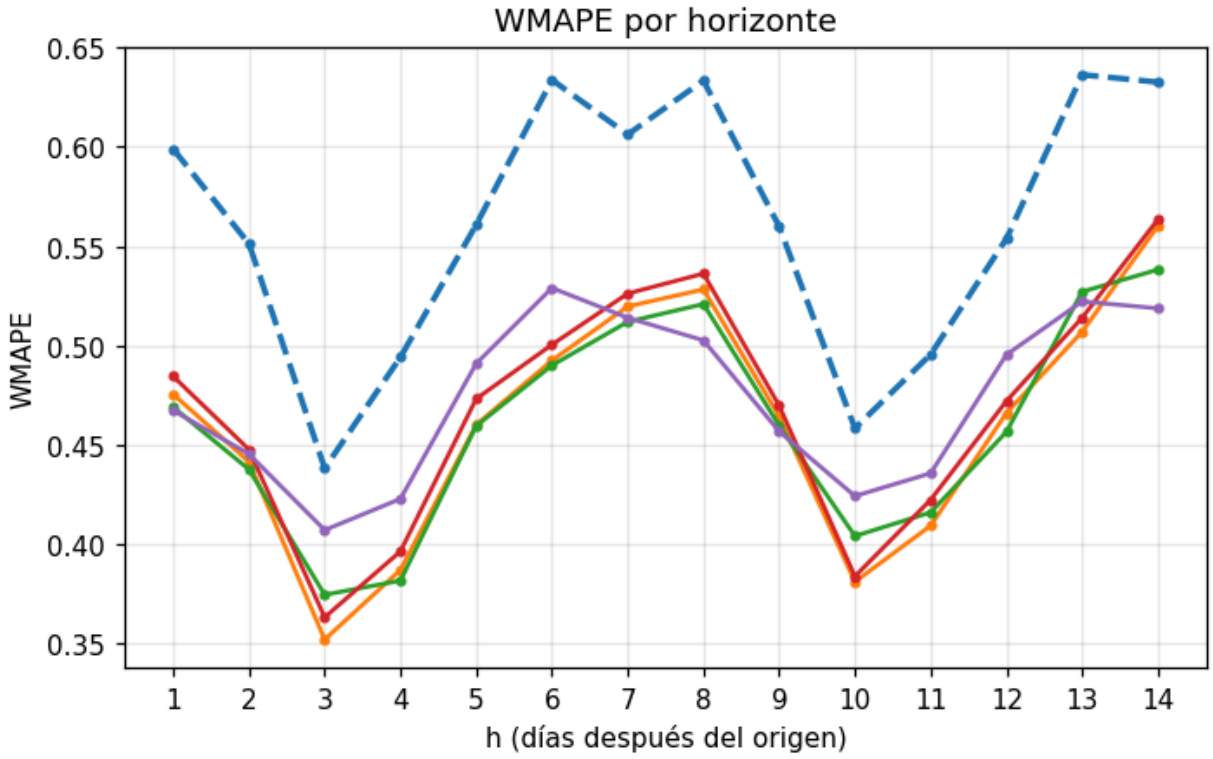


Figura 1a. WMAPE por horizonte en la muestra común. Fuente: módulo 21, salida 5; panel extraído.

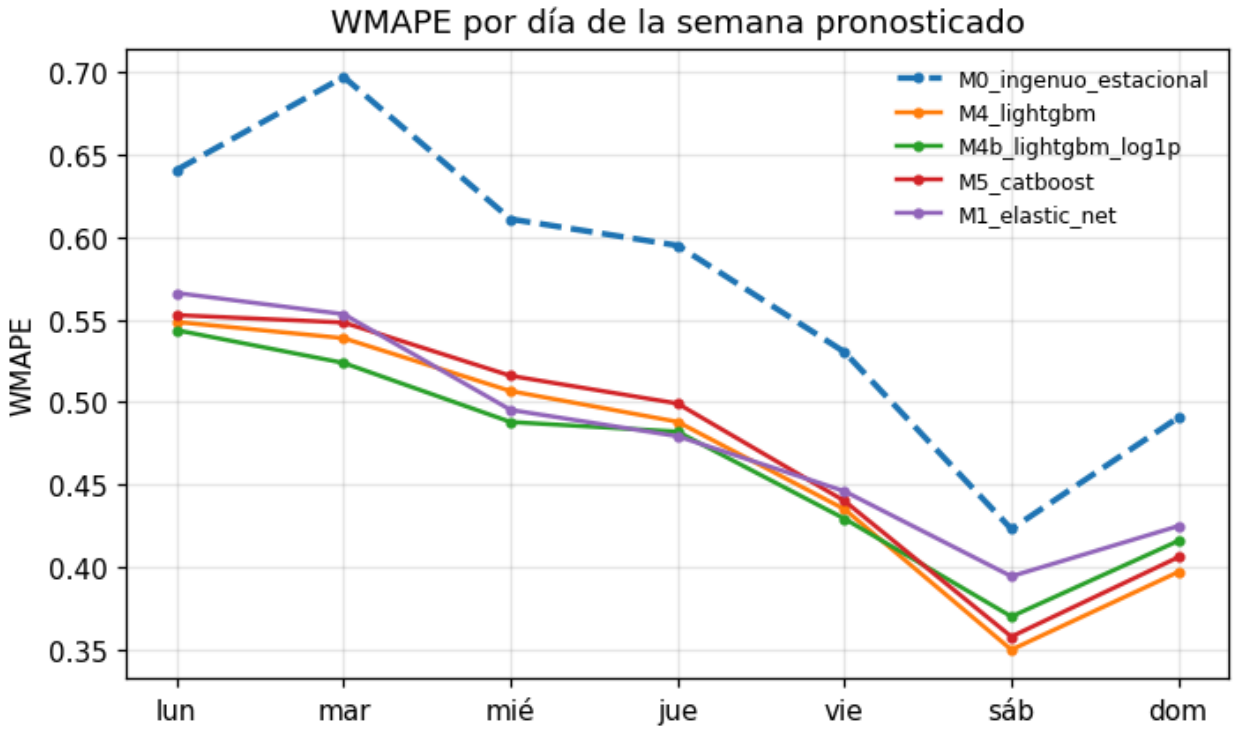


Figura 1b. WMAPE por día de semana en la muestra común. Fuente: módulo 21, salida 5; panel extraído.

El panel 1a compara los catorce horizontes; el panel 1b compara los días objetivo y muestra la leyenda común. La línea discontinua es el ingenuo. LightGBM Tweedie mejora la referencia en todos los horizontes de esta muestra: pasa de 0.4755 en h1 a 0.5603 en h14, frente a 0.5989 y 0.6326 del ingenuo. La curva no crece de forma monótona: el calendario y la composición de ventas influyen junto con la distancia al origen. En el panel 1b, el sábado tiene WMAPE 0.3496 y el lunes 0.5485; el beneficio de los modelos también existe entre semana, donde la referencia es más débil. La figura precede a la evaluación ampliada y sus cifras no deben intercambiarse con las de 5.3.

3.4 Justificación de los finalistas y recursos utilizados

Se eligen LightGBM Tweedie y CatBoost Tweedie. La variante M4b se excluye del paso de finalistas por su función diagnóstica, evitando afinar dos formulaciones de la misma implementación LightGBM. Así, CatBoost es el siguiente candidato de decisión con mejor WMAPE y sesgo cercano a cero. Ambos son implementaciones de boosting; su selección no implica dos familias algorítmicas amplias distintas ni resuelve la condición académica de algoritmos sin ensamble.

Tabla 9. Costo observado del torneo base y diagnóstico de entrenamiento

Candidato	Train WMAPE	Brecha val−train	Entrena 4 cortes min	Infiere muestra s
LightGBM Tweedie	0.3534	0.0969	31.0	48.0

Candidato	Train WMAPE	Brecha val−train	Entrena 4 cortes min	Infiere muestra s
LightGBM Log1p + Duan	0.3910	0.0610	29.2	26.7
CatBoost Tweedie	0.3558	0.1024	37.9	12.4
Elastic Net	0.4427	0.0250	7.4	0.4
Theta	No calculado	No calculada	3.3	0.5
Random Forest	0.3591	0.1100	17.3	7.5
GLM Tweedie	0.4008	0.0819	8.1	5.5
Perceptrón multicapa	0.4066	0.1216	18.0	5.4
TSB	No calculado	No calculada	0.3	0.4

Los tiempos corresponden al entorno de la corrida, no a una promesa de latencia productiva ni a importes de Azure. CatBoost infiere la muestra más rápido que LightGBM, aunque tarda más en entrenar. Los límites diferentes de filas de entrenamiento condicionan esta comparación. Para evaluar costos monetarios se necesitan tipo de cómputo, uso y tarifas; el notebook no entrega esa conciliación.

SECCIÓN 4. Ajuste de hiperparámetros y diagnóstico de generalización

4.1 Diseño de la búsqueda y presupuesto completado

Se utiliza el origen 20 de mayo, anterior al primer corte del torneo, con hasta 800,000 ejemplos de entrenamiento y 204,942 de validación. Se solicita minimizar WMAPE con Optuna, semilla 43, un máximo de 25 pruebas y 25 minutos por finalista. La configuración inicial se evalúa como referencia y se conserva si ninguna prueba la supera. El planteamiento había propuesto afinar sobre el primer corte; la ejecución utiliza un origen anterior, lo que separa el ajuste de parámetros de esas ventanas, aunque los finalistas ya fueron elegidos utilizando los cuatro cortes.

Tabla 10. Espacios de hiperparámetros explorados

Familia	Parámetros	Rangos o alternativas
LightGBM	Potencia Tweedie; árboles; tasa de aprendizaje	1.1–1.9; 200–1,200; 0.015–0.15
LightGBM	Hojas; mínimo de ejemplos por hoja	15–191; 50–2,000
LightGBM	Submuestra filas y columnas	0.5–1.0 para ambas
LightGBM	Penalizaciones L1 y L2; max_bin	0–10; 63, 127 o 255

Familia	Parámetros	Rangos o alternativas
CatBoost	Potencia Tweedie; iteraciones; tasa	1.1–1.9; 200–900; 0.02–0.18
CatBoost	Profundidad; penalización L2	4–9; 1–30
CatBoost	bagging_temperature; random_strength	0–1; 0–5
CatBoost	one_hot_max_size	2–64

Tabla 11. Resultado efectivo de la afinación en el origen de ajuste

Finalista	Pruebas	Minutos	WMAPE inicial	WMAPE retenido	Mejora
LightGBM	7	28.3	0.4657	0.4657	0.0%
CatBoost	4	27.1	0.4743	0.4743	0.0%

Las duraciones superan ligeramente el límite solicitado porque el timeout no interrumpe una prueba que ya está en curso, completándose siete pruebas en LightGBM y cuatro en CatBoost dentro del tiempo asignado. Cabe destacar que la configuración inicial evaluada como referencia (500 árboles, tasa 0.05, 63 hojas, mínimo 200 ejemplos por hoja, submuestreo de 0.8 y regularización L2 de 1.0 con potencia Tweedie 1.5) no corresponde a los hiperparámetros crudos de fábrica de las librerías (100 árboles, 31 hojas, 20 ejemplos por hoja y sin regularización), sino a una parametrización ya pre-regularizada para demanda minorista con alta proporción de ceros. Debido a ello, y a que el muestreador TPE inicia con ocho pruebas exploratorias aleatorias antes de su fase adaptativa, ninguna de las combinaciones iniciales superó a la parametrización base pre-calibrada, garantizando mediante su retención un ajuste monótonamente no degradante [10].

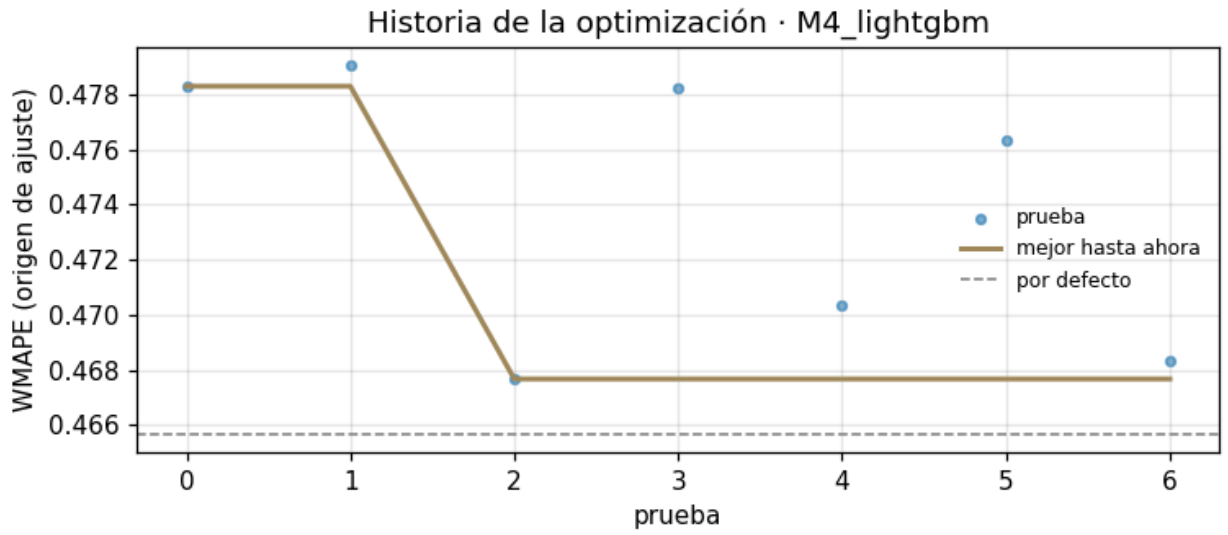


Figura 2. Historia de optimización de LightGBM. Fuente: módulo 21, salida 7.

Cada punto representa una prueba y la línea continua conserva el mejor resultado encontrado entre las pruebas. La línea discontinua marca la configuración inicial, 0.4657. Aunque la búsqueda mejora respecto a sus primeras propuestas, su mejor prueba permanece por encima de esa referencia; por ello se conserva la configuración inicial. Los índices de cero a seis corresponden a siete pruebas. La figura muestra el origen de ajuste y no el promedio de los cuatro cortes.

La tabla de importancia de hiperparámetros de la salida atribuye 19.8% a colsample_bytree, 17.3% a learning_rate, 15.2% a la potencia Tweedie y 14.2% a reg_alpha. Estas participaciones dependen de las pocas combinaciones exploradas y no deben tratarse como efectos causales ni como un ranking estable de oportunidades de mejora.

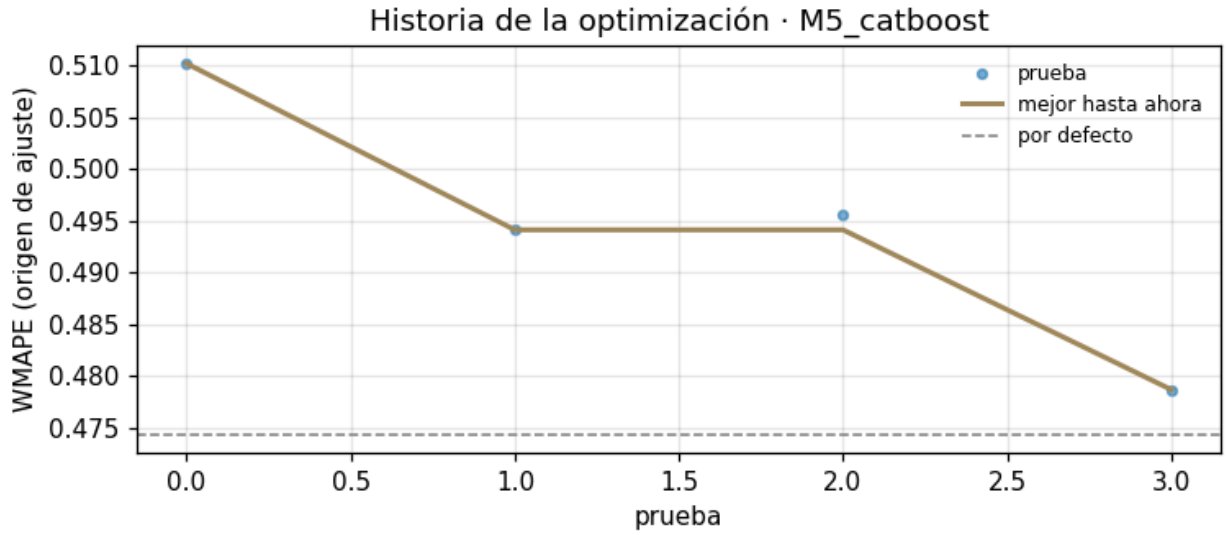


Figura 3. Historia de optimización de CatBoost. Fuente: módulo 21, salida 9.

Las cuatro pruebas reducen el mejor error observado desde aproximadamente 0.510 hasta 0.479, pero ninguna baja de la línea discontinua de la configuración inicial, 0.4743. La mejora entre propuestas de

búsqueda no es mejora respecto al modelo inicial. El resultado confirma por qué el procedimiento retiene los parámetros iniciales y reporta ganancia de 0.0%.
La importancia exploratoria de hiperparámetros de CatBoost asigna 29.2% a random_strength, 23.4% a bagging_temperature, 17.9% a variance_power y 16.0% a l2_leaf_reg. Con sólo cuatro pruebas, las proporciones son especialmente sensibles a las combinaciones probadas; sirven para documentar la búsqueda, no para certificar sensibilidad estable del modelo.

4.2 Configuraciones retenidas y evaluación posterior

Tabla 12. Configuraciones finales observadas

Parámetro	LightGBM Tweedie	CatBoost Tweedie
Objetivo	tweedie, potencia 1.5	Tweedie:variance_power=1.5
Árboles o iteraciones	500	400
Tasa de aprendizaje	0.05	0.08
Estructura	63 hojas; mínimo 200 ejemplos por hoja	Profundidad 8
Submuestreo	Filas 0.8; frecuencia 1; columnas 0.8	Parámetros iniciales conservados
Regularización	reg_lambda=1.0	l2_leaf_reg=3.0
Semilla	43	43

Al reevaluar los cuatro cortes de la muestra común, LightGBM permanece en 0.4503 y CatBoost en 0.4582, tanto con etiqueta inicial como con etiqueta ajustada. “Ajustado” identifica el resultado del proceso de búsqueda, no un cambio efectivo de hiperparámetros. La duplicación de métricas es coherente con conservar los valores iniciales y no debe presentarse como una ganancia adicional atribuible al tuning.

4.3 Curva de aprendizaje y brechas de generalización

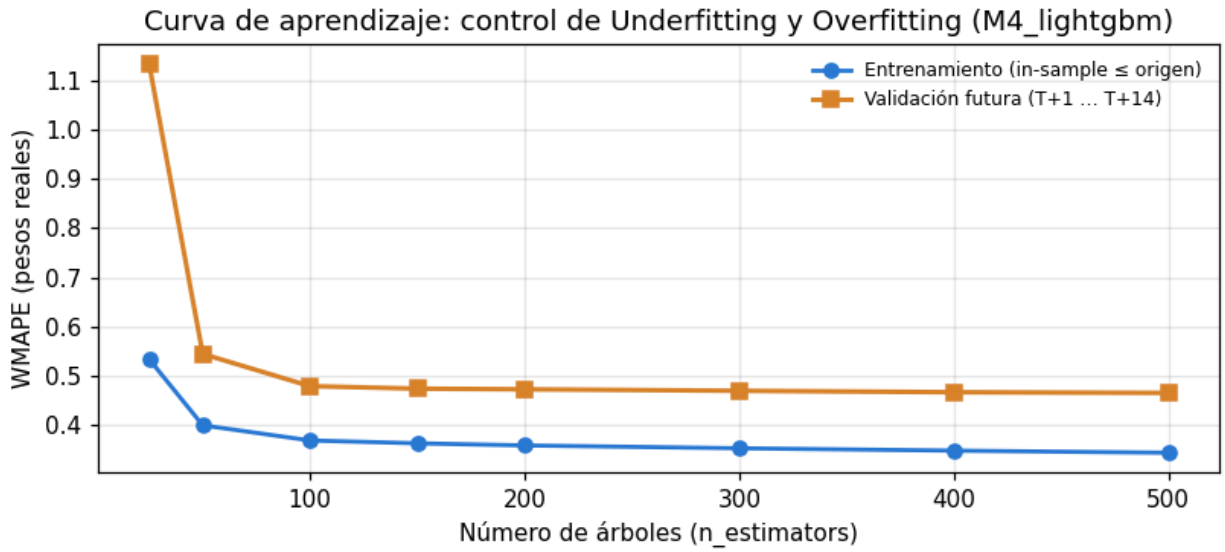


Figura 4. WMAPE de entrenamiento y validación por número de árboles de LightGBM. Fuente: módulo 21, salida 11.

En el origen de ajuste, el WMAPE de validación cae de 1.1332 con 25 árboles a 0.4794 con 100 y 0.4657 con 500. El entrenamiento baja de 0.5342 a 0.3444. No se observa repunte final de validación en los puntos medidos, pero la brecha a 500 árboles es 0.1213, equivalente a 12.13 puntos de WMAPE. Una curva descendente no demuestra ausencia de sobreajuste: existe una diferencia de generalización que debe mantenerse bajo vigilancia. La figura utiliza el origen de ajuste y no la media del torneo.

Tabla 13. Puntos de la curva de aprendizaje temporal

Árboles	WMAPE train	WMAPE validación	Brecha
25	0.5342	1.1332	0.5990
50	0.4001	0.5447	0.1447
100	0.3693	0.4794	0.1101
150	0.3636	0.4744	0.1108
200	0.3593	0.4730	0.1138
300	0.3535	0.4700	0.1165
400	0.3487	0.4672	0.1184
500	0.3444	0.4657	0.1213

En el torneo, la brecha media LightGBM es 0.0969 y la de CatBoost 0.1024. El WMAPE de entrenamiento tabular se mide sobre hasta 200,000 filas del entrenamiento utilizado, no sobre todo el

histórico. La estabilidad de sus WMAPE entre cortes es favorable, pero mide una propiedad diferente de la distancia entre entrenamiento y validación. El diagnóstico automático del notebook usa reglas heurísticas; sus etiquetas no prueban la causa del error y algunas no corresponden al algoritmo, como la referencia a hojas en GLM. Por ello se reportan métricas observadas y señales de capacidad, sin certificar ausencia de sobreajuste ni atribuir la inestabilidad del perceptrón exclusivamente a falta de capacidad.

SECCIÓN 5. Evaluación ampliada, decisión final y explicabilidad

5.1 Resultado en todas las filas evaluables

Tabla 14. WMAPE por corte en la evaluación ampliada

Modelo	C1	C2	C3	C4	Media	Desv.
LightGBM	0.4553	0.4576	0.4508	0.4611	0.4562	0.0043
CatBoost	0.4606	0.4637	0.4609	0.4696	0.4637	0.0042
Ingenuo	0.5566	0.5448	0.5764	0.5344	0.5530	0.0180

LightGBM supera al ingenuo en los cuatro cortes ampliados y reduce el WMAPE medio en 0.0968, aproximadamente 9.68 puntos, o 17.5% en términos relativos. El MAE relativo es 0.825 y el RMSE relativo 0.792; CatBoost obtiene 0.838 y 0.800. El resultado de 0.4562 está dentro de la meta orientativa 0.42–0.46 del planteamiento, aunque el cuarto corte por sí solo marca 0.4611. La meta global no asegura homogeneidad por horizonte o segmento.

El sesgo medio ampliado es +0.48% en LightGBM, +0.65% en CatBoost y −0.75% en el ingenuo. El valor ampliado de LightGBM difiere del −0.08% de la muestra común porque cambia la población. Los sesgos por corte de la muestra LightGBM —+1.4%, −1.1%, −1.6% y +1.0%— se encuentran dentro de ±3%; esa comprobación no sustituye publicar el mismo control por corte para toda la evaluación ampliada.

5.2 Matriz de decisión y elección del candidato

La matriz combina siete criterios. Para métricas donde menor es mejor, normaliza mediante el mejor valor observado dividido entre el valor del candidato; para interpretabilidad y compatibilidad usa puntuaciones relativas asignadas en el código. Después aplica las ponderaciones de la tabla. El resultado es una regla de decisión explícita, no una probabilidad de éxito ni un puntaje académico.

Tabla 15. Criterios y valores de la decisión entre finalistas

Criterio	Peso	LightGBM	CatBoost
WMAPE ampliado	35%	0.4562	0.4637
Estabilidad, desviación	10%	0.0043	0.0042
Sesgo absoluto medio	10%	0.48%	0.65%
Error entre semana y h8–14*	10%	0.4863	0.4929
Tiempo medio train + inferencia, s**	10%	489.7	572.9
Interpretabilidad asignada	10%	0.70	0.70
Compatibilidad asignada	15%	1.00	1.00
Puntaje ponderado total	100%	0.9968	0.9515

* Promedio de WMAPE entre semana y WMAPE de horizontes 8–14. **Costo calculado con tiempos medios de los ajustes en la muestra; no incluye todo el costo de preparación ni toda la inferencia ampliada. Esta última tarda 15.1 minutos en LightGBM y 1.9 en CatBoost para los cuatro cortes. Por tanto, CatBoost tiene una ventaja de inferencia que debe considerarse al dimensionar la operación, aunque no gane la matriz actual.

Se selecciona LightGBM Tweedie por menor error ampliado, sesgo reducido, estabilidad cercana a CatBoost y menor tiempo de entrenamiento observado. CatBoost queda como retador. La comparación DM entre finalistas imprime $p = 0.000$, expresado aquí como $p < 0.001$; se calcula sobre las predicciones de la muestra común y no constituye un contraste separado por cada corte ampliado. La decisión técnica es defendible dentro del experimento y permanece sujeta a las reservas de independencia temporal y cumplimiento académico ya señaladas.

5.3 Dónde acierta y dónde falla el modelo seleccionado

El análisis siguiente utiliza la evaluación ampliada, agrega las pérdidas por segmento y evita extrapolar un buen promedio a toda la operación. LightGBM mejora al ingenuo 17.8% entre semana y 16.8% en fin de semana; la reducción es 18.8% en h1–7 y 16.0% en h8–14. Los WMAPE agregados entre semana y h8–14 son 0.5022 y 0.4703, frente a 0.6113 y 0.5608 del ingenuo.

Tabla 16. Resultado ampliado por horizonte

h	WMAPE modelo	WMAPE ingenuo	Mejora relativa	Sesgo
1	0.4762	0.5833	18.4%	−3.2%
2	0.4447	0.5455	18.5%	−3.3%
3	0.3609	0.4411	18.2%	−1.1%

h	WMAPE modelo	WMAPE ingenuo	Mejora relativa	Sesgo
4	0.3974	0.4991	20.4%	−6.6%
5	0.4634	0.5666	18.2%	−4.2%
6	0.4967	0.6531	23.9%	+1.0%
7	0.5248	0.6089	13.8%	+2.6%
8	0.5193	0.6246	16.9%	+6.2%
9	0.4603	0.5554	17.1%	+2.2%
10	0.3906	0.4649	16.0%	+5.8%
11	0.4350	0.5074	14.3%	+6.3%
12	0.4701	0.5672	17.1%	−2.5%
13	0.5043	0.6357	20.7%	−2.9%
14	0.5711	0.6351	10.1%	+9.6%

El horizonte 14 es el más débil: WMAPE 0.5711 y sobreestimación de 9.6%. También exceden ±3% los sesgos de h1, h2, h4, h5, h8, h10 y h11. El sesgo global cercano a cero resulta de compensaciones y no garantiza ausencia de exceso o faltante en decisiones específicas. Antes de utilizar estos pronósticos para reabasto deben revisarse calibración por horizonte y reglas de inventario; una mejora relativa positiva no vuelve aceptable cualquier error absoluto.

Tabla 17. Resultado ampliado por día de semana

Día	WMAPE modelo	WMAPE ingenuo	Mejora	Sesgo
Lunes	0.5570	0.6505	14.4%	+2.9%
Martes	0.5372	0.6969	22.9%	−2.2%
Miércoles	0.5120	0.6097	16.0%	+0.9%
Jueves	0.4853	0.5920	18.0%	+0.3%
Viernes	0.4349	0.5284	17.7%	−2.0%
Sábado	0.3559	0.4275	16.8%	+1.2%
Domingo	0.4143	0.4980	16.8%	+1.7%

El patrón semanal reproduce el hallazgo de la figura 1: sábado es más predecible en proporción a sus ventas y lunes conserva mayor error. La mayor mejora relativa ocurre el martes, 22.9%, porque el ingenuo parte de un desempeño más débil. Esto orienta el seguimiento comercial hacia días donde la comparación histórica simple funciona peor, sin confundir mayor mejora relativa con menor error final.

Tabla 18. Resultado ampliado por tipo de categoría

Tipo	Filas	WMAPE modelo	WMAPE ingenuo	Mejora	Sesgo
Genérico	536,371	0.2944	0.3474	15.3%	+0.4%
Mercancía	27,912,186	0.4174	0.5060	17.5%	+0.5%
Servicio	2,022,813	0.9141	1.1138	17.9%	−0.1%

Mercancía supera el umbral del plan de 0.506 y representa la mayor parte de las filas. Servicio conserva WMAPE muy elevado pese a su mejora relativa. El planteamiento excluía pronosticar servicios de Arcadial, pero el resultado actual sí incluye el segmento servicio. Se registra esta desviación de alcance y debe reconciliarse el catálogo antes de aprobar la compuerta; el 0.4562 global no debe etiquetarse como resultado exclusivo de mercancía.

Tabla 19. Resultado ampliado por región

Región	WMAPE modelo	WMAPE ingenuo	Mejora	Sesgo
Noroeste	0.4336	0.5204	16.7%	−0.5%
Sureste	0.4325	0.5341	19.0%	+0.6%
Noreste	0.4941	0.5938	16.8%	+1.7%
Sin región	0.4492	0.5422	17.2%	+1.6%
Centro	0.6193	0.7696	19.5%	+1.2%
Occidente	0.5840	0.7127	18.1%	+1.2%

Centro y Occidente requieren atención por sus errores absolutos, 0.6193 y 0.5840, aun cuando mejoran al ingenuo. La categoría geográfica Sin región contiene 3,978,413 ejemplos y debe conservarse visible como pendiente de catálogo. Los días marcados atípicos tienen WMAPE 0.3662 frente a 0.4727 de referencia, sobre 973,085 filas; los normales, 0.4605 frente a 0.5569, sobre 29,498,285. Su menor error no prueba causalidad de eventos: las poblaciones y niveles de venta pueden diferir.

5.4 Importancia de variables y continuidad con Semana 5

La Semana 5 reportó concentración de Gain en promedios y rezagos de ventas. El nuevo experimento conserva ese predominio de historia, pero incorpora dos lecturas complementarias: frecuencia de partición y SHAP. Gain mide reducción acumulada de la función objetivo; Splits cuenta uso en nodos; SHAP distribuye contribuciones a la predicción bajo el modelo y la muestra explicada. Ninguna de ellas identifica por sí sola causalidad de promociones o precios [1, 11].

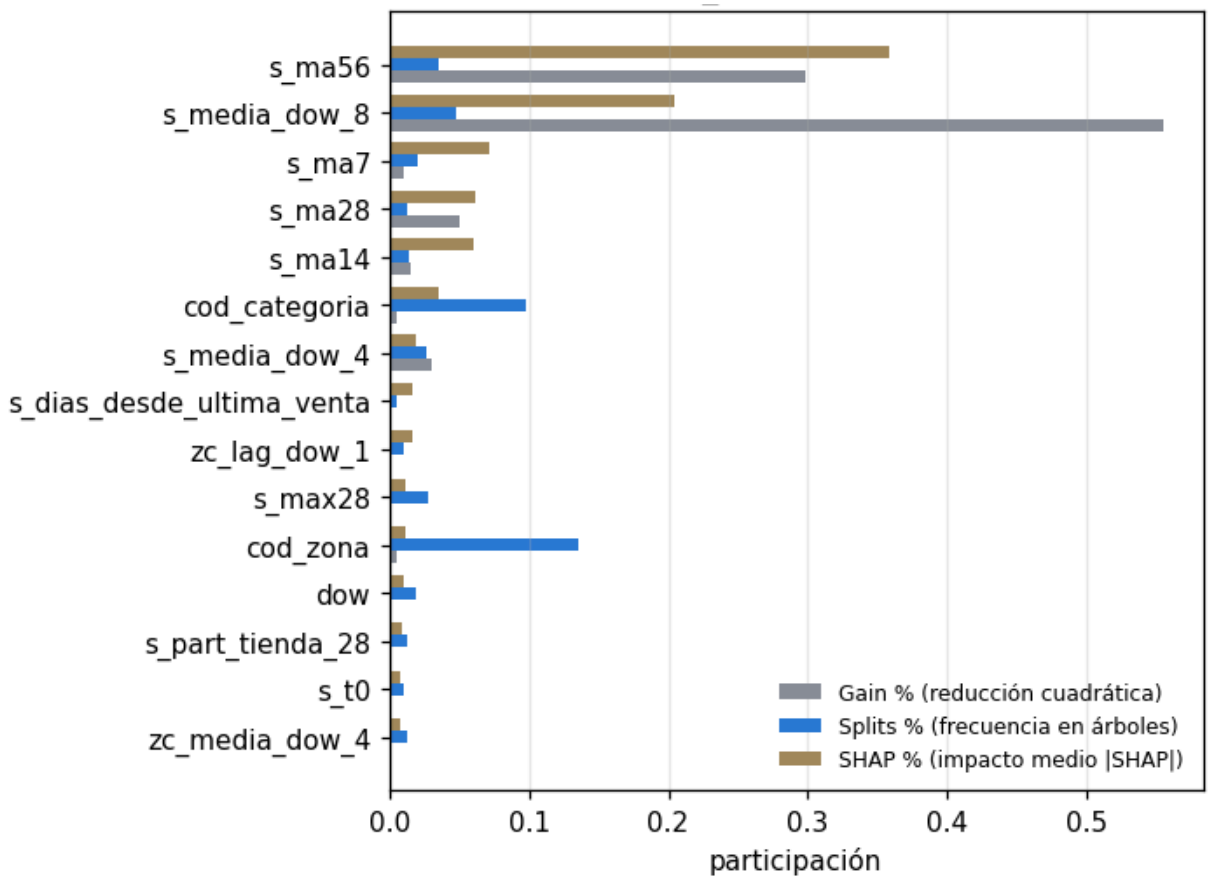


Figura 5a. Top 15 variables por Gain, Splits y SHAP. Fuente: módulo 21, salida 20; panel extraído.

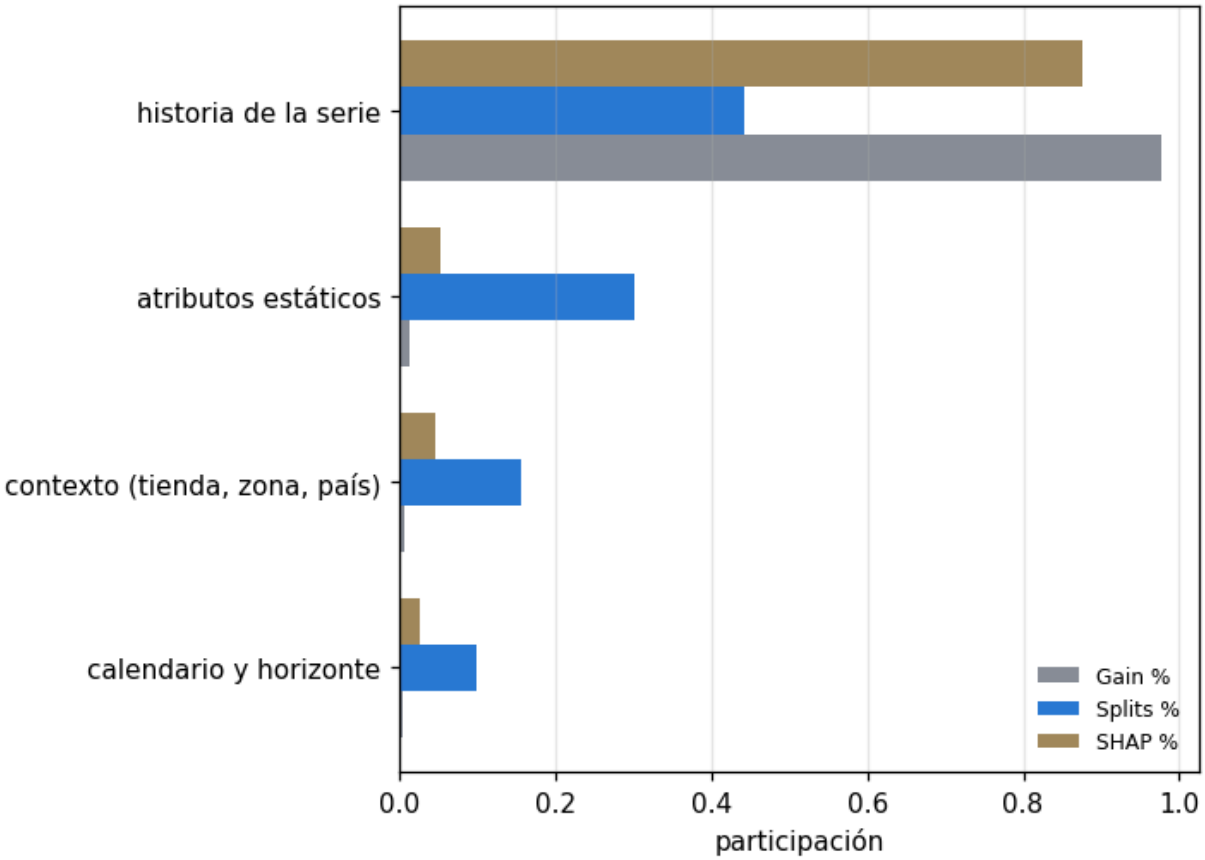


Figura 5b. Importancia por familias mediante Gain, Splits y SHAP. Fuente: módulo 21, salida 20; panel extraído.

El panel 5a muestra quince variables destacadas y el panel 5b las familias; la tabla de salida del notebook enumera veinte. s_media_dow_8, s_ma56 y s_ma28 acumulan 90.4% de Gain, 9.6% de Splits y 62.5% de SHAP. La concentración depende de la medida: atributos estáticos participan mucho en particiones pero tienen menor participación de importancia SHAP. SHAP se calcula con TreeExplainer sobre una muestra de 20,000 filas; estas proporciones describen esa explicación, no toda la población ni una prueba de generalización. La leyenda de Gain alude a reducción cuadrática, pero el estimador utiliza pérdida Tweedie; se interpreta Gain conforme a esa función objetivo.

Tabla 20. Variables principales del modelo final

Variable	Gain %	Splits %	SHAP %
s_ma56	29.80	3.54	35.90
s_media_dow_8	55.58	4.79	20.41
s_ma7	1.02	2.02	7.09
s_ma28	5.00	1.22	6.18
s_ma14	1.54	1.41	6.07

Variable	Gain %	Splits %	SHAP %
cod_categoria	0.50	9.78	3.55
s_media_dow_4	3.06	2.58	1.83
s_dias_desde_ultima_venta	0.02	0.50	1.63
zc_lag_dow_1	0.06	0.95	1.58
s_max28	0.13	2.71	1.16

Tabla 21. Importancia por familia de variables

Familia	Gain %	Splits %	SHAP %
Historia de la serie	97.7	44.2	87.6
Atributos estáticos	1.3	30.2	5.3
Contexto de tienda, zona y país	0.6	15.7	4.6
Calendario y horizonte	0.4	9.9	2.5

El 37.5% de SHAP que queda fuera de las tres variables principales incluye otras variables históricas: no corresponde exclusivamente a calendario, contexto y atributos. En conjunto, la historia de la propia serie concentra 87.6% de SHAP. La lectura de negocio es que el nivel reciente y el patrón semanal sostienen gran parte del pronóstico; los atributos y contexto lo modulan. El nuevo conjunto no incluye las variables climáticas observadas usadas en el baseline antiguo. Su ausencia impide atribuir la mejora actual a clima o a INEGI.

5.5 Registro, trazabilidad y límite de la entrega MLOps

El reentrenamiento final utiliza una muestra de 2,000,000 de filas del histórico de entrenamiento cargado, no todas las filas originales. Tarda 7.9 minutos y registra WMAPE de entrenamiento 0.3590. Ese objeto final es distinto de los modelos ajustados por corte y su métrica de entrenamiento no sustituye el backtesting. Las salidas confirman un run de MLflow y el registro modeladoprescriptivoventas.maestria.demanda_categoria, versión 1, alias challenger.

El intento de fijar el experimento compartido /Shared/mna_equipo43/avance4_torneo produjo RestException y el flujo continuó en el experimento de la libreta. El registro final sí se reporta completado. Se documenta esa ruta alternativa para no afirmar que todas las corridas quedaron necesariamente en el experimento compartido previsto. La repetición reproducible requiere fijar además la versión exacta de Delta, el orden y selección de muestras, mapas categóricos, parámetros, dependencias y el tope de predicción.

Tabla 22. Artefactos y resultados registrados por el flujo actual

Recurso del esquema maestria	Contenido registrado
gold_features_origen; gold_calendario	Ejemplos por origen y horizonte; calendario conocido
mlops_oro_resumen; mlops_hallazgos	Conteos, reconstrucción de referencia y conclusiones de ejecución
mlops_torneo_modelos; mlops_torneo_predicciones_muestra	Métricas por candidato y corte; predicciones de la muestra común
mlops_comparativa_log1p_tweedie	Error y sesgo de las tres formulaciones monetarias
mlops_diagnostico_generalizacion	Métricas de entrenamiento y brechas observadas
mlops_ajuste_fino_pruebas	Pruebas, tiempos y parámetros explorados
mlops_evaluacion_completa; mlops_decision_modelo_final	Resultados ampliados y matriz de decisión
mlops_importancia_variables	Gain, Splits y SHAP
demanda_categoria, versión 1, challenger	Modelo candidato registrado en Unity Catalog

Las salidas acreditan escrituras históricas de estos recursos; la entrega documental no ejecuta una nueva consulta sobre sus contenidos vivos. El notebook lee la tabla vigente y no registra versionAsOf, por lo que falta vincular de manera explícita el resultado a un snapshot Delta. También debe verificarse que el paquete de inferencia incorpore mapas categóricos y postproceso, además del estimador. Registrar el modelo no acredita todavía un pipeline programado, promoción, rollback, servicio de consulta ni pronósticos futuros publicados.

SECCIÓN 6. Conclusiones y ruta de aceptación del siguiente avance

6.1 Aprendizajes y decisión de la Semana 6

La comparación muestra que una pérdida compatible con ventas no negativas y asimétricas puede ofrecer un equilibrio comercial más útil que elegir sólo el WMAPE mínimo. LightGBM Tweedie mantiene error estable entre ventanas, reduce desviaciones grandes frente a las formulaciones Log1p y limita el sesgo agregado. CatBoost es un retador sólido y más rápido en inferencia; se conserva como alternativa, mientras Elastic Net aporta una referencia de simplicidad y las otras familias muestran los límites de capacidad y costo bajo el presupuesto de entrenamiento utilizado.

La decisión final del avance es mantener LightGBM Tweedie con 500 árboles, tasa 0.05, 63 hojas y potencia 1.5. La evaluación ampliada registra 0.4562 de WMAPE frente a 0.5530 del ingenuo, con 17.5% de mejora relativa. La búsqueda de ambos finalistas se completó parcialmente y no encontró mejores

parámetros. El alias challenger expresa correctamente que el modelo aún debe atravesar validaciones y compuertas antes de convertirse en versión operativa vigente.

6.2 Brechas frente al planteamiento y criterios de aceptación

El avance cubre comparación de rendimiento entre seis familias algorítmicas, justificación de dos finalistas, búsqueda de hiperparámetros, auditoría anti-fuga, explicabilidad multinivel y elección técnica sustentada. La evidencia también permite delimitar los pasos siguientes hacia producción: reservar una ventana de evaluación final independiente para la compuerta, refinar el orden de imputación temporal en los métodos estadísticos por serie y conciliar el alcance del segmento de servicios en el catálogo.

Respecto a la composición del torneo, quedan documentadas tanto la evaluación de los diez modelos candidatos independientes (previa a la construcción de meta-ensambles en la Semana 7) como la distinción entre los seis modelos de estimador único (M0, M1, M2, M6, M8 y M9) y las cuatro formulaciones basadas en árboles (M3, M4, M4b y M5), manteniendo a LightGBM Tweedie y CatBoost Tweedie como los dos finalistas de mayor desempeño predictivo en pesos reales.

Para cerrar la evaluación se requiere reservar una ventana futura no usada para elegir modelos ni parámetros, ampliar la prueba física anti-fuga a los cortes y variables finales, corregir la imputación anterior al truncamiento en Theta y TSB y fijar versiones de datos y mapas. La meta es poder reconstruir el resultado con los mismos insumos y explicar qué evidencia corresponde a desarrollo y cuál a validación final.

La compuerta de negocio del planteamiento exige WMAPE global menor que 0.553 y mercancía menor que 0.506, sesgo dentro de ±3% en cada corte y significancia diaria en al menos tres cortes. Los resultados actuales apoyan las condiciones de error global y mercancía, pero deben publicarse los controles restantes en la población aprobada, con especial atención a servicios, regiones débiles y horizonte 14. La diferencia entre cumplir una meta agregada y aprobar toda la compuerta debe conservarse explícita.

El siguiente módulo indicado por el notebook es 22_cuantiles_y_compuerta. Debe entrenar y evaluar P10, P50 y P90, reportar pinball loss, cruces, ancho de intervalos y cobertura objetivo 80% ±5 puntos por segmento y horizonte, con calibración temporal adecuada. Este notebook no produce esas métricas ni intervalos; el buen resultado puntual no certifica todavía un pronóstico probabilístico útil.

Para operación se requieren contratos de entrada y features, paquete de inferencia con postproceso, reglas críticas de calidad antes de cada corrida, alias de promoción y rollback, jobs encadenados, monitoreo de error y deriva y presupuesto validado. El plan vigente prioriza el flujo en Databricks; la arquitectura React/API/SQL descrita en documentos de visión es una evolución propuesta y no se declara construida por este avance [2, 12–14].

6.3 Relación con promociones y decisiones de negocio

La utilidad inmediata es disponer de un candidato y un diagnóstico de dónde sus pronósticos son confiables en términos relativos y dónde requieren control. Para promociones se necesita separar el calendario conocido en T de información observada después, y evaluar escenarios bajo un rango soportado por los datos. SHAP y las importancias actuales no estiman elasticidad causal ni autorizan recomendar descuentos óptimos.

La siguiente fase deberá validar qué variables comerciales pueden cambiarse, cómo se generan escenarios y cómo se publica el resultado de forma trazable. El usuario de negocio podrá seleccionar parámetros autorizados; no deberá alterar rezagos, medias o categorías técnicas del modelo. La traducción de ventas monetarias a unidades, inventario y reabasto exige sus propios contratos y validaciones. Sólo una evaluación operacional posterior podrá cuantificar el beneficio en disponibilidad, merma y rentabilidad.

El cierre de la Semana 6 es, por tanto, un candidato de pronóstico seleccionado con evidencia comparativa, dos procesos de afinación documentados y una ruta concreta de aceptación. La entrega preserva la continuidad con la ingeniería de características y el baseline, al tiempo que reconoce los cambios de población, infraestructura y alcance que impiden comparar cifras históricas como si procedieran del mismo experimento.

Referencias bibliográficas

[1] Equipo 43. (2026). Avance 4 TEC.ipynb. Módulos 20_features_oro y 21_avance4_modelos_alternativos. Código y salidas registradas del 20 y 22 de octubre. Figuras 1–5 extraídas de las salidas 5, 7, 9, 11 y 20 del segundo módulo; tablas transcritas de resultados agregados.

[2] Equipo 43. (2026). Planteamiento_S6-S10_Equipo43_CRISP-MLQ_v2. Plan de trabajo y criterios de aceptación. https://docs.google.com/document/d/1XehGfo6DLlez821BwaPDWox4j10k70UK/edit

[3] Equipo 43. (2026). Avance Semana4 - Ingeniería de Características (Equipo 43). https://docs.google.com/document/d/1r-dx7EVVIT4JILsGYrFCaY2EUYMdCLyZ37MHncDB7PM/edit

[4] Equipo 43. (2026). Semana 5 - Avance 3: Baseline y Validación Walk-Forward (Equipo 43). https://docs.google.com/document/d/18tU5GyYrHh1WttJrWyhA31jnBU_foCvZdOvon9M9W5w/edit

[5] Diebold, F. X., y Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business & Economic Statistics, 13(3), 253–263. Referencia metodológica del contraste de pérdidas utilizado en el proyecto.

[6] Dunn, P. K., y Smyth, G. K. (2005). Series evaluation of Tweedie exponential dispersion model densities. Statistics and Computing, 15(4), 267–280. Referencia de la familia Tweedie.

[7] LightGBM. Documentación oficial de LGBMRegressor. Parámetros de boosting y número de árboles. https://lightgbm.readthedocs.io/en/v4.6.0/pythonapi/lightgbm.LGBMRegressor.html

[8] scikit-learn. Documentación oficial de RandomForestRegressor. Metaestimador y agregación de árboles. https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

[9] Duan, N. (1983). Smearing estimate: A nonparametric retransformation method. Journal of the American Statistical Association, 78(383), 605–610. Referencia de la corrección de retransformación.

[10] Optuna. Documentación oficial de TPESampler. Fase inicial aleatoria y muestreo adaptativo. https://optuna.readthedocs.io/en/stable/reference/samplers/generated/optuna.samplers.TPESampler.html

[11] Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30. Marco metodológico de SHAP.

[12] Bnext. Documentacion.md. Prototipo implementado, contratos y evaluación histórica. Copia de referencia del proyecto.

[13] Bnext. Arquitectura.md. Arquitectura objetivo sobre Azure Databricks y separación entre batch y consulta. Documento de visión.

[14] Bnext. Future.md. Prioridades, simulación y evolución propuesta. Documento de visión.

(2026). ChatGPT (basado en GPT-5), se utilizó como herramienta de apoyo para la redacción, ampliación y organización de contenidos, la revisión ortográfica y gramatical, y la mejora de la claridad, coherencia y formato del documento. https://chat.openai.com/